

Outils de recherche en sciences sociales numériques

Chaire de leadership en enseignement des sciences sociales numériques (CLESSN)

2024-03-12

Table of contents

Avant-propos

Ceci est un exemple de citation Adcock and Collier (2001) .

Introduction

1 Données massives, causalité et sciences sociales : Changements et réflexions sur l'avenir

L'apparition des données massives (*big data*) dans le paysage technologique représente un cas de phénomène hautement technique dont les effets politiques et sociaux sont remarquables. Depuis quelques années, la discussion publique s'est en effet rapidement emparée du sujet, au point de transformer un développement technologique en phénomène social. Les données massives se trouvent ainsi régulièrement présentées dans l'espace public à la fois comme un moyen puissant de développement et d'innovation technoscientifique, de même que comme une menace à la stabilité de certaines normes sociales telles que la confidentialité des informations privées. Il n'est d'ailleurs pas rare que le discours public s'inquiète du danger que poseraient les données massives à la séparation des sphères publique et privée, pourtant centrale à la conception libérale du rôle de la politique qui structure la majorité des débats sociaux, en amalgamant parfois de manière trop rapide l'objet et l'utilisation qui en est faite. Toutefois, ce même discours public s'emporte aussi rapidement à propos des gains technologiques monumentaux réalisés par l'utilisation des données massives.

Dans le domaine des sciences sociales, les avancées dues à l'utilisation des données massives se font de plus en plus fréquentes et l'impact des données massives dans le domaine de la recherche sociale est en ce sens indéniable. Toutefois, d'un point de vue épistémologique, l'utilisation des données massives en recherche en sciences sociales dans les dernières années laisse plusieurs questions ouvertes dans son sillage.

1 Données massives, causalité et sciences sociales : Changements et réflexions sur l'avenir

Comment l'utilisation des données massives change-t-elle la pratique des sciences sociales? Les données massives causeront-elles un changement de paradigme scientifique?

Ce chapitre ne prétend pas offrir de réponses définitives à ces questions, mais plutôt des pistes de réflexion par le biais d'une introduction critique de certains points relatifs aux impacts des données massives sur la recherche en sciences sociales. Premièrement, nous présentons une conceptualisation des données massives. Deuxièmement, nous nous penchons sur les impacts des données massives en sciences sociales et soulignons tout particulièrement comment elles affectent les enjeux de la *validité* interne et externe dans le domaine des sciences sociales. Cela nous offre aussi l'opportunité d'aborder le sujet important de la différence entre les données expérimentales et observationnelles. Finalement, nous proposons quelques pistes de réflexion sur l'avenir des données massives en sciences sociales en identifiant certains changements *épistémologiques* que ces données pourraient potentiellement entraîner.

1.1 Définition des données massives

Il existe au moins trois approches conceptuelles permettant de définir les « données massives » (voir Figure 1.1.).

1.1 Définition des données massives

1. Définition de base	Quantité importante de données dont la nature, le type, la source, etc. varient
2. Définition technique/technologique	Ensemble de <i>pratiques</i> de collecte, de traitement et d'analyse de ces données
3. Définition sociologique	Innovation technique et technologique, de même que les effets sociaux qui l'accompagne

1. Premièrement, les données massives représentent une ***quantité importante de points d'information*** qui varient selon la nature, le type, la source, etc. Ici, la distinction entre données massives et données plus traditionnelles (ou « non-massives ») est simplement quantitative.
2. Deuxièmement, les données massives constituent un ***ensemble de pratiques*** de collecte, de traitement et d'analyse de ces points d'information. Les données massives représentent une technique, c'est-à-dire une manière ou une méthode nouvelle de faire de la recherche.
3. Finalement, d'une perspective sociologique, les données massives représentent les impacts sociaux de ces importants développements technologiques. Cette perspective souligne le caractère essentiellement social des données massives, en portant notamment attention aux risques liés à la confidentialité des données, aux enjeux relatifs au consentement et à l'autorisation de collecte des informations, aux innovations en intelligence artificielle, etc.

Dans les domaines scientifiques et technologiques, la définition courante attribuée aux données massives intègre des éléments de ces trois niveaux d'analyse en se référant à la composition et à la fonction des données. Premièrement, la *composition* des données massives est généralement conceptualisée comme comprenant « 4V » : le volume, la variété, la vélocité

et la véracité. Cette conceptualisation jouit d'un large consensus scientifique (Chen, Mao et Liu, 2014; Gandomi et Haider, 2015; Kitchin et McArdle 2016). Par ailleurs, plusieurs chercheurs ont élargi cette définition de la composition des données massives en y incluant, par exemple, la variabilité et la valeur des points de données (Kitchen et McArdle 2016). Deuxièmement, la *fonction* des données massives comprend les innovations relatives à l'optimisation, à la prise de décision et à l'approfondissement des connaissances qui résultent de leur utilisation. Ces fonctions touchent des domaines sociaux disparates, incluant le souci d'efficacité et de rendement des secteurs privé et public ainsi que la recherche scientifique pure (Gartner 2012).

1.2 Les données massives et les sciences sociales

Dans le domaine des sciences sociales, les changements causés par l'utilisation des données massives en recherche sont significatifs. Plusieurs n'hésitent d'ailleurs pas à les qualifier de changements de paradigme dans l'étude des phénomènes sociaux (Anderson 2008; Chandler 2015; Grimmer 2015; Kitchin 2014; Monroe et al. 2015). Dans le cas qui nous intéresse, deux dimensions majeures méritent d'être abordées : (1) une première relative à la validité (interne et externe) des données massives et (2) une seconde relative à la différence entre les données expérimentales et les données observationnelles. Ces deux dimensions sont présentées de manière simultanées dans les prochaines sections.

1.2.1 La validité de la mesure en sciences sociales

La validité de la mesure constitue une exigence méthodologique centrale à la recherche en sciences sociales. Les scientifiques cherchent effectivement à s'assurer que ce qui est mesuré — par un sondage, une entrevue, un thermomètre ou tout autre outil de mesure — constitue bel et bien ce qui est censé être mesuré. Adcock et Collier définissent plus spécifiquement l'application

1.2 Les données massives et les sciences sociales

de la validité de la mesure en sciences sociales en affirmant que des scores (y compris les résultats de classification qualitative) doivent capturer de manière significative les idées contenues dans le concept correspondant (2001: 530).

Toutefois, les problèmes liés à la validité de la mesure sont nombreux et ont une importance considérable. Dans l'étude des phénomènes sociaux et humains, la validité de la mesure prend d'ailleurs une complexité supplémentaire du fait que les données collectées par le biais d'une mesure constituent le *produit de l'observation* d'un phénomène, mais non pas le phénomène en soi. Ainsi, lorsque, dans le contexte d'une recherche, on propose de mesurer l'humeur de l'opinion publique (le phénomène en soi) sur un enjeu politique, on utilise généralement un sondage qui a pour fonction de mesurer le pouls d'un échantillon de la population d'intérêt (ce qui est réellement observé). Cependant, ce que ce sondage mesure ne constitue pas tout à fait l'opinion publique elle-même, mais plutôt un segment populationnel qui se veut le plus souvent représentatif de l'humeur de l'opinion publique. Ceci est tout aussi vrai pour les sondages à petits échantillons que pour ceux utilisant des données massives. Autrement dit, la mesure et les données collectées ne représentent pas le phénomène — l'opinion publique — en soi.

On a déjà mentionné que la validité de la mesure a de l'importance puisqu'elle garantit que ce qui est mesuré représente réellement ce qu'on croit mesurer. Toutefois, pour être plus spécifique, dans une approche positiviste, la validité de la mesure se traduit généralement par une logique de classification des valeurs attribuées aux différentes manifestations distinctes d'un même phénomène. Par exemple, une mesure de la démocratie comme celle proposée par *Freedom House*, fréquemment utilisée en science politique, classifie les libertés civiles et les droits politiques des États du monde par degré afin de construire un index, ou une échelle, allant d'un autoritarisme complet à une démocratie parfaite. Les scores représentent, dans ce contexte, une mesure artificielle, mais ordonnée et logique, des idées contenues dans le concept de démocratie telles que libertés civiles et droits politiques. On peut ainsi dire que la question de la validité de la

mesure est un élément central de ce qui unit (1) le phénomène social étudié (la démocratie), (2) son opérationnalisation (via les libertés civiles et droits politiques) et (3) la méthode de mesure utilisée pour observer et classifier d'une certaine façon le phénomène et les données qui en découlent (dans le cas de *Freedom House*, des codeurs travaillant de manière indépendante les uns des autres).

1.2.2 La validité des données massives

En ce qui a trait aux données massives, la question de la validité de la mesure constitue un défi nouveau. Les données massives ont en effet comme avantage d'offrir aux chercheur.e.s soit de nouveaux phénomènes à étudier, soit de nouvelles manifestations et nouvelles formes à des phénomènes déjà étudiés. Les données massives permettent donc d'agrandir la connaissance scientifique.

L'étude de King et al. (2013) représente un cas éclairant de phénomène social que l'utilisation des données massives permet désormais d'étudier. En se basant sur la collecte de plus de 11 millions de publications en ligne, King et ses collègues ont pu mesurer la censure exercée par le gouvernement chinois sur ces réseaux sociaux. En utilisant des données massives nouvelles, les auteurs ont donc pu observer une manifestation inédite de censure massive qui, sans de telles données, serait probablement demeurée mal comprise d'une perspective scientifique. Le nombre de recherches basées sur l'utilisation des données massives similairement innovantes en sciences sociales est par ailleurs en croissance constante (Beauchamp 2017; Bond et al. 2012; Poirier et al. 2020; Bibeau et al. 2021).

Cependant, il faut aussi souligner que les données massives, en raison de leur complexité, peuvent avoir pour désavantage d'embrouiller l'étude des phénomènes sociaux. Les opportunités scientifiques liées aux données massives s'accompagnent en effet de certaines difficultés méthodologiques. Parmi ces difficultés, trois enjeux sont particulièrement cruciaux : (1) la validité interne, (2) la validité externe et (3) la question d'un changement

1.2 Les données massives et les sciences sociales

de posture ou d'orientation épistémologique en sciences sociales causé par les données massives.

1.2.2.1 Validité interne des données massives

Premièrement, les données massives peuvent représenter un défi à la validité interne des études en sciences sociales en rendant pratiquement difficile l'établissement de *mécanismes causaux clairs*. Ce défi est notamment une conséquence du fait que la plupart des données sont présentement issues d'un processus de génération (*data-generating process*) qui est hors du contrôle des chercheur.e.s. Les données massives proviennent en effet habituellement de sources diverses qui sont externes aux projets de recherche qui les utilisent. Elles ne sont pas donc générées de manière aléatoire sous le contrôle des chercheur.e.s.

Un des problèmes liés à cette situation est qu'il est difficile de garantir une source *exogène* de variation par laquelle les chercheur.e.s éliminent l'effet potentiel des facteurs confondants (*confounders*). Règle générale, la distribution aléatoire d'un traitement et d'un contrôle dans une expérience en laboratoire ou sur le terrain représente le standard le plus élevé permettant de fournir cette source exogène de variation, notamment parce qu'elle l'attribution aléatoire du traitement ou du contrôle est entièrement sous le contrôle du chercheur.e.s menant l'expérience. Cependant, en ce qui à trait à la plupart des données massives, elles sont générées de manière indépendante du contrôle du chercheur.e.s, et sont donc soumises aux mêmes enjeux et problèmes (biais) que les données observationnelles traditionnelles.

Pour le dire autrement, le défi de validité interne avec les données massives constitue un enjeu relatif à la qualité des données. Ce n'est évidemment pas un défi propre ou unique aux données massives. Ce défi s'applique également aux autres types de données. Cependant, dans l'état actuel des choses, le volume et la variété — deux des 4V — des données massives — textuelles, numériques, vidéos, etc. — peuvent miner la qualité de l'inférence causale

entre une cause et une conséquence que permet habituellement un processus contrôlé de génération des données. En somme, la validité interne des données massives est une fonction de la qualité de ces mêmes données.

1.2.2.2 Validité externe des données massives

Deuxièmement, les données massives représentent aussi un défi important pour la validité externe des recherches en sciences sociales (Tufekci 2014; Lazer et Radford 2017; Nagler et Tucker 2015). Un des problèmes les plus évidents concerne la **représentativité** des données massives collectées.

Comme le soulignent Lazer et Radford (2017), la quantité de données, en soi, ne permet pas de corriger pour la non-représentativité des données. Les données massives sont ainsi soumises au même problème de biais de sélection que les autres types de données observationnelles, tels un sondage ou une série d'entrevues, traditionnellement utilisés en sciences sociales.

Le cas célèbre de l'erreur de prédiction du *Literary Digest* lors de la campagne présidentielle américaine de 1936 illustre bien ce problème. Lors de cette campagne, le *Literary Digest* a prédit à tort la victoire du candidat républicain Alf Landon sur le président démocrate sortant Franklin D. Roosevelt, puisque son échantillon de répondants surreprésentait les électeurs plus aisés, traditionnellement plus républicains, au détriment des électeurs moins aisés, plus généralement proches du Parti démocrate. Cette erreur de surreprésentation dans l'échantillon est due au fait que le *Literary Digest* a effectué un échantillonnage basé sur les listes téléphoniques et le registre des propriétaires de voitures, biaisant par le fait même l'échantillon au détriment des électeurs plus pauvres ne possédant pas de téléphone ou d'automobile, mais qui constituaient un électorat favorable à Roosevelt (Squire 1981). Le biais de sélection du sondage a ainsi sous-estimé le soutien populaire de Roosevelt de plus de 20 points de pourcentage.

Aujourd'hui, l'utilisation des données massives est soumise aux mêmes enjeux méthodologiques. L'accumulation massive de données ne permet pas

1.2 Les données massives et les sciences sociales

de compenser pour la qualité des données. Les données massives, comme les données plus traditionnelles, sont soumises aux conséquences induites par le processus de génération des données (*data generating process*) comme un échantillonnage.

Toutefois, depuis quelques années, le développement de nouvelles méthodes de pondération des données offre des pistes de solutions. La grande quantité de données massives permet notamment d'appliquer des méthodes de pondération bien plus efficaces pour corriger les échantillons non-représentatifs (Wang et al. 2015).

1.2.3 Données expérimentales

La question du processus de génération des données devient plus claire quand on considère comment les *données observationnelles* et les *données expérimentales* permettent d'effectuer des inférences de manière distincte (voir Figure 2). Toutefois, pour bien comprendre ce point, il faut comprendre les notions de données expérimentales et d'inférence causale, qui sont centrales au domaine de la causalité en recherche.

En quelques mots, l'essence de la démarche causale se résume comme suit : le processus de génération de données expérimentales a pour objectif d'assurer la validité d'une inférence causale estimée sur un échantillon sur l'ensemble de la population visée.

Plus spécifiquement, le processus de génération des données permet aux chercheur.e.s de s'assurer que la distribution du traitement entre les deux groupes, traitement et contrôle, est entièrement aléatoire. De manière technique, cette distribution aléatoire du traitement entre les deux groupes permet de garantir une source exogène (à l'opposé de endogène) de variation sur la variable indépendant (x). *Cette source exogène de variation permet, quant à elle, d'éliminer l'endogénéité entre la variable indépendante (x) et le résidu (e^*).*

Autrement dit, le fait de distribuer au hasard le traitement entre les membres du groupe traitement et ceux du groupe contrôle assure que la variation dans les résultats ne vient pas d'autres facteurs non-contrôlés (le résidu, e), mais plutôt du traitement lui-même (la variable indépendante, x). En distribuant le traitement de manière aléatoire, on s'assure que les différences dans les résultats sont vraiment dues au traitement et non à d'autres facteurs.

Il s'agit là d'assurer le respect de la condition d'indépendance, essentielle à la validité de l'identification de l'effet causal étudié. Autrement dit, en éliminant l'endogénéité entre la x et e , on s'assure que l'effet observé n'est pas dû à une variable confondante.

Pour revenir aux données massives, celles-ci ne peuvent pas résoudre les enjeux liés aux inférences causales ou explicatives (Grimmer, 2015). Elles sont en effet également soumises aux mêmes impératifs issus du processus de génération des données.

1.2.4 Données observationnelles

En ce qui a trait aux données observationnelles, il y a deux points importants. Premièrement, des méthodes d'inférence basées sur des approches par design (*design-based methods*) comme une méthode de régression sur discontinuité ou de variable instrumentale peuvent également garantir des inférences explicatives et causales valides. Elles nécessitent toutefois plusieurs postulats plus restrictifs dont l'objectif est d'imiter ou de récréer, de la manière la plus fidèle possible, une distribution aléatoire du traitement – ce que la littérature appelle un *as-if random assignment* (comme si l'attribution était aléatoire) (Dunning, 2008).

Dans un contexte observationnel, les données massives peuvent donc permettre d'augmenter la précision des estimations causales. Effectivement, comme dans un modèle de régression linéaire, plus l'échantillon est grand,

1.2 Les données massives et les sciences sociales

plus l'estimation du coefficient causal ou probabiliste est précise. Par exemple, un échantillon large dans un modèle de régression sur discontinuité permet de restreindre la largeur de bande autour du seuil, garantissant ainsi une distribution presque parfaitement aléatoire des données et une validité plus élevée à l'estimation de l'effet causal.

Un autre exemple pourrait être l'utilisation du « matching », souvent utilisé dans les études économétriques. Supposons que vous souhaitez estimer l'effet d'un programme éducatif sur les résultats scolaires d'étudiant.e.s. Le devis de recherche idéal serait d'assigner aléatoirement les étudiant.e.s au programme (le groupe traitement) ou non (le groupe contrôle). Toutefois, puisque ce devis idéal peut être difficilement réalisable, un grand nombre de données pourrait permettre de trouver pour chaque étudiant.e dans le groupe traitement un étudiant.e « jumeau » dans le groupe contrôle. Ce « jumeau » serait similaire en âge, sexe, antécédents socio-économiques, etc. Il serait ensuite possible de comparer les résultats scolaires de ces jumeaux pour estimer l'effet du programme. Plus l'échantillon est grand, plus l'estimation sera précise et fiable, parce qu'il y aura plus de jumeaux possibles à apparié, réduisant ainsi le biais dû aux variables non observées.

Il s'agit d'un exemple où les données massives augmentent la validité interne de l'étude, même si les données sont de nature observationnelle et non expérimentale.

Deuxièmement, un échantillon de données massives observationnelles issues d'une plateforme comme X — anciennement Twitter — ou Facebook peut fournir une *description* plus fine de certaines dynamiques sociales observées sur les réseaux sociaux. Cependant, c'est la manière dont sont collectées les données de cet échantillon de données massives qui garantit la représentativité de l'échantillon — avec pour objectif l'absence d'un biais de sélection — et non pas la quantité de données. Généralement, le biais d'un échantillon est une conséquence de la non-représentativité des répondants; dans notre exemple, les utilisateurs des médias sociaux ne sont généralement pas représentatifs de la population entière.

Dans un tel cas, des méthodes de pondération sur des données observationnelles peuvent compenser pour la sur- ou la sous-représentativité de sous-groupes dans un échantillon afin d'assurer la validité de l'inférence entre échantillon et population. Les données massives ont ici une importance puisqu'une pondération fiable nécessite une quantité substantielle d'observations. Une pondération *a posteriori* sera donc plus fiable plus l'échantillon est grand. Les données massives ont ainsi une valeur ajoutée afin d'établir des inférences descriptives plus précises et sophistiquées.

1.2.5 Validité écologique et observation par sous-groupes

Les données massives peuvent aussi jouer d'autres rôles importants relatifs à la validité externe. Premièrement, les données massives facilitent effectivement la validité externe de certaines études en accroissant la validité écologique (*ecological validity*) des tests expérimentaux, c'est-à-dire le réalisme de la situation expérimentale (Grimmer, 2015: 81). En effet, la variété des sources et des formats de données permet aux chercheurs d'imiter plus fidèlement la réalité sur le terrain vécue par les participants aux études.

Deuxièmement, la quantité importante de données rend possible l'observation d'effets précis, spécifiques et inédits par sous-groupes (Grimmer 2015: 81). Alors qu'auparavant, la taille réduite des échantillons ne permettait pas d'effectuer des inférences valides pour des sous-groupes de la population — les écarts-types par sous-groupes étaient trop grands, rendant difficile l'estimation précise d'un paramètre comme la moyenne et impossible celle d'un coefficient —, la taille énorme des échantillons de données massives permet aux chercheurs d'estimer des paramètres qui étaient demeurés extrêmement imprécis jusqu'à aujourd'hui. Notre compréhension des phénomènes sociaux s'en trouve par le fait même approfondie de façon considérable.

1.3 Conclusion : trois questions ouvertes pour le futur

	Données observationnelles	Données expérimentales
Processus de génération des données	Non contrôlé par le chercheur	Contrôlé par le chercheur
Type d'inférence causale	Locale (LATE) ou populationnelle (ATE)	Populationnelle (ATE)
Méthodes	Approches par design	Distribution aléatoire du traitement
Exemples	Régression sur discontinuité, variable instrumentale	Expérience de terrain, laboratoire

Figure 1.1: image2_2

1.3 Conclusion : trois questions ouvertes pour le futur

Comme nous venons de le voir, la quantité et la variété nouvelle des données massives permettent à la fois un approfondissement de l'analyse de certains phénomènes et l'ouverture de nouvelles avenues de recherche. L'analyse des données massives peut permettre de mettre en lumière des tendances subtiles échappant aux ensembles d'informations plus restreints.

Il faut toutefois souligner que les données massives représentent une complexification de l'analyse des phénomènes en sciences sociales d'une perspective non pas seulement méthodologique/technique mais également épistémologique.

Cela soulève au moins trois questions d'importance, dont les réponses ne nous sont pas encore accessibles, pour l'avenir de la recherche en sciences sociales : (1) les données massives entrent-elles (partiellement du moins) en conflit avec l'impératif de parcimonie qui caractérise la science moderne?; (2) ces données sont-elles dans la continuité ou représentent-elles une coupure dans la tradition béaloréaliste en sciences sociales (et en science politique

1 Données massives, causalité et sciences sociales : Changements et réflexions sur l'avenir

tout particulièrement)?; (3) et finalement, de manière reliée, les données massives proposent-elles ou non une manière de dépasser l'individualisme méthodologique qui caractérise les sciences sociales contemporaines?

2 Le monde du libre

"Vers une science numérique plus transparante: l'apport du logiciel libre et du code ouvert dans les sciences sociales" author: "Catherine Ouellet et Jozef Rivest"

Catherine Ouellet et Jozef Rivest

Ce chapitre vise à initier les lecteurs et lectrices aux concepts fondamentaux du logiciel libre. Pour ce faire, nous présenterons, dans un premier temps, l'historique de ce mouvement afin de pouvoir le situer temporellement. De cette façon, nous pourrons mieux comprendre les motivations derrière ce mouvement, mais aussi ses influences actuelles. Ensuite, nous distinguerons le logiciel libre du code ouvert. Bien que les deux soient très près l'un de l'autre, il est important de les distinguer puisqu'ils ne renvoient pas aux mêmes caractéristiques et aux mêmes fondements. Après coup, nous utiliserons un exemple concret pour illustrer le propos: R, et ses différentes librairies. La dernière section du chapitre présentera les avantages et les inconvénients, en plus de défis qui se posent. En guise de conclusion, nous souhaitons mettre l'accent sur l'apport du logiciel libre et du code ouvert afin d'assurer la transparence, la reproductibilité ainsi que la qualité des recherches scientifiques.

« Vous n'avez pas à suivre une recette avec précision. Vous pouvez laisser de côté certains ingrédients. Ajouter quelques champignons parce que vous en raffolez. Mettre moins de sel car votre médecin vous le conseille — peu importe. De surcroît, logiciels et recettes sont faciles à partager. En donnant une recette à un invité, un cuisinier n'y perd que du temps et le

2 Le monde du libre

coût du papier sur lequel il l'inscrit. Partager un logiciel nécessite encore moins, habituellement quelques clics de souris et un minimum d'électricité. Dans tous les cas, la personne qui donne l'information y gagne deux choses : davantage d'amitié et la possibilité de récupérer en retour d'autres recettes intéressantes. » - Richard Stallman (Williams, Stallman, and Masutti 2010)

Cette analogie illustre bien trois concepts au coeur de la philosophie de Richard Stallman, souvent considéré comme le père fondateur du logiciel libre : liberté, égalité, fraternité. Les utilisateurs de ces logiciels sont libres, égaux, et doivent s'encourager mutuellement à contribuer à la communauté. Ainsi, un logiciel libre est généralement le fruit d'une collaboration entre développeurs qui peuvent provenir des quatre coins du globe. Une réflexion éthique est au cœur du mouvement du logiciel libre, dont les militants font campagne pour la liberté des utilisateurs dès le début des années 1980. La Free Software Foundation (FSF), fondée par Richard Stallman en 1985, définit rapidement le logiciel «libre» [free] comme étant garant de quatre libertés fondamentales de l'utilisateur: la liberté d'utiliser le logiciel sans restrictions, la liberté de le copier, la liberté de l'étudier, puis la liberté de le modifier pour l'adapter à ses besoins puis le redistribuer¹. Il s'agit ainsi d'un logiciel dont le code source² est disponible, afin de permettre aux internautes de l'utiliser tel quel ou de le modifier à leur guise. Puisque le langage machine est difficilement lisible par l'homme et rend la compréhension du logiciel extrêmement complexe, l'accès au code source devient essentiel afin de permettre à l'utilisateur de savoir ce que le programme fait réellement. Seulement de cette façon, l'utilisateur peut *contrôler* le logiciel, plutôt que de se faire contrôler par ce dernier (Stallman 1986).

¹La redistribution doit évidemment respecter certaines conditions précises, dont l'enfreint peut mener à des condamnations [<http://www.softwarefreedom.org/resources/2008/shareware.html>]

²Pour rester dans les analogies culinaires, le code source est au logiciel est ce que la recette est à un plat: elle indique les actions à effectuer, une par une, pour arriver à un résultat précis. Encore une fois, cette dernière peut-être adaptée, modifiée, bonifiée.

2.1 Émergence et sémantique du libre

2.1.1 Émergence et sémantique du *libre*

Plusieurs situent les débuts du mouvement du logiciel libre avec la création de la licence publique générale GNU, en 1983, à partir de laquelle va se développer une multitude de programmes libres. Parmi les plus populaires, on retrouve notamment le navigateur Firefox, la suite bureautique OpenOffice et l'emblématique système d'exploitation Linux, qui se développe d'ailleurs à partir de la licence GNU. Aujourd'hui, il s'agit d'un véritable phénomène sociétal: des milliers d'entreprises, d'organisations à but non lucratif, d'institutions ou encore de particuliers adoptent ces logiciels, dont la culture globale et les valeurs (entraide, collaboration, partage) s'arriment avec le virage technologique de plusieurs entreprises. Les logiciels libres ont différents usages, en passant par la conception Web, la gestion de contenu, les systèmes d'exploitation, la bureautique, entre autres. Ils permettent donc de répondre à plusieurs types de besoins numériques et informatiques.

Attention, le logiciel libre est avant tout une philosophie, voire un mouvement de société. C'est une façon de concevoir la communauté du logiciel, où le respect de la liberté de l'utilisateur est un impératif éthique (Williams, Stallman, and Masutti 2010). Par conséquent, le terme libre, *free* en anglais, porte à confusion. Celui-ci ne signifie pas qu'un logiciel libre est nécessairement gratuit. Certes, plusieurs sont effectivement téléchargeables gratuitement. Toutefois, il est aussi possible de (re)distribuer des logiciels libres payant. Par ailleurs, aucun logiciel libre n'est réellement « gratuit » dans la mesure où son déploiement et son utilisation nécessitent généralement différents coûts, dont les degrés sont variables en fonction des compétences et de l'infrastructure dont disposent les utilisateurs (coût d'apprentissage, coûts d'entretien, etc.). Enfin, il est important de garder en tête que les logiciels libres possèdent eux aussi une licence - cette dernière est d'ailleurs garante des libertés que confèrent les logiciels libres aux utilisateurs.

2.2 Logiciel libre et code ouvert

À voir

Liste de logiciel libre répertorié par le gouvernement du Canada:
<https://code.open.canada.ca/fr/logiciels-libres.html#>

Parallèlement au logiciel libre, il y a aussi le code ouvert, ou *open source*. A priori, la dénomination du logiciel libre et celle du *code ouvert* semble suggérer qu'il s'agit de synonymes. Dans les deux cas on dirait que l'on fait référence à des logiciels, par exemple, qui sont exempts de restrictions d'utilisations et auxquels les utilisateurs peuvent participer au développement. Cependant, il y a une distinction importante entre les deux.

Bien que les deux renvoient sensiblement aux mêmes types de logiciels, les tenants de ces approches ne partagent pas la même perspective. Comme Stallman (2022) l'explique, le logiciel libre est d'abord et avant tout un mouvement qui fait “campagne pour la liberté des utilisateurs de l'informatique”. Le code ouvert, quant à lui, met l'accent sur les avantages pratiques, plutôt que de militer pour des principes.

Le terme *code ouvert* sera introduit seulement en 1998 afin de clarifier l'ambiguité dans la dénomination “logiciel libre”³, *free software* en anglais, afin de spécifier que le code source était accessible, et non pas que le logiciel était “gratuit” (Ballhausen 2019). De plus, les logiciels code ouvert, doivent respecter certains critères quant à la distribution de leurs logiciels (Open Source Initiative 2006). Nous aborderons ces critères dans le prochain paragraphe.

Afin de mieux distinguer les deux, il est utile de faire référence aux critères qui composent ces deux éléments, et qui constituent la base de leur définition. Tout d'abord, le logiciel libre se définit sur la base de quatre libertés:

³Soit ceux qui ont été conçus suivant les principes philosophiques et “moraux” qui sous-tendent ce mouvement.

2.2 Logiciel libre et code ouvert

1) liberté d'utiliser le programme tel que désiré; 2) liberté d'étudier le fonctionnement du programme et de le modifier pour ses propres besoins; 3) liberté de re-distribuer des copies; 4) liberté de distribuer des copies de la version “améliorer” du programme pour ses pairs (Ballhausen 2019). Concernant le *code ouvert*, tout logiciel qui souhaite être inclus sous cette appellation doit respecter dix critères: 1) Redistribution gratuite; 2) doit inclure le code source; 3) doit permettre les modifications et les travaux dérivés; 4) intégrité du code source; 5) ne doit pas discriminer des personnes et/ou groupes; 6) ne doit pas restreindre personne dans l'utilisation du logiciel pour un domaine d'activité; 7) distribution d'une licence pour l'utilisation; 8) la licence ne doit pas être spécifique pour un produit; 9) la licence ne doit pas placer de restriction sur d'autres programmes; 10) la licence doit être technologiquement neutre⁴ (Open Source Initiative 2006).

Il est aussi utile de distinguer des logiciels “non-libres”, soit les logiciels propriétaires: “Son utilisation, sa redistribution ou sa modification sont interdites, ou exigent une autorisation spécifique, ou sont tellement restreintes qu'en pratique vous ne pouvez pas le faire librement” (Système d'exploitation GNU 2023). Par contraste, la licence libre confère des droits de propriétaire. L'utilisateur a le droit d'installer le logiciel sur autant d'ordinateurs que désiré, le modifier selon ses besoins et le distribuer avec ou sans ses modifications. Il peut même demander d'être payé pour distribuer des copies, avec ou sans ses modifications. Par exemple, le logiciel Ubuntu, une version de Linux, peut être téléchargé gratuitement du site Ubuntu.com. Il est aussi vendu par Amazon.com pour 12\$ la copie, plus les frais d'expédition!

Comme nous le constatons, le logiciel libre et le *code ouvert* ont certaines similitudes puisqu'ils adhèrent tous les deux à la même vision du logiciel, ainsi que de son accessibilité. Toutefois, il est important tout de même

⁴Pour plus d'informations sur ces caractéristiques, nous encourageons les lecteurs à se référer au lien web de Open Source Initiative (2006). Ils y trouveront un contenu détaillé pour chacunes des caractéristiques sus-mentionnées.

2 Le monde du libre

de les distinguer puiqu'ils ont des origines différentes, et qu'ils mènent à certaines pratiques qui sont différentes. La prochaine section utilise un cas concret afin d'expliquer l'effet du libre, et l'utilité que cela peut avoir.

2.3 Les sciences sociales à l'ère du numérique: les enseignements de la philosophie du logiciel libre

En quoi est-ce que ces deux concepts, issus du monde de l'informatique, sont-ils intéressants et/ou important pour les sciences sociales? Pour répondre à cette question, il est important de retourner à la base, soit de se questionner sur que sont les sciences sociales.

Ce chapitre à voulu mettre de l'avant le logiciel libre afin d'initier les lecteurs et lectrices à ce monde. Le but n'était pas de présenter de manière exhaustive tout ce champ. Plutôt, nous avons préféré nous limiter aux bases de compréhension, ainsi qu'à quelques exemples. Par conséquent, nous souhaitions qu'à la lecture du chapitre, les lecteurs et lectrices soient mieux outillés pour comprendre et réfléchir par rapport à ce monde, et ainsi insérer ces réflexions dans leurs démarches scientifiques. Générer des idées et des débats nous paraît bien plus promoteur pour l'avenir que d'apprendre par coeur.

En guise de conclusion, nous souhaitons résumer ce chapitre tout en situant ces différents éléments dans les sciences sociales à l'ère du numérique. Le livre de Marres (2017) est très intéressant à ce sujet. Face au constat que la vie sociale se trouve affectée par les changements numériques, il nous faut en tant que chercheur du monde social réfléchir à notre façon de comprendre les changements qui sont entrain de s'opérer. Bien que ces réflexions ratissent large⁵, nous nous concentrerons ici sur la dimension méthodologique.

⁵Allant de nos postulats ontologiques, épistémologiques et méthodologiques.

2.3 Les sciences sociales à l'ère du numérique: les enseignements de la philosophie du logiciel libre

Comme nous l'avons présenté ci-haut, les bas coûts associés à l'utilisation ainsi que la facilité du partage avec la communauté nous semble être deux avantages importants pour l'avenir des sciences sociales numériques. Notamment parce qu'ils ont le potentiel d'améliorer la transparence des protocoles scientifiques. Dans *Designing Social Inquiry*, l'un des livres les plus influents en science politique depuis les trente dernières années, les auteurs définissent quatre caractéristiques que chaque recherche doit posséder afin d'être considérée comme scientifique. L'une d'elles, est que la *procédure doit être publique*: "La recherche scientifique utilise des méthodes explicites, codifiées et publiques afin de générer et analyser des données sur lesquelles la fiabilité peut ensuite être déterminer" (King, Keohane, and Verba 2021, 6). Chaque individu qui souhaite contribuer à la connaissance et à la compréhension globale que nous avons de la réalité sociale doit garder en tête cette caractéristique fondamentale. Comme nous l'avons exposé, le partage du code devient un impératif pour assurer la transparence, la réplicabilité ainsi que la qualité des recherches.

2.3.1 Avantages

2.3.1.1 Le partage et co-construction des connaissances

La grande liberté que ce type de logiciel offre favorise la collaboration entre les utilisateurs, et ce à une échelle pouvant être internationale. Les interactions entre les chercheurs créées une dynamique d'« innovation ascendante » et d'entraide (Couture 2014). Ce résultat constitue un avantage important pour le développement de ces logiciels. Selon certains, et comparativement aux logiciels privés, les logiciels libres ont un niveau plus élevé d'innovation (Smith 2002). Contrairement à ceux qui se développent de manière privé et fermée, les logiciels libres permettent à tous les utilisateurs de participer au développement. Ceux-ci partagent ensuite leurs améliorations, ce qui stimulent à son tour de nouvelles initiatives. Ainsi, un certain savoir est généré dans cette situation. De plus, il est raisonnable de penser que l'utilité des améliorations, ainsi que leur utilisation par les utilisateurs en fonction

2 Le monde du libre

de leur besoin, comme dans le cas de la recherche sociale avec R permet de générer un savoir collaboratif (Couture 2020). Amélioration constante, entraide, savoir partagé et plusieurs milliers de contributeurs (Couture 2014), ces éléments résument très bien la philosophie du logiciel libre.

Comme nous le verrons dans la section suivante, cet avantage est couplé avec ceux économiques. Les bas coûts démocratise l'accès à plusieurs logiciels qui sont utiles pour mener des analyses scientifiques. Et ce, pour tous les utilisateurs dans le monde.

2.3.1.2 Avantages économiques : Une plus grande accessibilité pour tous

Le principal avantage économique des logiciels libres est son faible d'acquisition et de renouvellement pour les particuliers. Cet avantage individuel génère plusieurs externalités positives.

Tout d'abord, certains logiciels statistiques et programmes informatiques, tel que Stata et SPSS, coûtent plusieurs centaines, voir des milliers de dollar. De plus, la license doit être renouvelée annuellement. Ce qui augmente les coûts associés à l'utilisation du logiciel et par conséquent limite son accessibilité. Comparativement, pour les logiciels libres, la license d'acquisition coûte bien souvent moins cher, et aucun renouvellement de licence n'est demandé dans la plus part des cas. Étant donné que les chercheurs doivent souvent faire face à des contraintes budgétaires, les logiciels libres deviennent des outils intéressant afin de minimiser les coûts de la recherche (Yu and Muñoz-Justicia 2022). Avantage encore plus important pour les chercheurs dans les pays du Sud global (Santillán-Anguiano and González-Machado 2023). L'accessibilité de ces ressources permet donc de réduire l'écart dans la production scientifique entre les pays du Sud et ceux du Nord. De plus, elle permet à tous de bénéficier d'outils pédagogiques accessibles, ce qui favorise l'acquisition ainsi que le développement de compétences méthodologiques.

2.3 Les sciences sociales à l'ère du numérique: les enseignements de la philosophie du logiciel libre

Dans le cadre d'une formation universitaire, il peut être pertinent d'enseigner aux étudiants à se servir de logiciel statistique ou d'analyse de texte. L'acquisition de ces compétences peut être précieux tant pour ceux et celles qui souhaitent se diriger vers le milieu académique, que pour ceux et celles qui visent le marché professionnel. D'ailleurs sur le site web de la banque d'emplois du gouvernement du Canada⁶, les conditions d'emplois sont en ce moment⁷ très bonnes, et une pénurie de main d'oeuvre est anticipé, entre 2022-2031, dans les emplois en analyse de données. Ces compétences sont d'autant plus précieuses aujourd'hui, dans le monde de données dans lequel nous vivons.

Ensuite, le logiciel libre est adaptable et modifiable. Ces coûts techniques de développement restent néanmoins nettement inférieurs aux coûts de renouvellement et de mise à jour des logiciels propriétaires dans bien des cas. L'argent sauvegardé des licences peut alors être investi dans le développement du logiciel libre (Béraud 2007). Cependant, une transition vers les logiciels libres ne doit pas se faire seulement sur des bases économiques, mais dans une perspective globale de changement de cultures. Changer pour des raisons purement économiques viendrait à violer l'essence même de la philosophie du logiciel libre, qui se veut davantage être un esprit de collaboration et de transparence. Par conséquent, il est important d'incorporer aussi les valeurs et la philosophie dans notre utilisation

Pour résumer, les logiciels libres permettent donc une plus grande égalité dans l'accès aux nouvelles technologies, puisqu'ils ont dans la majorité des cas, des coûts d'acquisition nettement moindre. (Oui et non, l'acquisition financière est une chose, mais il y a d'autres barrières à l'utilisation tel que l'apprentissage à faire pour apprendre un langage de programmation, l'achat de matériel informatique, etc.) Cependant, considérant cela, donner l'exemple de l'étude qui montre que c'est beaucoup plus économique, même si l'on doit compter les coûts de formation, le soutien technique, l'entretien

⁶Ces informations proviennent du site web suivant:
<https://www.jobbank.gc.ca/marketreport/outlook-occupation/17882/ca>

⁷En date d'écrire ces lignes, septembre 2023.

2 Le monde du libre

et la maintenance. (Couture 2014; Karjalainen 2010).

2.3.2 Inconvénients et défis:

2.3.2.1 Coûteux en temps

Dans leur texte, Paura and Arhipova (2012) soulèvent une critique faite envers certains logiciels libres, notamment envers R. Le problème principal d'enseigner les statistiques avec des logiciels libres est qu'ils sont compliqués à apprendre ainsi qu'à utiliser; par conséquent, les étudiants passeraient plus de temps à tenter de résoudre les erreurs de programmation plutôt que d'apprendre les statistiques. Il est vrai que ces logiciels demandent un investissement en temps, afin d'être en mesure de mener ses propres analyses statistiques. Par exemple, R demande l'apprentissage d'un langage de programmation afin de pouvoir utiliser le logiciel à son plein potentiel.

La synthaxe de certaines libraries demandent aussi un certain temps d'adaptation. Par exemple, je souhaite recoder la variable femme, de l'ensemble de données `titanic`, afin de remplacer les valeurs numériques actuelles (0, 1) par des valeurs nominales (homme, femme). La section de code ci-dessous réalise cette tâche avec les commandes de base de R et celle du `tidyverse`.

Toutefois, lorsqu'on compare le coût d'apprentissage avec les bénéfices tirés, il est plus difficile de soutenir qu'il s'agit d'un désavantage. L'habileté que nous développons devient très utile par la suite, puisqu'elle nous permet de manipuler ainsi que d'analyser des données. Surtout, ces compétences s'inscrivent dans la longue durée, alors que l'apprentissage est plutôt de courte à moyenne durée. Surtout, la logique derrière la synthaxe de base de R et celle d'une nouvelle librairie reste sensiblement inchangée. Par conséquent, lorsque nous avons une bonne compréhension du fonctionnement de base de R, l'apprentissage d'une nouvelle librairie se fait relativement rapidement. Certaines, comme `dplyr` du `tidyverse` facilite grandement la manipulation des données comparativement aux commandes de base.

2.3 Les sciences sociales à l'ère du numérique: les enseignements de la philosophie du logiciel libre

Pour résumer, bien que l'apprentissage d'un langage de programmation demande un investissement en temps, les bénéfices générées par ces nouvelles compétences dépassent le coût initial.

2.3.2.2 Problème de transparence

L'arrivée des sciences informatiques a fait émerger des problèmes de reproductibilité des protocoles scientifiques (Janssen 2017). Le problème principal est relatif à l'accès au code utilisé par les chercheurs. Par exemple, il est possible de réaliser des analyses statistiques avec R sans partager le code utilisé, ce qui limite la transparence du processus scientifique. Dans cette situation, il est difficile de savoir si des erreurs de codage ont été commises, volontairement ou involontairement, affectant ainsi les résultats partagés.

Afin de remédier à ce problème, certains logiciels tel que GitHub⁸ participent à la transparence des résultats scientifiques (Fortunato and Galassi 2021). Ce logiciel permet aux chercheurs de partager leur code afin qu'il puisse être accessible pour tous. Il est important de mentionner ici que l'installation et la configuration de GitHub peut s'avérer difficile pour ceux et celles qui ne sont pas initiés à l'informatique. Cela constitue une certaine barrière dans l'utilisation de ce logiciel. Toutefois, nous souhaitons tout de même présenter l'utilité de ce logiciel puisqu'il permet de rendre les processus ainsi que les résultats de recherche plus transparent.

Par exemple, si l'on réalise une analyse statistique de la relation entre l'économie et le vote, nous pourrions partager l'ensemble du code que nous avons utilisé sur GitHub. D'une part cela permettrait aux utilisateurs de vérifier si les résultats sont honnêtes, et d'autre part de réutiliser le code pour mener leurs propres analyses.

⁸une plateforme publique *code ouvert* sur laquelle nous pouvons héberger et partager notre code.

2 Le monde du libre

Cependant, le partage du code utilisé reste encore majoritairement volontaire. Janssen, Pritchard, and Lee (2020) soutiennent que plus d'effort et d'actions concertés doivent être mise en place afin d'améliorer l'accessibilité aux codes. Toujours selon ces auteurs, les journaux scientifiques pourraient exiger que les auteurs rendent leur code publique lors du processus de publication. D'ailleurs, les résultats d'une expérience sur les facteurs qui influencent les chercheurs à partager leur code démontre que les initiatives individuelles ne seront pas suffisantes pour une augmentation du partage du code (Krähmer, Schächtele, and Schneck 2023). Par conséquent, rendre le code accessible devrait devenir un standard institutionnalisé.

2.3.2.3 Appropriation capitaliste

Dans ce cas-ci, il s'agit plutôt d'un défis auquel le logiciel libre est confronté plutôt qu'une critique quant aux limites de son utilisation. En fait, l'accès au code source ainsi que la liberté et la possibilité de contribuer au développement du logiciel constitue un avantage intéressant pour les compagnies privées. Par conséquent, nous avons assisté à une intégration partielle du logiciel libre dans la logique capitaliste (Broca 2013; Bessen 2002). Certaines d'entre elles utilisent les utilisateurs comme une main d'oeuvre gratuite afin de bonifier leur logiciel, ce qui permet, dans certains cas, de générer des revenus commerciaux dont l'entreprise est la seule bénéficiaire (Couture 2020). Attention, il ne faut pas penser que toutes les compagnies agissent de manière prédatrice. Le but ici est de souligner que certaines pratiques commerciales trouble l'essence du mouvement du logiciel libre, qui se veut davantage être un outil de collaboration accessible, plutôt qu'un moyen pour générer des profits. Il est important de garder en tête les valeurs et la philosophie qui a donné lieu à ce mouvement.

2.4 Critères de sélection

3 R ou ne pas R?

Plusieurs notions liées à l'ère numérique, notamment à ce qui a trait aux opportunités et difficultés que cette dernière peut amener, ont été présentées par l'entremise du chapitre précédent. C'est un monde de possibilité qui s'offre à ceux qui maîtrisent les nouveaux outils des temps modernes. Mais comment en arriver là ? Le présent chapitre a pour but de présenter certains outils flexibles et péreins permettant la réalisation de nombreuses tâches. Une des premières étapes permettant de notamment réaliser la collecte, l'analyse et la visualisation graphique de données ainsi que la rédaction de documents est l'apprentissage d'un langage de programmation. Bien que plusieurs langages de programmation existent, le présent ouvrage priorise le langage **R**. Les sections suivantes présentent ce langage de programmation, ces forces et ces faiblesses ainsi que les raisons de son utilisation. Enfin, la dernière section présente un environnement de programmation qui se prête bien à son utilisation.

3.1 Pourquoi R?

Comme mentionné précédemment, il existe plusieurs langages de programmation. **R** a deux types de compétiteurs : les logiciels à licences comme SAS, STATA et SPSS, et les langages *OpenSource* tels que Python et Julia. **R** est un langage de programmation *OpenSource* développé par des statisticiens, pour des statisticiens, dans les années 1990 (Tippmann 2015). **R** prend ses racines dans le langage de programmation S, créé notamment par Ross Ihaka et Robert Gentleman. Ces derniers ont fait des choix non

3 R ou ne pas R?

orthodoxes lors de l’élaboration du langage, qui font aujourd’hui la popularité de ce logiciel auprès d’un large pan de la communauté académique. En effet, Morandat et al. (2012) rapporte que le langage a été élaboré afin qu’il soit intuitif et qu’il permette aux nouveaux utilisateurs de rapidement réaliser des analyses.

Le langage de programmation **R** a plusieurs avantages qui font de lui un outil puissant et utile pour tout chercheur. L’un de ses grands avantages est qu’il est *OpenSource*. Ayant déjà abordé le sujet dans le chapitre précédent, il sera question ici de simplement rappeler les grandes lignes de l’argument, à savoir que : 1) l’*OpenSource* est gratuit d’utilisation; 2) l’*OpenSource* est développé de façon bottom-up, ce qui lui procure une grande flexibilité; et 3) il permet aux utilisateurs de créer leurs propres fonctions. À l’inverse, les logiciels à licences sont coûteux, rigides et l’ajout de fonctionnalités se fait par les développeurs internes à la compagnie. Ces formalités rendent le processus plus lent et réduisent l’éventail des possibilités pour la personne chercheuse. Ceci étant dit, certains avanceront que c’est justement ce processus interne lent qui assure la validité et la fiabilité des analyses effectuées par SAS, STATA ou SPSS. Or, dans son livre dédié aux utilisateurs de SPSS et de SAS, Muenchen (2011) soulève le point que bien souvent, ce sont des individus atomisés qui développent les nouvelles fonctionnalités de ces langages et que le processus de révisions se fait ensuite par des comités internes de testeurs. Il en va de même pour le développement des *packages R* dans la mesure où ce dernier se voit testé et amendé par plusieurs programmeurs indépendants dans un processus itératif des plateformes telles que GitHub. De plus, bien des nouvelles techniques statistiques sont développées pour R par des chercheurs qui publient leur travail dans des journaux académiques revus par des pairs, assurant la qualité du procédé. Le fait que SAS et SPSS permettent à leur utilisateur d’intégrer des routines R à leur programme est un indicateur fort ne serait-ce que de l’utilité de R (Muenchen 2011). Le langage de programmation **R** permet également de réaliser une grande quantité de tâches de recherche. En effet, les personnes programmant en **R** peuvent notamment manipuler et visualiser des données, faire différents types

3.2 Où coder en R ?

d'analyses, créer des fonctions et faire des boucles en plus de pouvoir combiner **R** avec certains langages de balisages.

D'un autre côté, l'utilisation du langage de programmation **R** peut être perçue comme ayant certains inconvénients. Plusieurs disent que la courbe d'apprentissage peut être plus grande que celle de programmes à licences. La véracité de cet argument est discutable. Les programmes demandant des licences ont également un coût d'entrée. De plus, les nouvelles itérations de ces logiciels amènent des changements demandant une période d'adaptation pour la personne chercheuse. D'autres disent que le développement *OpenSource*, spécifiquement celui du langage de programmation **R**, se fait de façon anarchique. Cela est davantage une question d'opinion et de conception du monde qu'une vérité. Le développement de *package* se fait effectivement de manière décentralisée et toute personne sachant programmer en **R** peut collaborer à cette communauté. Bien qu'il n'y ait pas d'autorité centrale, les *packages* sont regroupés sur le *Comprehensive R Archive Network* (CRAN) (voir le <https://cran.r-project.org/> pour plus d'information). Le site a une politique de dépôt stricte, ainsi les *packages* doivent être suffisamment documentés. Il est également possible d'y télécharger le langage de programmation **R**. Ce langage, ainsi que ces différents *packages*, sont disponible sur Windows, macOS et Linux.

3.2 Où coder en R ?

Un environnement de développement intégré (IDE) permet aux programmeurs de consolider les différents aspects de l'écriture d'un programme informatique. Ils permettent de réaliser toutes les activités courantes d'un programmeur – l'édition du code, la construction des exécutables et le débogage – au même endroit. Les environnements de développement intégrés sont conçus pour maximiser la productivité du programmeur. Ils fournissent de nombreuses fonctionnalités – notamment la coloration syntaxique ainsi que le contrôle de version – pour créer, modifier et compiler du code. Certains environnements de développement intégré sont dédiés

3 R ou ne pas R?

à un langage de programmation spécifique. Par conséquent, ils contiennent des fonctionnalités qui sont plus compatibles avec les paradigmes de programmation du langage auquel ils sont associés. Enfin, il existe de nombreux environnements de développement intégré multilingues.

Comme mentionné précédemment, R est un des langages de statistiques et d'exploration de données les plus populaires en sciences sociales. R est pris en charge par de nombreux environnements de programmation. Plusieurs ont été spécialement conçus pour la programmation en R – le plus notable étant RStudio – tandis que d'autres sont des environnements de programmation universels – tels que Visual Studio Code – et prennent en charge R via des plugins. Il est également possible de coder en R à partir d'une interface en ligne de commande. Une telle méthode permet la communication entre l'utilisateur et son ordinateur. Cette communication s'effectue en mode texte : l'utilisateur tape une « ligne de commande » – c'est-à-dire du texte dans le *terminal* – pour demander à son ordinateur d'effectuer une opération précise, telle que rouler un fichier de code R.

La suite du chapitre présente RStudio, notamment à travers ses avantages et inconvénients, mais également des exemples de ses fonctionnalités.

3.3 Qu'est-ce que RStudio ?

RStudio est un projet open source destiné à combiner les différentes composantes du langage de programmation R en un seul outil (Allaire, 2011). RStudio fonctionne sur tous les systèmes d'exploitation, y compris Windows, Mac OS et Linux. En plus de l'application de bureau, RStudio peut être déployé en tant que serveur pour permettre l'accès Web aux sessions R s'exécutant sur des systèmes distants (Allaire, 2011). RStudio facilite l'utilisation du langage de programmation R en offrant de nombreux outils permettant à son utilisateur d'aisément réaliser ses tâches. Parmi les plus utiles, on retrouve notamment une fenêtre d'aide, de la documentation sur les différents packages R, un navigateur d'espace de travail, une visionneuse

3.3 Qu'est-ce que RStudio ?

de données et une prise en charge de la coloration syntaxique (Horton, Kleinman, 2015). De plus, RStudio permet de coder dans plusieurs langages et de supporter une grande quantité de formats. Il fournit également un support pour plusieurs projets ainsi qu'une interface pour utiliser des systèmes de contrôle, tels que GitHub (Horton, Kleinman, 2015).

RStudio a plusieurs avantages. Son utilisation est facile à apprendre pour les débutants. Les principaux éléments d'un IDE sont intégrés dans une disposition à quatre volets (Verzani, 2011). Cette disposition comprend une console, un éditeur de code source à onglets pour organiser les fichiers d'un projet, un espace pour l'environnement de travail et un quatrième volet où il est notamment possible d'afficher des graphiques ou de la documentation sur différents packages. Ce volet permet d'ailleurs d'accéder au répertoire des *packages* disponibles pour *R* en plus de permettre à l'utilisateur de consulter l'arborescence de ses fichiers. De plus, on y retrouve la possibilité de créer plusieurs espaces de travail – appelés projets – qui facilitent l'organisation de différents *workflows*.

Il y a plusieurs autres aspects de RStudio que les programmeurs apprécient. Parmi ceux-ci se trouve le fait qu'il peut être utilisé via un navigateur Web pour un accès à distance (Verzani, 2011). De plus, RStudio supporte plusieurs langages de programmation ainsi que différents langages de balisage. Qui plus est, de nouvelles fonctionnalités sont régulièrement ajoutées pour satisfaire les besoins de la communauté scientifique. Enfin, R logiciel est également souvent mis à jour.

Parmi ce que certains considèrent comme étant les points faibles de RStudio, on retrouve des éléments liés à la configuration. Certains utilisateurs trouvent que le nombre de raccourcis est limité. D'autres trouvent que le *set up* des différents panneaux n'est pas ergonomique, ou même qu'il n'est pas possible de pouvoir suffisamment personnaliser l'environnement de programmation. De plus, certains utilisateurs ont rapporté que RStudio était plus lent que d'autres alternatives pour quelques opérations, surtout celles comprenant de longs codes.

3.4 Comment utiliser RStudio ?

Bien que de nombreux éléments puissent être personnalisés, la disposition par défaut de RStudio est composée de quatre volets principaux (Verzani, 2011). Dans le coin supérieur gauche se trouve le cadran principal. C'est dans celui-ci que l'utilisateur passera la plus grande partie de son temps. On y modifie des fichiers de différents formats et il est possible d'y afficher des bases de données. Dans le coin inférieur gauche se trouve la console ainsi que le terminal. Dans cette première, on peut interagir avec R de la même manière que dans le cadran principal, mais le code ne sera pas enregistré. Le terminal, pour sa part, est le point d'accès de communication entre un usager et son ordinateur. Bien que les différents systèmes d'exploitation viennent avec un terminal déjà intégré, il est aussi possible d'y accéder à partir de RStudio.

On retrouve, dans le coin supérieur droit, l'espace de travail. Ce cadran contient trois éléments : l'*environnement global*, l'*historique* et les *connections*. L'*environnement global* est l'endroit où l'utilisateur peut voir les bases de données, les fonctions et les différents autres objets R qui sont actifs. Il peut cliquer sur les divers éléments actifs pour les consulter. L'onglet *historique* permet à l'utilisateur de consulter les derniers morceaux de code R qu'il a roulé ainsi que les dernières commandes écrites dans la console. L'onglet *connections*, pour sa part, permet de connecter son IDE à une variété de sources de données et d'explorer les objets et les données qui la composent. Il est conçu pour fonctionner avec une variété d'autres outils pour travailler avec des bases de données en R dans RStudio.

Le cadran dans le coin inférieur droit, pour sa part, contient plusieurs outils très utiles pour les usagers de RStudio. L'onglet *Files* permet à l'utilisateur de naviguer dans les fichiers que contient son ordinateur sans avoir à sortir de RStudio. L'onglet *Plots* permet de visualiser les graphiques générer à partir de R, que ce soit en utilisant *ggplot2*, *lattice* ou *base R*. L'onglet *Packages* permet de consulter les packages installés précédemment par l'utilisateur en plus de pouvoir en consulter la documentation. C'est

3.5 Conclusion

aussi un des différents endroits à partir d'où il est possible d'installer des packages avec RStudio. L'onglet *Help* permet à l'utilisateur de chercher et de consulter de la documentation sur de nombreux sujets, notamment sur les différentes fonctions en R ainsi que sur les packages. Pour sa part, l'onglet *Viewer* permet la visualisation de contenu web local.

Enfin, l'utilisateur peut modifier les dimensions par défaut pour chacun des quatre cadrants principaux. En cliquant sur la division des sections, il est possible d'ajuster l'allocation horizontale de l'espace. De plus, chaque côté dispose d'un autre séparateur pour ajuster l'espace vertical. Qui plus est, la barre de titre de chaque cadran comporte des icônes pour omburer un composant, maximiser un cadran verticalement ou modifier la taille des l'espace de travail (Verzani, 2011; Nierhoff et Hillebrand, 2015).

3.5 Conclusion

Le langage de programmation R est un outil très utile pour toutes sortes de tâches notamment reliées aux statistiques et à la visualisation graphiques. Sa maîtrise est requise pour accéder à plusieurs emplois, autant dans le monde académique que dans les secteurs publics et privés. Avec un peu de chance, le présent chapitre vous a éclairé sur son utilité et sa pertinence dans le monde du travail contemporain. Bien que le langage de programmation R ne doivent pas obligatoirement être utilisé avec RStudio, nous pensons que pour la plupart des usagers, leur utilisation conjointe est bénéfique et souhaitée. RStudio permet également d'utiliser différents langages de balisage compatibles avec R, facilitant l'utilisation de plusieurs outils complémentaires. L'apprentissage du langage de programmation R apparaît également être une valeur sûre. Sa longévité dans plusieurs sphères ainsi que la forte croissance de sa base d'usagers laisse présager que d'en connaître au moins les bases est un énorme avantage pour tout le monde. Pour ceux qui sont particulièrement intéressés par le langage de programmation R et qui désirent s'impliquer dans sa communauté, il existe plusieurs conférences internationales et nationales sur R – notamment

3 R ou ne pas R?

RConference and *useR!* – et un journal académique, *The R Journal*. On retrouve également différentes communautés telle que *R-Ladies* qui met de l'avant la diversité des genres dans la communauté du langage de programmation R. Le langage de programmation R est plus qu'un simple outil statistique, il est le centre d'une grande communauté de gens qui ont à cœur des principes liés à l'inclusion et à l'avancement humain.

4 À la quête de l'optimisation

Le monde de la recherche en sciences sociales numériques est en constante évolution, offrant de nouvelles opportunités mais aussi des défis uniques. Dans cette quête incessante pour optimiser notre efficacité et notre collaboration, l'utilisation des bons outils devient la clé de la réussite. Que vous soyez un chercheur en herbe ou un professionnel chevronné, la manière dont vous organisez vos méthodes de travail et gérez vos ressources peut déterminer la qualité et l'impact de vos résultats.

4.1 L'importance d'une méthode de travail efficace

Avant même de plonger dans les détails des méthodes de recherche et des analyses, il est crucial de poser les bases d'une méthode de travail efficace. Qu'il s'agisse de travailler en solitaire ou en équipe, l'ordre et la structure sont des éléments essentiels. Des dossiers bien organisés, une arborescence claire et un entreposage sécurisé deviennent les piliers sur lesquels repose votre productivité. Après tout, un environnement de travail organisé engendre des résultats ordonnés.

Ce chapitre vous emmènera à découvrir une gamme d'outils conçus pour répondre aux besoins spécifiques des chercheurs en sciences sociales numériques. Dans une quête pour maximiser votre temps, améliorer vos flux de travail et renforcer vos collaborations, nous explorerons trois types d'outils qui vous guideront dans cette quête d'optimisation :

4 À la quête de l'optimisation

1. **Logiciels de communication** : La communication transparente est le cœur d'une collaboration réussie. Nous explorerons des outils tels que Slack qui facilitent les échanges en temps réel, connectant les chercheurs, même à distance, pour un partage rapide d'idées et d'informations.
2. **Logiciels de gestion de versions décentralisé** : Nous plongerons dans le monde de Git et GitHub, des outils indispensables pour le suivi des versions et la collaboration efficace sur le code source.
3. **Outils d'entreposage de données** : Que vous traitiez des données sensibles ou non, la conservation sécurisée de vos informations est primordiale. Des plateformes telles que Dropbox et Amazon Web Services (AWS) offrent des espaces sécurisés pour entreposer et partager vos données avec votre équipe.

Chacun de ces outils est une pièce du puzzle, conçue pour vous aider à gagner du temps, à collaborer de manière plus fluide et à renforcer la qualité de votre recherche en sciences sociales numériques. Plongeons dans ces outils avec un désir commun d'optimisation et d'excellence dans notre travail.

4.2 Logiciel de gestion de communication (Slack)

Dans tout bon projet de recherche, la communication est primordiale. Que ce soit pour décrire les avancements, discuter des étapes à venir, entretenir un partenariat avec des partenaires ou simplement structurer ses pensées, la plateforme par laquelle vous communiquez vous accompagne à chacune des étapes du travail. Il est donc important de choisir un outil qui convient bien à vos projets et de prendre le temps de l'apprivoiser et d'optimiser son utilisation.

Il y a tellement de plateformes différentes pour communiquer qu'il faut être prudent par rapport au nombre utilisé. Si vous ne faites pas un choix,

4.2 Logiciel de gestion de communication (Slack)

vous pouvez, sans vous en rendre compte, mêler Teams, courriels, Zoom et autres. Rapidement, vous perdez le contrôle de ce qui est dit. Nous vous proposons d'opter pour un logiciel de gestion de communication. Il existe plusieurs logiciels du genre, tels que Microsoft Teams, Slack, Google Workspace et Workplace. Toutes ces options peuvent vous permettre de collaborer efficacement en équipe. Dans le cadre de nos travaux, nous utilisons Slack. C'est donc principalement de cet outil que nous parlerons dans cette section, mais n'hésitez pas à vérifier quelle plateforme correspond le mieux à vos besoins.

4.2.1 Pourquoi utiliser une de ces plateformes

Peu importe votre niveau d'implication, la collaboration et la communication sont inévitables en recherche. La science n'est pas une discipline qui se développe en solitaire, elle nécessite des échanges et des débats. Les équipes de recherche sont souvent dispersées géographiquement. Même si vous travaillez actuellement seulement avec votre directeur, il est certain que plusieurs équipes de recherche dans votre département utilisent un tel logiciel. Un courriel peut faire l'affaire pour une discussion ponctuelle qui se règle rapidement. Cependant, dans une équipe de travail dynamique, où plusieurs membres participent à divers projets, les courriels deviennent rapidement chaotiques, il est difficile de retracer ce qui a été dit et de conserver les pièces jointes. Les discussions deviennent rapidement trop complexes pour le médium utilisé.

Les logiciels de gestion de communication ont été conçus spécifiquement pour répondre aux besoins des équipes collaboratives. Vous y trouverez leur facette la plus attrayante : une structure simple et adaptée. Les chaînes et fils de discussions permettent de garder des traces et de se retrouver facilement dans ce qui a été dit. Une autre force de ces logiciels est la centralisation des outils de travail. Sur Slack, comme sur Teams, vous pouvez faire des appels en visioconférence à l'endroit où vos conversations écrites se trouvent. Il est aussi possible d'y télécharger l'application mobile,

4 À la quête de l'optimisation

ce qui facilite l'accessibilité et la connexion des membres de l'équipe. Tout avoir structuré à son goût au même endroit et à portée de main, cela permet de structurer sa pensée plus efficacement, d'éviter les oubli et de réduire le stress.

4.2.2 Comment utiliser votre logiciel efficacement

Une fois que vous êtes convaincu d'aller de l'avant avec un de ces outils, vous devrez apprendre à bien vous en servir. Voici quelques trucs qui pourront vous aider à optimiser son utilisation. Les points ci-dessous font référence à Slack, mais peuvent très bien être adaptés à d'autres plateformes.

4.2.2.1 Structuration

Il est important de bien réfléchir à la structuration de vos chaînes. Si vous ne faites pas ce travail, les chaînes peuvent se multiplier rapidement et les conversations se mettent alors à s'entrecroiser, vous faisant ainsi perdre le fil. L'objectif de ces outils étant d'évitez ces problèmes, vous ne voulez pas perdre l'avantage comparatif que vous venez tout juste de gagner face aux courriels! La structuration des chaînes devrait être similaire à celle de votre équipe de recherche. Si vous utilisez Notion ou un autre logiciel du genre, la structure des deux outils devrait être la même. Nous vous proposons d'avoir une chaîne pour chacun des projets. Si le projet est trop gros et que la conversation devient chaotique, pensez à créer une sous-chaîne (un sous-projet) qui vous permettra d'aborder un sujet précis, sans mêler les discussions. Pour faciliter la structuration des chaînes, vous pouvez utiliser des préfixes, pour classer les chaînes par thème, ou autre typologie qui vous convient. Également, utilisez les Espaces d'équipe. Chaque équipe devrait avoir son propre espace, avec ses propres chaînes. Vous pouvez faire partie de plusieurs équipes et naviguer à travers les espaces. Si plusieurs équipes partagent un même espace de travail, vous pourriez perdre le contrôle de sa structure.

4.2 Logiciel de gestion de communication (Slack)

4.2.2.2 Maintenance

Slack est un espace dynamique, tout comme votre équipe! La structure que vous avez choisie n'est pas permanente. Vous devriez rapidement vous questionner à savoir si elle convient toujours à vos activités. Votre espace d'équipe est comme votre réel lieu de travail, faites-y régulièrement le ménage pour vous assurer que tout est propre et en ordre. Archivez les chaînes qui ne sont plus pertinentes ou actives, puisque vous pourrez toujours les désarchiver quand cela sera nécessaire. Épinglez des messages importants et des documents utiles aux projets dans les chaînes appropriées. Faites le tour de ce qui est épingle à l'occasion pour vérifier si c'est encore pertinent. Cela peut paraître énergivore, mais l'efficacité de votre travail d'équipe va en bénéficier. Également, rappelez aux membres de votre équipe d'utiliser les bonnes chaînes pour chacune des discussions. Il ne faut pas que les conversations se croisent à travers les chaînes. Chaque chaîne a son utilité et doit être utilisée en conséquence. Les appels d'équipe doivent aussi se faire dans les bonnes chaînes. Quand vous êtes en appel, utilisez le fil de discussion pour conserver des traces écrites des points abordés dans la réunion. Les fils de discussions sont en général un bon outil pour ne pas se perdre dans une discussion. Si l'usage des mauvaises chaînes est un problème récurrent, il est possible que la structure que vous employez est mal adaptée à vos travaux. Vous pouvez alors retourner à la planche à dessin. Assurez-vous que toute l'équipe comprenne bien comment utiliser Slack. Si ce n'est pas le cas, formez-les. Une structure adaptée et une équipe bien formée peuvent faire des miracles.

4.2.2.3 Collaboration

La grande majorité des conversations devraient se faire dans les chaînes. Les conversations privées ont leur utilité, vous vous en servirez. Il est parfois nécessaire d'avoir des discussions plus confidentielles et de parler rapidement à quelqu'un sur un sujet éphémère. Toutefois, par soucis de transparence et d'inclusion, toute discussion à propos d'un projet devrait

4 À la quête de l'optimisation

se faire dans sa chaîne. Si vous jugez qu'un membre d'une chaîne ne devrait pas lire ce que vous avez à dire sur le projet, c'est qu'il ne devrait pas faire partie de la chaîne. Par rapport aux membres, trouvez le bon équilibre par rapport à qui devrait être dans quelle chaîne. L'objectif n'est pas d'exclure et de cacher du contenu, vous voulez une équipe transparente. Vous voulez que vos membres restent bien informés de l'avancement des projets sans les submerger d'information qui ne leur est pas utile. C'est à vous de trouver la formule gagnante. Invitez vos partenaires externes dans votre espace d'équipe. Créez des chaînes spécifiques aux partenaires pour que les conversations externes soient tout aussi organisées. N'invitez pas vos partenaires dans vos chaînes privées, question de confidentialité. Si un partenaire n'a pas l'habitude d'utiliser Slack ou l'outil que vous utilisez, proposez-lui de vous y joindre quand même. Moins vous utilisez les outils des autres, plus vous gardez centralisées vos communications et évitez de jongler avec plusieurs plateformes.

4.2.2.4 Optimisation personnelle

Une fois que la structure d'équipe est définie et que vos membres et vos partenaires sont à l'aise avec l'utilisation de la plateforme, il est temps d'organiser la structure de votre Slack personnel. Créez des sections pour trier les chaînes. La structure d'équipe est essentielle, mais une fois qu'elle est déterminée, chaque membre n'utilise pas forcément les chaînes de la même façon. Vous pouvez vous créer une section de favoris, ou encore différentes sections par rapport aux différents thèmes pour y faciliter la navigation. Également, ajustez vos paramètres de notifications. C'est à vous de déterminer quelle chaînes méritent de produire des alertes, et à quels moments vous souhaitez les recevoir. Slack a plusieurs applications intégrées qui facilitent la compatibilité avec vos autres outils. Vous pouvez connecter votre calendrier, votre Notion et votre GitHub pour recevoir des alertes pertinentes. Allez explorer ces applications pour déterminer lesquelles vous conviennent.

4.2 Logiciel de gestion de communication (Slack)

Tel que mentionné précédemment, plusieurs logiciels peuvent convenir à vos besoins. Puisque nous utilisons Slack, voici quelques raisons qui pourraient vous convaincre d'opter pour cette option ou de vous en éloigner. Sachez que cette liste n'est pas du tout exhaustive, mais reflète simplement quelques-unes de nos observations par rapport à notre outil de travail.

- Avantages

L'utilisation de Slack est très intuitive. Nous l'utilisons régulièrement dans des cours, et les étudiants apprennent rapidement à l'utiliser. La distinction entre les chaînes publiques accessibles à tous les membres d'un espace d'équipe et les chaînes privées est claire et simple d'utilisation. Slack offre aussi une fonction de recherche, qui vous permet de retrouver des messages à travers les chaînes. L'intégration de applications qui font le pont avec d'autres outils est fort appréciée. Enfin, Slack est utilisé partout dans le monde par des équipes de toutes les tailles et dans tous les domaines. C'est un outil très présent en recherche académique qui facilite la collaboration et la multidisciplinarité. Les chances sont élevées que vos partenaires utilisent déjà l'outil, ou au minimum en aient déjà entendu parler.

- Inconvénients

Si vous avez l'habitude d'utiliser les outils d'une suite, comme celles de Microsoft ou de Google, il est possible que vous trouviez l'intégration de ces outils à Slack moins pratique que si vous utilisiez les plateformes proposées par ces compagnies. Également, gardez en tête que la version gratuite de Slack a plusieurs limitations. Elle implique notamment un limite de temps par rapport à l'archivage des messages, que vous ne pourrez pas retracer après 90 jours. Les coûts pour utiliser Slack à son plein potentiel peuvent être élevés, mais puisque ce genre d'outils est de plus en plus répandu, il est fort possible que son utilisation soit financée par votre département.

4.3 Logiciel de gestion de versions décentralisé

Lorsque l'on aborde le domaine de la recherche scientifique en sciences sociales numériques, la collaboration et la gestion efficace du code deviennent des éléments cruciaux pour progresser dans ses projets. Dans cette optique, les outils de gestion de versions décentralisés ont pris une place prépondérante. Parmi eux, Git et GitHub se démarquent tant par leur popularité que par leur efficacité.

4.3.1 Pourquoi choisir Git et GitHub?

4.3.1.1 Avantages

Git, développé par Linus Torvalds en 2005, s'est imposé comme le système de gestion de versions décentralisé de référence. Sa principale force réside dans sa capacité à suivre l'évolution d'un projet en enregistrant les modifications apportées au code source. Chaque modification est enregistrée sous forme de dépôts (*commits*), avec un message explicatif, permettant aux collaborateurs de comprendre facilement les évolutions du projet.

GitHub, lancé en 2008, est une plateforme qui utilise Git comme base pour l'entreposage et la gestion de projets. C'est une vitrine virtuelle où les développeurs peuvent héberger leurs dépôts Git et collaborer de manière transparente. L'aspect social de GitHub, avec ses fonctionnalités de suivi des projets, de gestion des problèmes et de demandes de fusion, en fait un lieu de choix pour les projets en code source ouvert et collaboratifs.

En sciences sociales numériques, où le partage et la collaboration sont essentiels, Git et GitHub offrent plusieurs avantages majeurs. Tout d'abord, ils permettent de suivre les modifications apportées au code, ce qui facilite la reproductibilité des résultats. Les chercheurs peuvent revenir à n'importe quelle version précédente du code, ce qui est particulièrement utile pour corriger des erreurs ou analyser l'impact de différentes approches.

4.3 Logiciel de gestion de versions décentralisé

De plus, Git et GitHub favorisent le travail collaboratif. Plusieurs chercheurs peuvent travailler sur le même projet simultanément, chacun dans sa branche de développement. Une fois les modifications effectuées, il est possible de fusionner les branches pour intégrer les changements. Cette approche évite les conflits majeurs et facilite la répartition des tâches au sein de l'équipe.

Enfin, l'aspect de code source ouvert de GitHub permet aux chercheurs en sciences sociales numériques de partager leurs codes avec la communauté académique et de bénéficier des contributions d'autres chercheurs. Cela favorise un environnement de partage des connaissances et de collaboration fructueuse.

4.3.1.2 Inconvénients

Cependant, Git et GitHub ne sont pas sans leurs défis. La courbe d'apprentissage peut être raide pour les débutants, car ces outils impliquent des concepts spécifiques tels que les branches, les conflits de fusion et les requêtes de tirage. De plus, bien que GitHub offre un niveau de gratuité pour les projets en code source ouvert, des frais peuvent être appliqués pour des fonctionnalités avancées ou pour des projets privés.

4.3.2 Comment les utiliser efficacement (en parallèle à Dropbox, etc.)

Pour utiliser Git et GitHub efficacement dans un contexte de recherche en sciences sociales numériques, il est recommandé de suivre quelques bonnes pratiques. Tout d'abord, il est important de structurer son dépôt Git de manière logique, en organisant les fichiers et les dossiers de manière cohérente. Les messages de commit doivent être descriptifs et clairs, pour permettre à tous les collaborateurs de comprendre les changements effectués.

4 À la quête de l'optimisation

Il est également conseillé de travailler sur des branches distinctes pour chaque fonctionnalité ou modification majeure. Cela facilite la gestion des changements et minimise les conflits lors de la fusion. Les chercheurs devraient également consulter régulièrement les projets et les problèmes sur GitHub pour encourager une communication ouverte et résoudre rapidement les problèmes.

L'utilisation de Git et de GitHub peut être complémentaire à d'autres outils d'entreposage, tels que Dropbox ou Google Drive. Ces derniers peuvent être utilisés pour entreposer des fichiers non liés au code, tels que des données brutes non sensibles ou des documents de recherche, tandis que Git et GitHub gèrent le code source et ses évolutions.

Bien qu'il existe plusieurs alternatives à l'utilisation combinée de Git et de GitHub sur le marché, ces deux plateformes liées continuent de dominer le domaine de la gestion de versions décentralisée. Parmi les alternatives notables, on peut citer Mercurial, Bitbucket, GitLab et SourceForge. Chacun de ces outils offre des fonctionnalités similaires à celles de Git et GitHub, mais il est important de comprendre pourquoi Git et GitHub restent les choix privilégiés pour les chercheurs en sciences sociales numériques.

4.3.3 Pourquoi prioriser Git et GitHub pour les chercheurs en sciences sociales

1. *Intégration et adoption répandue* : Git est devenu un standard de facto dans l'industrie du développement logiciel. Sa popularité et son adoption répandue signifient que de nombreuses ressources d'apprentissage, des tutoriels et des forums de support sont disponibles en ligne, ce qui facilite l'utilisation de cet outil pour les chercheurs en sciences sociales débutants. GitHub, en tant que plateforme principale de gestion des versions, bénéficie également d'une grande base d'utilisateurs et d'une communauté active, ce qui encourage la collaboration et le partage des connaissances.

4.3 Logiciel de gestion de versions décentralisé

2. *Facilité de collaboration* : Git et GitHub sont conçus pour faciliter la collaboration entre les individus et les équipes. Les chercheurs en sciences sociales travaillent souvent ensemble sur des projets de recherche, et la capacité de suivre les modifications, de gérer les conflits et de fusionner les contributions devient essentielle. L'interface conviviale de GitHub, avec des fonctionnalités telles que les demandes de fusion et les commentaires en ligne, simplifie grandement la collaboration.
3. *Visibilité et partage* : GitHub brille par sa fonctionnalité de projet open source, qui permet aux chercheurs en sciences sociales de partager leurs travaux avec la communauté mondiale. Les projets en code source ouvert sont visibles et accessibles à tous, favorisant ainsi la collaboration et l'examen par les pairs. Cela peut être particulièrement bénéfique pour les chercheurs souhaitant contribuer à des initiatives académiques et collaborer à des projets interdisciplinaires.
4. *Suivi des versions et recherche reproductible* : Les chercheurs en sciences sociales doivent s'assurer que leurs travaux sont reproductibles et vérifiables. Git permet de suivre les versions du code, ce qui signifie que les chercheurs peuvent retrouver facilement des versions antérieures pour reproduire des analyses spécifiques ou corriger des erreurs. Cette fonctionnalité est cruciale pour maintenir l'intégrité des résultats de recherche.
5. *Infrastructure et sécurité* : GitHub offre une infrastructure robuste pour l'entreposage sécurisé des dépôts Git. Les chercheurs peuvent être assurés que leurs travaux sont sauvegardés et protégés contre les pertes de données accidentelles. De plus, les contrôles d'accès et les autorisations granulaires de GitHub permettent aux chercheurs de contrôler qui peut accéder et contribuer à leurs projets.

En somme, Git et GitHub offrent aux chercheurs en sciences sociales numériques un moyen puissant de gérer leur code, de collaborer efficacement et de contribuer à la communauté académique grâce à l'open source. Bien

4 À la quête de l'optimisation

que leur apprentissage puisse représenter un défi initial, les avantages qu'ils apportent en termes de suivi des versions, de collaboration et de partage des connaissances en font des outils essentiels dans l'arsenal de tout chercheur moderne.

4.3.4 Pratiques à éviter sur GitHub pour les chercheurs en sciences sociales

Lorsque les chercheurs en sciences sociales utilisent GitHub pour partager leur code, collaborer sur des projets et contribuer à la communauté académique, il est essentiel de connaître les pratiques à éviter. En effet, certaines erreurs peuvent compromettre la sécurité, la confidentialité et l'efficacité de la recherche. Voici quelques éléments à éviter :

1. *Entreposer des informations sensibles* : Évitez d'entreposer des données sensibles ou confidentielles sur GitHub. Cela inclut les données de sondages, les informations personnelles identifiables et tout autre contenu pouvant porter atteinte à la vie privée des individus. Assurez-vous de supprimer ou de masquer soigneusement ces informations avant de les télécharger sur la plateforme.
2. *Inclure des mots de passe et clés d'accès* : Ne jamais inclure de mots de passe, de clés d'accès ou d'informations d'identification dans votre code source. Cela peut compromettre la sécurité de vos systèmes et de vos données. Utilisez plutôt des méthodes sécurisées pour gérer ces informations, telles que les variables d'environnement ou les fichiers de configuration externes.
3. *Entreposer des fichiers lourds* : Évitez d'entreposer des fichiers volumineux sur GitHub, notamment des fichiers binaires, des données brutes massives ou des ensembles de données volumineux. Ces fichiers peuvent ralentir les opérations de clonage et de fusion, ce qui affecte la performance globale du dépôt. Utilisez plutôt des services

4.3 Logiciel de gestion de versions décentralisé

d’entreposage dédiés pour ces fichiers et fournissez des liens vers ces ressources dans votre dépôt.

4. *Inclure des identifiants personnels* : Évitez de publier vos propres identifiants personnels, tels que des numéros de sécurité sociale, des numéros de carte de crédit ou d’autres informations confidentielles. Ces informations pourraient être exploitées à des fins malveillantes si elles tombent entre de mauvaises mains.
5. *Ignorer les pratiques de branches et de fusion* : Évitez de fusionner directement du code dans la branche principale (habituellement appelée *main* ou *master*). Utilisez plutôt des branches distinctes pour les fonctionnalités et les corrections, et suivez les pratiques de fusion pour intégrer proprement les changements. Ignorer ces pratiques peut entraîner des conflits et une perte de trace des modifications.
6. *Ignorer les commentaires des collaborateurs* : Lorsque vous travaillez avec d’autres chercheurs, ne négligez pas les commentaires et les suggestions qu’ils fournissent. Les retours d’expérience et les idées des autres peuvent contribuer à améliorer la qualité de votre code et de vos analyses.
7. *Ne pas documenter* : Évitez de ne pas documenter votre code. Une documentation claire et détaillée est essentielle pour permettre à d’autres chercheurs de comprendre vos méthodes et vos résultats. Utilisez des commentaires explicatifs et fournissez des explications sur la manière d’exécuter votre code.

En suivant ces conseils et en évitant ces erreurs courantes, les chercheurs en sciences sociales peuvent garantir la sécurité, la qualité et l’efficacité de leurs projets sur GitHub. La responsabilité de préserver la confidentialité des données et de créer un environnement de travail collaboratif et respectueux repose sur les épaules de chaque contributeur.

4.3.5 Exemple d'utilisation de Git et de GitHub pour un chercheur en sciences sociales

Dans le contexte de la recherche en sciences sociales numériques, la gestion efficace du code, la collaboration transparente et la préservation des données sensibles sont des impératifs. Imaginons que vous êtes un jeune chercheur en sciences sociales qui étudie l'impact des médias sur l'opinion publique. Vous utilisez le langage de programmation R pour analyser des données de médias et des données de sondage. Bien que vous travailliez seul, vous souhaitez rendre votre travail accessible à votre équipe pour validation et permettre à vos collègues de contribuer aux améliorations. Voici comment vous pouvez utiliser Git et GitHub pour gérer votre projet de manière structurée et collaborative.

4.3.5.1 Étape 1 : Création d'un répertoire local et initialisation de Git

Ouvrez votre terminal et naviguez vers le dossier où vous souhaitez enregistrer votre projet.

```
cd chemin/vers/votre/dossier
```

Créez un nouveau répertoire pour votre projet et accédez-y.

```
mkdir mon_projet
```

```
cd mon_projet
```

Initialisez Git dans ce répertoire.

```
git init
```

4.3 Logiciel de gestion de versions décentralisé

4.3.5.2 Étape 2 : Ajout de votre code et de vos fichiers

Ajoutez vos fichiers R contenant le code pour l'analyse des médias et des sondages dans le répertoire. Par exemple, vous pouvez avoir des fichiers *analyse_medias.R* et *analyse_sondages.R*.

Utilisez la commande `git status` pour vérifier l'état de vos fichiers.

```
git status
```

4.3.5.3 Étape 3 : Ajout, validation et commit de vos modifications

Ajoutez vos fichiers pour qu'ils soient prêts à être validés.

```
git add -A
```

Validez vos modifications avec un message descriptif.

```
git commit -m "Ajout du code d'analyse des médias et des sondages"
```

4.3.5.4 Étape 4 : Création du répertoire sur GitHub et du lien avec votre répertoire local

Allez sur GitHub et connectez-vous à votre compte. Créez un nouveau répertoire vide avec le nom *mon_projet*.

De retour dans votre terminal, ajoutez le lien GitHub à votre répertoire local.

```
git remote add origin https://github.com/votre-utilisateur/mon_projet.git
```

4.3.5.5 Étape 5 : Push de votre travail sur GitHub

Envoyez vos commits locaux vers GitHub.

```
git push -u origin master
```

4.3.5.6 Étape 6 : Collaboration avec vos collègues

Si vos collègues souhaitent contribuer à votre projet, ils peuvent *forker* votre répertoire sur GitHub, ce qui créera une copie dans leur propre compte.

Lorsqu'ils ont fait des modifications dans leur copie, ils peuvent soumettre une *pull request* pour vous demander de fusionner leurs modifications dans votre répertoire principal.

4.3.5.7 Étape 7 : Pull des modifications de vos collègues

Lorsque vos collègues ont soumis des modifications et vous ont demandé de les fusionner, vous pouvez mettre à jour votre répertoire local avec leurs changements.

```
git pull origin master
```

4.3.5.8 Étape 8 : Répéter le processus

Répétez les étapes 2 à 7 au fur et à mesure que vous développez votre projet, ajoutez du code, effectuez des analyses et collaborez avec vos collègues. Assurez-vous de valider et de pousser régulièrement vos modifications pour maintenir le dépôt à jour.

4.3 Logiciel de gestion de versions décentralisé

4.3.6 GitHub Desktop

Alors que le terminal reste une approche fondamentale pour maîtriser Git et GitHub, il existe des outils conviviaux tels que GitHub Desktop qui offrent une alternative intuitive. Cet outil simplifie le processus de gestion de versions décentralisée, en particulier pour ceux qui souhaitent commencer par une approche visuelle. Cependant, comprendre son fonctionnement et équilibrer les avantages et les inconvénients est essentiel.




Figure 4.1: image

GitHub Desktop fournit une vue claire de vos dépôts, de vos modifications, de vos branches et de vos demandes de fusion. Il élimine la nécessité de mémoriser les commandes en ligne de terminal, ce qui peut être un défi pour certains chercheurs. L'application simplifie également la résolution des conflits lors de la fusion des branches.

4 À la quête de l'optimisation

Toutefois, en utilisant GitHub Desktop, il est possible de perdre la compréhension des commandes Git en ligne de commande, ce qui pourrait devenir un inconvénient si vous devez travailler dans un environnement sans interface visuelle. De plus, GitHub Desktop est spécifiquement conçu pour interagir avec GitHub. Si vous devez travailler avec d'autres plateformes de gestion de versions, cela pourrait poser des problèmes.

La décision entre l'utilisation du terminal et de GitHub Desktop dépend de vos préférences et de vos besoins. Pour les chercheurs qui débutent, GitHub Desktop offre une transition en douceur vers les concepts de gestion de versions. Cependant, il est important de ne pas se limiter à une interface visuelle. Comprendre les commandes Git en ligne de commande reste essentiel pour résoudre des problèmes complexes, gérer des projets avancés et collaborer avec d'autres chercheurs qui utilisent des approches basées sur le terminal.

4.4 Conclusion

En utilisant Git et GitHub de manière stratégique, vous pouvez gérer efficacement votre projet de recherche en sciences sociales, collaborer avec vos collègues et rendre votre travail accessible tout en préservant la confidentialité des données sensibles. Ce processus contribue à un environnement de recherche collaboratif et structuré, essentiel pour mener à bien vos analyses sur l'impact des médias sur l'opinion publique.

4.5 Outils d'entreposage des données

L'entreposage des données occupe une place cruciale dans la recherche en sciences sociales numériques. La manière dont vous entreposez et gérez vos données peut avoir un impact significatif sur la sécurité, la confidentialité et la reproductibilité de votre travail. Dans cette section, nous allons aborder

4.5 Outils d'entreposage des données

différents aspects de l'entreposage de données, des outils disponibles et de l'importance d'une gestion efficace de vos fichiers.

4.5.1 Entreposage de données non sensibles

Au fil du temps, de nombreux outils d'entreposage ont émergé pour répondre aux besoins variés des chercheurs en sciences sociales. Des solutions populaires incluent Dropbox, Google Drive, OneDrive et Amazon S3 d'AWS. L'histoire de ces outils témoigne de l'évolution des besoins d'entreposage et de collaboration.

Lorsqu'il s'agit d'entreposer vos données de recherche, la règle d'or est de ne jamais perdre d'informations précieuses. Cette préoccupation prend toute son importance lorsqu'un chercheur en sciences sociales, seul ou en équipe restreinte, se lance dans un projet. Pour répondre à ce besoin, les services d'entreposage cloud tels que Dropbox, Google Drive et OneDrive se révèlent indispensables. Voici quelques avantages d'un entreposage sur le cloud pour la recherche :

1. *Sauvegarde automatique* : Les solutions cloud sauvegardent automatiquement vos fichiers, garantissant que vous ne perdrez jamais vos données en cas de panne d'ordinateur ou d'accident.
2. *Accessibilité universelle* : Vous pouvez accéder à vos fichiers à partir de n'importe quel appareil avec une connexion Internet, ce qui favorise la flexibilité dans la gestion de vos projets.
3. *Partage facilité* : Les services cloud permettent de partager facilement des fichiers et des dossiers avec des collègues, même en dehors de votre équipe de recherche. Cela favorise la collaboration et la communication.

Il est important de noter que le choix d'un service cloud dépend de vos besoins et de vos préférences. Considérez des facteurs tels que la ca-

4 À la quête de l'optimisation

pacité d'entreposage, les fonctionnalités de partage, la convivialité et la compatibilité avec vos outils de recherche existants.

Dropbox est connu pour sa simplicité d'utilisation et sa convivialité. Il peut être un choix approprié pour entreposer des fichiers non sensibles, partager des documents avec des collègues et faciliter la collaboration.

Pour utiliser Dropbox efficacement, organisez vos fichiers en arborescence logique. Créez des dossiers spécifiques pour chaque projet et partagez-les avec les membres de votre équipe. Pour éviter de pousser des fichiers sensibles sur GitHub, ajoutez le nom de dossier à exclure dans un fichier `.gitignore`.




Figure 4.2: image1

Dropbox offre un suivi automatique des modifications, ce qui vous permet de remonter dans le temps pour restaurer des versions antérieures de vos fichiers. Cela garantit l'intégrité de vos données et vous permet de revenir à des versions précédentes si nécessaire. De plus, l'archivage de dossiers et de projets complets peut aider à conserver une vue chronologique de votre travail au fil du temps.

4.5 Outils d'entreposage des données

Il est également crucial de considérer la taille de vos données. Si vous traitez des fichiers volumineux tels que des images, des vidéos ou des ensembles de données massifs, il peut être judicieux d'utiliser un service cloud pour entreposer ces fichiers et les partager avec vos collaborateurs, plutôt que de les pousser sur des plateformes de gestion de versions comme GitHub.

Pour les données sensibles, les services cloud tels que Dropbox et Google Drive peuvent ne pas être suffisamment sécurisés. C'est là que des solutions comme AWS entrent en jeu. Cependant, il est important de noter que l'utilisation d'AWS peut s'avérer complexe, en particulier pour un jeune chercheur travaillant en solo ou en petite équipe.

4.5.2 Entreposage de données sensibles

Lorsqu'il s'agit d'entreposer des données sensibles, tels que des données de sondage comportant des informations personnelles identifiables, la sécurité et la confidentialité sont essentielles. Comme abordé précédemment, GitHub n'est pas adapté à l'entreposage de telles données en raison de ses caractéristiques publiques et de son orientation vers le code source ouvert. Une solution courante est d'utiliser des services de cloud sécurisés, tels qu'AWS, qui offrent des mesures de sécurité robustes pour protéger vos données sensibles.

AWS regroupe un ensemble de services *cloud* proposés par Amazon. Il offre une vaste gamme de services, allant de l'entreposage et de la gestion des données à la computation et à l'analyse avancée. AWS est conçu pour offrir une infrastructure hautement évolutive et sécurisée, ce qui en fait un choix attrayant pour les chercheurs qui gèrent des données sensibles. L'outil présente de multiples avantages:

1. *Sécurité robuste* : AWS met l'accent sur la sécurité, avec des fonctionnalités telles que le chiffrement des données en transit et au repos, la gestion des accès basée sur les rôles et la conformité à des normes de sécurité strictes.

4 À la quête de l'optimisation

2. *Scalabilité* : AWS permet de faire évoluer vos ressources en fonction des besoins, garantissant des performances optimales même lorsque vos projets de recherche croissent en taille et en complexité.
3. *Flexibilité* : AWS propose une variété de services adaptés à différentes utilisations, allant de l'entreposage de données au calcul intensif pour l'analyse avancée.
4. *Collaboration simplifiée* : Bien que le coût d'entrée soit généralement bas, la possibilité de partager des ressources avec des collègues et de travailler en équipe rend AWS adapté à la collaboration.

AWS n'est pas le seul service cloud disponible. Microsoft Azure et Google Cloud Platform (GCP) sont des concurrents majeurs offrant des fonctionnalités similaires. Lorsque vous choisissez un fournisseur, prenez en compte les coûts, la convivialité et les fonctionnalités offertes. Le coût d'utilisation d'AWS peut varier en fonction des services utilisés, de la quantité de données entreposées et de la capacité de calcul requise. Lorsque vous travaillez seul, le coût peut sembler élevé par rapport à l'utilisation de solutions gratuites telles que Dropbox. Cependant, en équipe, la répartition des coûts peut rendre AWS plus abordable.

4.5.2.1 Exemple d'utilisation d'AWS pour entreposer et accéder à des données de sondages dans RStudio

Imaginez un jeune chercheur en sciences sociales qui travaille sur une analyse comparative de données de sondages recueillies sur plusieurs décennies. Pour maintenir la sécurité des données sensibles et faciliter l'accès pour les analyses dans RStudio, il décide d'utiliser AWS pour l'entreposage et la gestion de ses données.

4.5.2.1.1 Étape 1 : Crédit d'un compte AWS et configuration

4.5 Outils d'entreposage des données

Le chercheur crée un compte AWS et configure ses paramètres de sécurité, y compris la configuration de l'authentification à deux facteurs pour renforcer la sécurité de son compte.

4.5.2.1.2 Étape 2 : Création d'un espace d'entreposage S3

Le chercheur crée un compartiment Amazon S3 (Simple Storage Service) pour entreposer ses données de sondage. Il choisit une région AWS et définit les paramètres de sécurité appropriés, tels que le chiffrement des données.

4.5.2.1.3 Étape 3 : Transfert des données vers Amazon S3

Le chercheur transfère les données de sondage dans son compartiment Amazon S3 à l'aide de l'interface en ligne AWS ou d'outils d'importation.

4.5.2.1.4 Étape 4 : Configuration des autorisations

Pour sécuriser davantage les données, le chercheur configure les autorisations d'accès aux données dans Amazon S3. Il attribue des rôles et des politiques d'accès spécifiques aux utilisateurs, garantissant que seules les personnes autorisées peuvent accéder aux données.

4.5.2.1.5 Étape 5 : Configuration d'accès dans RStudio

Le chercheur installe le package *aws.s3* dans RStudio pour accéder à ses données entreposées dans Amazon S3. Il configure également les informations d'identification AWS dans son environnement RStudio.

4 À la quête de l'optimisation

4.5.2.1.6 Étape 6 : Accès et analyse des données dans RStudio

À l'aide du package *aws.s3*, le chercheur peut maintenant accéder à ses données directement dans RStudio par quelques lignes de code. Il peut charger les données dans des structures de données R et effectuer des analyses statistiques, des visualisations et des croisements.

4.5.2.1.7 Étape 7 : Sécurité et conservation des données

Après avoir effectué ses analyses, le chercheur peut choisir de conserver les données de sondage dans Amazon S3 en utilisant les politiques de conservation appropriées. Il peut également archiver des copies de sauvegarde pour garantir l'intégrité des données à long terme.

Dropbox se concentre principalement sur l'entreposage et la collaboration de fichiers, alors que AWS offre une gamme de services *cloud*, y compris l'entreposage sécurisé de données sensibles et la mise en place d'infrastructures évolutives. GitHub, d'autre part, se concentre sur la gestion de versions et la collaboration de code source. Chaque outil a son propre domaine d'expertise et peut être utilisé de manière complémentaire pour différents aspects de la recherche.

4.5.3 Conclusion

L'entreposage des données est une étape cruciale dans la recherche en sciences sociales numériques. Choisissez des outils adaptés à la sensibilité des données, privilégiez des services sécurisés comme AWS pour les données sensibles, et utilisez Dropbox pour la collaboration et l'entreposage de fichiers non sensibles. Une gestion efficace des versions, de la structure des dossiers et de la sécurité garantira l'intégrité de vos données et facilitera la collaboration tout au long de vos projets de recherche.

5 Gestion de la littérature

5.1 Straight up from Jedro Arnaud

Comme mentionné précédemment, les outils numériques de données massives facilitent le travail des personnes chercheuses lors de la récolte de données dans le cadre d'analyses empiriques. Cependant, la révolution technologique offre également des outils pouvant être utiles lors d'autres étapes du cycle de la recherche. Il s'agit notamment du cas de la revue de littérature, alors que de nombreux outils offrent aux personnes chercheuses des ressources permettant d'élaborer un cadre théorique exhaustif par le biais de données massives sur la littérature scientifique. L'outil Covidence, géré par une compagnie sans but lucratif, en est un exemple particulièrement prisé du monde académique lors de l'entreprise de revues de littérature. La plateforme en ligne Covidence est utilisée pour faciliter les revues systématiques de littérature. Cette dernière permet de réduire drastiquement le temps d'accomplissement du travail en plus de le rendre plus simple et plus intuitif. L'outil a été développé pour mieux gérer et organiser l'évaluation de quantité importante d'études scientifiques. L'exécution d'une revue de littérature sur Covidence se fait par le biais d'un double codage. C'est-à-dire que l'évaluation des études se fait manuellement par deux codeurs

3.6 Covidence : outil de récolte d'articles scientifiques travaillant de manière autonome et qui mettront en commun leurs résultats à la fin de l'exercice. L'outil est reconnu pour ses trois étapes précises : « Title and abstract screening », « Full text review » et « Extraction ». Covidence permet

5 Gestions de la littérature

d'importer des données massives provenant de base de données bibliographiques. En effet, l'outil lance des requêtes auprès de multiples bibliothèques, ce qui offre l'accès à des milliers d'études sur le champ étudié par les personnes chercheuses. Ces requêtes sont adaptées aux besoins spécifiques de la personne chercheuse voulant explorer en profondeur un domaine de la littérature scientifique. La première étape, soit le « Title and abstract screening », consiste en la révision des titres et des résumés des articles récoltés. Pour rendre le travail davantage efficace, il est nécessaire d'inclure des critères précis pour analyser les titres et résumés d'articles. En se servant du jugement et des critères qui étaient recherchés, les individus doivent éliminer ou accepter selon la pertinence de l'article quant à la littérature étudiée. Cette partie est souvent longue, puisque la littérature existante est souvent massive. Il est donc important pour les personnes chercheuses de se rencontrer à maintes reprises pour discuter des conflits de jugement et pour trouver des compromis. En outre, cette étape, plutôt longue, s'avère très utile et motivante, puisqu'il est possible de développer un jugement critique davantage raffiné et de s'instruire dans une littérature continuellement plus précise. Une fois avoir complété la revue des titres et des résumés, il faut entamer le « Full text review » qui, comme l'indique le nom, consiste à la révision complète des textes sélectionnés. Cette étape demande d'analyser chaque texte, puis de voter « oui », « non » ou « peut-être » quant à la conservation du texte dans la revue de littérature. Le vote permet donc soit d'exclure l'article, de le retenir ou de l'envoyer à la prochaine étape. D'un autre côté, les conflits rendent le travail beaucoup plus long, puisque les codeurs.euses ont un texte entier à argumenter. Ainsi, cette partie du travail, bien qu'elle comporte beaucoup moins de documents, est assez longue et exigeante. La dernière étape, soit celle de l'extraction, consiste à recueillir toute donnée étant utile à l'étude de la littérature désignée. Cette étape est demandante, car les chercheur.euse.s doivent se conformer à une grille de codification prédéfinie. Le but est qu'un consensus entre les codeurs émerge de ce processus. L'extraction permet de faire ressortir les théories, les méthodologies et les conclusions présentent dans les études retenues. Une fois les étapes de la revue systématique terminées, Covidence facilite l'exportation des résultats de l'extraction sous

5.1 Straight up from Jedro Arnaud

forme de tableaux, de graphiques et de rapports pour la mét-a-analyse ou pour la rédaction d'articles scientifiques. De nombreuses universités offrent un accès à Covidence par le biais de licences, et l'outil est particulièrement utile et bien construit. Toutefois, il existe d'autres alternatives à Covidence. Le choix de l'outil dépend des coûts de même que des besoins spécifiques des personnes chercheuses. Les plateformes DistillerSR, Archie et Rayyan sont notamment largement utilisées par les personnes chercheuses.

6 La gestion des références

6.1 Pourquoi citer ?

La citation des sources est une pratique incontournable dans le monde académique, essentielle à la préservation de la crédibilité académique et au maintien des normes éthiques. Elle sert de fondement à la contextualisation de nos recherches, nous permettant de situer nos travaux au sein d'un cadre scientifique établi et reconnu. Ce processus de contextualisation facilite non seulement la compréhension de l'évolution des connaissances dans un domaine donné, mais contribue également à la création d'une base de connaissances solide et dynamique, sur laquelle d'autres travaux peuvent être bâties (Zaid, Shamsudin, and Habil 2017). La référenciation rigoureuse des travaux antérieurs garantit la reproductibilité des expériences et des analyses, un pilier central de la méthodologie scientifique. En fournissant des détails précis sur les méthodes et résultats, nous ouvrons la voie à la validation et à l'éventuelle réfutation de nos travaux, renforçant ainsi l'intégrité de la recherche (Hughes 2013). De plus, la citation adéquate des sources est une marque de respect envers les contributions des autres chercheurs, assurant une juste attribution du mérite. Cela reconnaît l'importance de chaque découverte et idée dans l'avancement de la science, tout en prévenant le plagiat, une faute grave dans la recherche académique (Racz and Marković 2018). Enfin, une référenciation minutieuse aide à éviter les biais, en exposant clairement les fondements sur lesquels se base notre recherche. Cela permet une évaluation critique des sources et des perspectives, encourageant une approche plus équilibrée et nuancée dans l'analyse scientifique (Kostoff and Cummings 2013). En résumé, la

6 La gestion des références

citation des sources est un acte fondamental qui englobe et adresse de multiples aspects cruciaux de la recherche académique : de la crédibilité et la contextualisation à la reproductibilité, de la création d'une base de connaissances solide à l'attribution correcte du mérite, tout en combattant le plagiat et en minimisant les biais. C'est dans ce contexte que des outils tels que Zotero prennent toute leur importance, en facilitant la gestion rigoureuse des références et en soutenant les chercheurs dans leur quête de rigueur et d'excellence académiques.

6.2 À quoi sert un logiciel de gestion bibliographique ?

Un outil de référence bibliographique est un logiciel conçu pour aider les scientifiques à gérer et à organiser leurs références bibliographiques de manière efficace. Ces outils s'avèrent particulièrement utiles lors de la rédaction d'articles de recherche, de thèses, de mémoires ou d'autres documents académiques. Voici quelques-unes des fonctions principales d'un tel outil :

1. Collecte de références : Les outils de référence bibliographique permettent aux personnes utilisatrices de collecter et d'importer des références bibliographiques à partir de bases de données, de catalogues de bibliothèques, de sites Web ou d'autres sources. Certains outils offrent même la possibilité d'extraire automatiquement les métadonnées à partir de documents PDF.
2. Organisation et classement : Les références collectées peuvent être organisées en différentes catégories et dossiers. Cela facilite la recherche ultérieure et permet de garder une vue d'ensemble claire de la bibliographie.
3. Citation et génération de bibliographies : L'un des avantages majeurs des outils de référence est leur capacité à générer automatiquement

6.2 À quoi sert un logiciel de gestion bibliographique ?

des citations et des bibliographies conformes à différents styles de citation (APA, MLA, Chicago, etc.). Ce processus permet de gagner énormément de temps en formatage. Les personnes utilisatrices peuvent insérer des références directement dans leurs documents sans avoir à se soucier des détails de formatage.

4. Collaboration : Certains outils offrent la possibilité de collaborer en ligne, ce qui donne l'occasion à plusieurs personnes de travailler sur une bibliographie commune. Cela peut être utile pour les projets de groupe ou de recherche partagée comme c'est le cas dans une chaire de recherche. En plus d'utiliser un même logiciel, l'utilisation d'un outil de référencement contribue à économiser du temps par la centralisation des données sur un même interface.
5. Recherche et exploration : De nombreux outils de référence bibliographique offrent des fonctionnalités de recherche avancée qui facilitent la découverte de nouvelles références liées à un sujet spécifique.
6. Synchronisation et sauvegarde : Les références et les bibliographies peuvent être synchronisées sur plusieurs appareils, ce offre la possibilité aux personnes utilisatrices d'accéder à leurs références où qu'elles soient. Les sauvegardes régulières assurent que les données ne soient pas perdues en cas de problème technique.
7. Suivi de lecture : Certains outils permettent aux personnes utilisatrices de suivre les articles et les documents qu'elles ont lus, ce qui est particulièrement utile pour garder une trace de la littérature pertinente.
8. Importation et exportation : Les outils de référence bibliographique autorisent généralement l'importation et l'exportation des références dans différents formats, ce qui facilite le transfert de données.

En résumé, un outil de référence bibliographique simplifie grandement le processus de gestion des références bibliographiques, de formatage ainsi

6 La gestion des références

que de création de bibliographies. De plus, ces outils offrent la flexibilité de changer de style de citation instantanément, facilitant l'adaptation aux exigences variées des revues scientifiques et permettant aux chercheurs de se consacrer à l'essence de leurs recherches sans se préoccuper des contraintes formelles et des détails de formatage. D'ailleurs, il existe plusieurs outils de référence bibliographique, dont : Endnote, Zotero et Mendeley.

Chaque logiciel offre des caractéristiques uniques tout en partageant des objectifs communs fondamentaux. Ils visent principalement à optimiser l'efficacité et la collaboration en centralisant les références, une commodité indéniable pour les chercheuses et chercheurs et les équipes académiques. Le choix d'un logiciel adapté aux besoins spécifiques des personnes l'utilisants dépend de plusieurs facteurs, notamment la nécessité de partager les résultats de recherche et de collaborer sur des projets communs. Lorsque la collaboration est au cœur d'un projet, il est judicieux que tous les membres de l'équipe adoptent le même outil pour faciliter l'échange d'informations et la cohésion du groupe.

Zotero, EndNote et Mendeley, bien qu'ils partagent des principes de base similaires, se distinguent par des fonctionnalités spécifiques qui peuvent mieux s'aligner sur les préférences et exigences individuelles. La sélection d'un logiciel doit donc être guidée par une évaluation attentive de ses capacités à répondre aux besoins de l'utilisateur, tout en considérant des aspects cruciaux tels que le partage, la collaboration et la facilité d'utilisation.

Il est essentiel de souligner l'importance de la préférence personnelle dans ce choix. L'interface utilisateur, la facilité d'intégration dans les flux de travail existants, et la compatibilité avec d'autres outils numériques sont des critères qui influent grandement sur l'expérience utilisateur et, par conséquent, sur la productivité. En fin de compte, l'outil idéal est celui qui non seulement facilite la gestion des références mais s'intègre de manière transparente dans le quotidien académique de l'utilisateur, lui permettant ainsi de se concentrer pleinement sur la substance de ses recherches.

6.3 Pourquoi Zotero?

6.3 Pourquoi Zotero?

L'avantage de Zotero réside dans sa gratuité et son accessibilité libre. Son code est ouvert et son dépôt GitHub compte plus de 13 000 contributions. Il propose une large gamme de fonctionnalités ainsi que la possibilité d'ajouter des extensions, complétant ainsi son usage. Zotero est puissant tout en restant facile à utiliser. Il est disponible sur plusieurs plateformes (Windows, Mac, Linux, iOS, Android), favorisant ainsi la collaboration entre tous les membres d'une équipe de recherche utilisant des plateformes diverses. Il est possible de synchroniser sa bibliothèque Zotero sur plusieurs appareils, soit en utilisant le service cloud payant de Zotero, soit en configurant son propre espace de stockage cloud. Zotero s'intègre parfaitement dans un projet de recherche utilisant LaTeX ou Quarto, car il permet de générer des fichiers .bib à partir des bibliothèques et de les maintenir à jour automatiquement. Il s'intègre également aux logiciels de traitement de texte tels que LibreOffice et Microsoft Office. Il est possible de générer des bibliographies et des citations dans plus de 9 000 styles de citation différents, ce qui le rend adaptable à tous les besoins.

Un autre grand avantage de Zotero réside dans la centralisation des sources bibliographiques et de leurs fichiers associés. Il est possible d'ajouter des PDF à Zotero et de les synchroniser au sein de groupes de travail, facilitant ainsi le partage de documents avec les autres membres de l'équipe de recherche. Plus besoin de recourir à des dossiers partagés ou d'envoyer des documents par courriel ou via des plateformes de partage de fichiers : tout est centralisé dans Zotero. Cette centralisation offre la possibilité d'effectuer des recherches par mot-clé (type ctrl+f) à travers l'ensemble des sources d'une bibliothèque. Vous rédigez une conclusion sur les radis finlandais et souhaitez discuter des enjeux internationaux liés à leur agriculture en citant une source consultée il y a trois ans ? Avec Zotero, retrouver cette source ne prend que quelques secondes grâce à une simple recherche.

L'inconvénient de Zotero réside dans sa difficulté à gérer d'immenses bibliothèques contenant plusieurs milliers de fichiers, nécessitant parfois

6 La gestion des références

l'achat d'espace de stockage supplémentaire. De plus, bien que performant, le logiciel n'est pas exempt de défauts. Il arrive qu'il faille compléter manuellement des informations non détectées automatiquement par le connecteur intégré.

Zotero est souvent utilisé en combinaison avec BibLaTeX via l'extension Better BibTeX pour exporter et actualiser automatiquement des bibliographies au format .bib. BibLaTeX, une extension moderne pour gérer les bibliographies dans LaTeX et Quarto, s'utilise couramment avec Biber, un outil de traitement bibliographique avancé compatible avec BibLaTeX. Biber propose des fonctionnalités telles que le tri poussé, la gestion de multiples bibliographies et le traitement de divers formats de données bibliographiques. BibLaTeX, prenant en charge de nombreuses langues, est idéal pour la rédaction de documents destinés à un public international. L'exportation de bibliothèques Zotero sous forme de fichiers .bib pour leur utilisation avec BibLaTeX est simplifiée grâce à Better BibTeX, qui assure la mise à jour automatique de ces fichiers. Il est recommandé de maintenir dans votre fichier .bib uniquement les références utilisées, organisées par ordre alphabétique, afin de faciliter la collaboration et le partage des ressources.

6.4 BibLaTeX

BibLaTeX est une extension destinée au traitement des bibliographies dans LaTeX et Quarto, généralement associée à Biber, un programme conçu pour le traitement des données bibliographiques spécifiquement pour BibLaTeX. Biber propose des fonctionnalités avancées comme le tri poussé, la gestion de multiples bibliographies et la capacité de traiter des sources bibliographiques dans divers formats. Grâce à sa prise en charge étendue des langues, BibLaTeX est particulièrement adapté à la rédaction d'articles ou de livres pour un public international. Bien que BibLaTeX soit avant tout un package pour LaTeX, il est possible d'exporter des bibliothèques depuis des outils tels que Zotero sous forme de fichiers .bib, qui peuvent

6.5 Installation et configuration de Zotero

ensuite être exploités avec BibLaTeX. L'extension Better BibTeX permet de maintenir automatiquement à jour vos fichiers .bib à partir de Zotero. Il est recommandé de conserver uniquement les références utilisées dans votre fichier et de les organiser par ordre alphabétique, facilitant ainsi la coopération et le partage des sources.

Les inconvénients potentiels de BibLaTeX comprennent une courbe d'apprentissage plus accentuée pour ceux habitués à BibTeX, ainsi que le besoin de mises à jour régulières pour assurer la compatibilité avec les versions les plus récentes de LaTeX. En outre, certains éditeurs académiques ou revues possèdent leurs propres styles de citation et peuvent ne pas accepter les soumissions réalisées avec BibLaTeX, même si cette réticence tend à diminuer.

En conclusion, pour ceux qui cherchent à maximiser la flexibilité et la puissance de leurs outils de gestion de bibliographie dans LaTeX, BibLaTeX, en tandem avec Biber, offre une solution moderne et robuste.

6.5 Installation et configuration de Zotero

Dans cette section, vous serez amené notamment à installer Zotero ainsi que Better BibTeX. Better BibTeX est une extension de Zotero servant à générer et à maintenir à jour des fichiers .bib compatibles avec BibLaTeX, à partir de Zotero.

6.5.1 Zotero

- Installer Zotero
- Installer Zotero Connector
- Une fois Zotero installé, vous avez l'option de créer un compte Zotero. L'identifiant que vous utiliserez sera celui que vous partagerez à vos collaborateurs pour créer et joindre des groupes.

6 La gestion des références

6.5.1.1 Better Bibtex

- La prochaine étape sera d’installer Better BibTex. Pour ce faire, allez dans l’onglet tools > Add-ons ensuite cliquez sur l’icône de paramètre et faites Install Add-on From File. Sélectionnez le fichier .xpi que vous avez téléchargé.


IMPORTANT

- Une fois le module complémentaire installé, accédez aux paramètres de Better BibTeX en allant dans l’onglet Zotero > Préférences > Onglet Better BibTeX > Ouvrir les préférences de Better BibTeX.
- Il est important, lors de la collaboration, de s’assurer d’avoir les mêmes clés de citation que vos collègues. Better BibTeX peut s’assurer que vos clés respectent un format standard.
- Voici une suggestion de format de clé de citation : il s’agit simplement du nom de l’auteur et de l’année de publication à deux chiffres. Pour l’utiliser, collez ceci dans la section Format de clé de citation : `authEtal2.fold.lower.replace(find=". ", replace=_ + len + shortyear | veryshorttitle + shortyear`
- Afin de vous assurer d’avoir les mêmes clés de citation, vous pouvez faire un clic droit sur vos références, aller dans les options de Better BibTeX et cliquer sur “Actualiser les clés de citation”

6.5.1.2 Génération du fichier .bib

Dans Zotero, vous devriez maintenant voir le groupe Zotero de votre équipe dans les Group Libraries.


6.5 Installation et configuration de Zotero



Il est important de comprendre que tout changement que vous faites dans Zotero sera automatiquement synchronisé avec le groupe de votre équipe de travail. Ainsi, si vous supprimez une référence, elle sera supprimée pour tout le monde!

Clic-droit sur la collection livre-outils > Export Collection choisissez le format Better BibLaTex et cochez la case [x] Keep updated. Faites OK et sauvegardez le fichier dans le dossier .git du projet livre-outils. Ce dossier sera constamment mis à jour avec les changements que vous faites dans Zotero et sera synchronisé avec le projet Github quand vous ferez vos pull requests.

6 La gestion des références



6.5.1.3 Utilisation de Zotero lors de l'écriture

Lors de l'écriture, vous n'avez qu'à écrire @ dans votre éditeur pour faire sortir la palette de référencement.

6.5.1.4 Ajouter des références à Zotero

Il y a différentes façons d'ajouter des références à Zotero :

- Glisser-déposer à partir de votre bibliothèque personnelle.
- Glisser-déposer les PDF que vous avez sur votre ordinateur dans la collection Livres-Outils. Zotero va essayer de trouver les métadonnées automatiquement.
- Si cela ne réussit pas, vous pourrez ajouter la référence en cliquant sur la baguette magique en haut à gauche du symbole "+" vert. L'outil de la baguette magique est utile si vous possédez le DOI ou l'ISBN de l'article/livre que vous devez ajouter. Dans les rares cas où Zotero ne trouve rien concernant votre référence, vous pourrez remplir les différents champs manuellement.
- Utiliser le connecteur dans votre navigateur. Zotero tentera également de télécharger l'article directement et de l'inclure dans la collection appropriée.

6.6 Conclusion

6.6 Conclusion

Pour conclure, l'adoption de Zotero comme outil de gestion bibliographique se révèle être un choix judicieux pour tout chercheur soucieux de l'efficacité et de la rigueur dans le processus de documentation scientifique. Au-delà de la simple facilitation du travail de recherche en équipe, Zotero se distingue par sa capacité à optimiser la gestion des citations et des bibliographies, permettant ainsi une économie de temps considérable et une réduction des risques d'erreurs. Sa fonctionnalité de centralisation des sources et de leurs fichiers associés offre un avantage notable en termes d'organisation et d'accès rapide à l'information, cruciale dans le cadre de recherches approfondies ou pluridisciplinaires. L'intégration de Zotero dans les environnements académiques, même en dehors des contextes de recherche, comme l'enregistrement des lectures pour des cours ou des séminaires, prépare efficacement les utilisateurs à des pratiques de recherche plus poussées et renforce la culture de la gestion rigoureuse des références. Cette initiation précoce est d'autant plus pertinente que Zotero se prête à une variété de styles de citation, répondant ainsi aux exigences diverses des publications académiques. Il est important de souligner que la maîtrise de Zotero, bien que facilitée par de nombreux tutoriels et ressources en ligne, représente un investissement en temps qui se trouve largement compensé par les bénéfices en termes d'efficacité et de qualité du travail de recherche. En outre, l'accès gratuit et le caractère open-source de Zotero témoignent de son engagement en faveur d'une diffusion élargie du savoir et d'une collaboration scientifique ouverte.

6.6.1 Revue Systématique

une revue systématique est une synthèse méthodique et exhaustive de la littérature centrée sur une question de recherche spécifique. Elle vise à recenser l'ensemble des travaux académiques, publiés ou non, relatifs à cette question Kibbee (2023) **kibbee23**. Comme mentionné précédemment, une

6 La gestion des références

telle revue requiert un investissement conséquent en temps et en effort, mais, lorsqu'elle est bien menée, elle présente un grand potentiel scientifique.

La méthode a été choisie selon le processus décisionnel suggéré par \textcite[16] (**cloutier23?**). Elle répond aux critères suivants: l'objectif est de recenser toutes les données relatives au sujet, l'équipe de recherche compte plus de deux personnes, le calendrier du projet prévoit plus de 12 mois de recherche, et l'analyse porte sur une unique question de recherche.

La revue systématique sera menée en suivant les 24 étapes décrites par (**muka_etal20?**).

1. Définir la question de recherche.

Dans le cadre de ce projet, la question de recherche est: Quels sont les éléments constitutifs d'une recherche en science politique? .

2. Établir l'équipe.

L'équipe sera composée de collègues universitaires souhaitant participer au projet et ayant une expérience dans le domaine d'étude.

3. Définir la stratégie pour l'obtention des références.

Plusieurs bases de données seront sélectionnées pour effectuer la recherche, dont celle de la bibliothèque de l'université, Web of Science, Google Scholar, JSTOR, etc. L'assistance d'un bibliothécaire sera sollicitée pour optimiser la stratégie de recherche et affiner l'utilisation des mots-clés, comme suggéré par cloutier23 et dufour23.

4. Définir les critères d'inclusion et d'exclusion.

Les critères de sélection permettront de circonscrire le nombre de références utilisées pour la revue. Ils pourront concerner un domaine d'étude, un choix de langues de publication ou une période donnée. Dans ce projet, les critères d'inclusion et d'exclusion seront à définir avec l'équipe.

6.6 Conclusion

5. Définir le formulaire d'extraction des données.

L'objectif de la revue systématique est d'extraire les données des textes analysés. Dans ce projet, il s'agit de construire une base de données composée d'éléments pertinents pour la recherche. Ainsi, les données extraites seront des métadonnées, telles que les sections, leur longueur, leurs titres, leur ordre, les méthodes utilisées, les définitions, les références, etc. Tous ces éléments sont pertinents pour structurer une recherche en science politique.

6. Écrire le protocole de recherche servant à guider le processus.

Le protocole de recherche est essentiel pour guider l'équipe tout au long du processus de filtrage. Avant de commencer la revue, [4]muka_{etal}20 recommandent de consulter différents experts afin de valider le protocole, s'assurant ainsi de sa validité et de sa pertinence.

7. Appliquer la stratégie de recherche à diverses bases de données.

Il faudra mettre en œuvre la stratégie de recherche sur les bases de données choisies et l'ajuster pour chaque base. Il sera important de bien documenter cette étape car elle servira à la preuve de concept d'automatisation de la revue systématique.

8. Rassembler les références et les résumés.

Les références seront rassemblées et intégrées dans une bibliothèque de groupe Zotero, un logiciel libre permettant de gérer les références bibliographiques.

9. Éliminer les doublons.

Zotero offre la possibilité d'éliminer les doublons automatiquement.

10. Filtrer les résultats à partir des titres et résumés.

À cette étape, deux membres de l'équipe de recherche effectueront le filtrage des résultats. Ils élimineront les références non pertinentes à la question de recherche en se basant sur le titre et le résumé. Les

6 La gestion des références

références non écartées par les deux évaluateurs seront conservées pour l'étape suivante.

11. Comparer les résultats des codeurs.

Il faudra conserver les références acceptées par au moins deux codeurs, écarter celles jugées non pertinentes par au moins deux d'entre eux et organiser une discussion concernant les références acceptées par un seul codeur pour juger de leur pertinence.

12. Télécharger les textes entiers et appliquer les critères d'inclusion et d'exclusion

Les références retenues seront téléchargées. Les textes difficiles d'accès seront recherchés manuellement. L'assistance d'un bibliothécaire pourrait être nécessaire à cette étape.

13. Contacter les experts du champs et s'informer à propos des éléments manquants ou non-publiés

Pour s'assurer qu'aucun élément pertinent n'a été omis, il est recommandé de consulter des experts du domaine. [6]muka_{etal}20suggèrentdecontacterchaquea

14. Rechercher manuellement des références additionnelles

Il s'agira de réaliser une recherche boulle de neige (*snowballing*) à partir de tous les articles retenus aux étapes 12 et 13. Cette méthode consiste à compiler chaque référence citée dans les articles sélectionnés et chaque article qui cite les articles retenus. Des outils tels qu'Elsevier Scopus peuvent faciliter cette démarche.

15. Sélectionner les références à inclure et déssiner le diagramme de flux

Les articles choisis lors des étapes 12, 13 et 14 constitueront ceux inclus dans la revue systématique. Un diagramme de flux sera réalisé pour documenter le processus de sélection: combien d'articles ont été examinés, combien ont été retenus, à quelle étape ont-ils été écartés, etc.

6.6 Conclusion

16. Extraire les données des articles

Les données des articles seront extraites. Il est crucial que chaque membre de l'équipe utilise le même formulaire d'extraction pour assurer la comparabilité des données.

17. Évaluer la qualité des articles et les risques de biais

L'échelle de notation Newcastle-Ottawa de wells_{etal}00 sera utilisée pour évaluer la qualité des articles. Cette échelle

18. Préparer la base de donnée pour l'analyse.

Les données de chaque article seront compilées dans une base de données, laquelle servira pour l'analyse des résultats. Le langage de programmation R pour la gestion de cette base de donnée sera privilégié pour sa facilité d'utilisation et sa popularité en science politique.

19. Construire une synthèse descriptive des données.

Une synthèse descriptive des données sera élaborée. Cela permettra de se familiariser avec elles, de les nettoyer et de les comprendre. Cette synthèse aidera à identifier les tendances et les éléments constitutifs de la recherche en science politique.

20. Décider si une méta-analyse est appropriée.

Selon [7]muka_{etal}20, les étapes 1 à 19 d'une revue systématique sont identiques à celles d'une méta-analyse. C'est à l'étape 20 qu'il faut décider de la pertinence d'une méta-analyse. Si les données sont trop hétérogènes, leur comparaison et leur analyse pourraient être imprécises et non significatives. Dans le cadre de ce projet, les données seront probablement propices à une analyse puisqu'elles sont majoritairement de nature quantitative.

21. Explorer l'hétérogénéité.

Il s'agira d'examiner les différences entre les articles pour déterminer si il est possible d'harmoniser les données de chaque étude, optimisant ainsi leur comparaison et leur analyse.

6 La gestion des références

22. Évaluer les biais.

Il est essentiel de reconnaître et de traiter les biais. Un biais de publication serait particulièrement susceptible d'affecter une revue systématique en science politique.

23. Évaluer la qualité des preuves et la confiance dans les résultats

La qualité de la base de données sera évaluée pour déterminer si les données sont suffisamment fiables pour une méta-analyse ou une revue systématique. Si la qualité s'avère insuffisante, il pourrait être nécessaire de reprendre le processus depuis la première étape.

24. Rédiger le rapport de la revue systématique

Ce rapport final documentera le processus de peaufinage des GML utilisés lors de la deuxième étape. Les données collectées seront essentielles à la réalisation du projet.

7 Les outils de collecte de données

La révolution numérique engendrée par l'émergence du Big Data représente un important défi pour le monde des sciences sociales (Manovich, 2011; Burrows et Savage, 2014). Elle constitue également une opportunité de recherche enrichissante et innovante permettant une compréhension plus accrue des phénomènes sociaux étudiés par la communauté scientifique (Connelly et al., 2016). Cette meilleure compréhension est permise, entre autres, par l'accès à des données massives concernant les trois acteurs clés de la société démocratique: les citoyens, les médias et les décideurs (Schroeder, 2014; Kramer, 2014). Si l'accès à ces données représente un défi éthique et théorique, tel qu'explicité lors des chapitres précédents, elle représente également un défi technique pour les chercheurs.euses voulant exploiter le potentiel et les opportunités offertes par les données massives (Burrows et Savage, 2014). Le chapitre qui suit vise à offrir un portrait de certains outils de collecte de données pouvant être exploités par les chercheurs.euses en sciences sociales visant à tirer profit de la révolution numérique. À travers ce chapitre, il sera question d'outils permettant de collecter des données de sondages, des données médiatiques, de même qu'une panoplie de données textuelles par le biais d'extracteurs. Ce chapitre offre donc un tour d'horizon de certains outils de collecte de données à la disposition de la communauté scientifique souhaitant entamer des recherches en sciences sociales numériques.

7.1 Le Big Data et les différents acteurs de la société :

Le champ d'étude de la science politique repose sur l'étude de trois types d'acteurs distincts ayant un impact sur la condition socio-économique et politique d'une société : les décideurs, les médias et les citoyens. La recherche sur les décideurs comprend entre autres l'analyse des politiques publiques, des partis politiques, de stratégies électorales ou encore l'analyse de discours de politiciens ou d'organisations. L'étude des médias repose largement sur le rôle des médias dans la formation des priorités et des jugements des citoyens quant aux enjeux politiques, de même que sur leur capacité d'influencer l'agenda des politiciens. En ce qui concerne les citoyens, le champ d'étude de l'opinion publique se consacre à l'analyse des comportements et des attitudes politiques des individus. De plus, de nombreuses recherches visant à comprendre le rôle des citoyens dans une société démocratique portent sur l'influence de la société civile de même que sur l'effet des mouvements sociaux.

Chacun de ces champs de recherches se voit confronté à une panoplie de défis théoriques et techniques en lien avec l'émergence des données massives. La révolution technologique permet une étude plus approfondie des phénomènes auxquels sont confrontés les différents acteurs de la société démocratique, en raison de l'importante quantité de données accessible aux chercheurs.euses. Toutefois, la collecte de données permettant de mener à terme de telles études peut s'avérer complexe. Pour chacun des trois acteurs démocratiques énumérés précédemment, les sections suivantes énumèrent et expliquent les capacités techniques d'outils permettant aux chercheurs.euses d'accéder à des données massives. Bien que d'autres outils existent et offrent des résultats satisfaisants, les méthodes suivantes sont particulièrement pertinentes dans une optique d'étude des sciences sociales numériques en raison de leur capacités techniques de même que par la relative simplicité de leur utilisation.

7.2

7.3 Plateformes de sondages et collecte de données

Malgré certaines différences méthodologiques, toute recherche doit analyser et interpréter des données fiables et de qualité afin d'émettre des résultats (Nayak & K. A., 2019). Notamment lorsqu'il est question d'étudier les citoyens et l'opinion publique, il est nécessaire d'accumuler suffisamment de données auprès d'un échantillon assez grand afin d'inférer des conclusions sur la population.

Quelques méthodes sont couramment utilisées pour la collecte de données sont le sondage, le panel, l'enquête, ou le questionnaire. Cette section se concentre sur le sondage. Ils peuvent être manuels ou électroniques, et dans le second cas, peuvent être administrés par ordinateur, par courriel ou via le web (Nayak & K. A., 2019). La différence majeure entre les méthodes manuelles et les méthodes numériques réside dans le fait que les premières impliquent un contact direct entre le chercheur et le répondant, tandis que dans le cas des secondes le contact est indirect (Evans & Mathur, 2018). L'arrivée des données massives et des outils numériques offre une panoplie de nouvelles opportunités de collecte de données pour la communauté scientifique. Lorsqu'exécutée manuellement, la collecte de données et la réalisation de sondages peuvent devenir des tâches lourdement fastidieuses, et de facto, demander énormément de ressources pour mener une recherche à grande échelle. C'est pourquoi les technologies du numérique peuvent faciliter cet aspect de la recherche en fournissant des plateformes de sondages et de collecte de données. De plus, les sondages représentaient en 2016 environ 20% du chiffre d'affaires de l'industrie globale du marketing (Evans & Mathur, 2018). Ces chiffres montrent la pertinence de l'acquisition de compétences nécessaires à la formation de sondages, tant dans le monde académique que professionnel. Le numérique permet donc de créer un questionnaire, de cibler une population et de la contacter, d'entreposer les

7 Les outils de collecte de données

données des répondants pour ainsi les visualiser, le tout à un coût réduit et plus rapidement que s'il avait été conduit manuellement (Nayak & K. A., 2019). Ainsi, les sondages en ligne ont une portée internationale, permettent le suivi de la ligne du temps, offrent des options qui contraignent le répondant à répondre à certaines questions et permettent d'utiliser des arbres de logique avancés que les sondages manuels ne permettent pas.

7.3.1 Les principales plateformes web.

Il existe un large éventail de plateformes de sondages et de collecte de données qui peuvent être utiles dans un contexte académique. Cet ouvrage se limite à cinq d'entre elles: Qualtrics, REDCap, SurveyMonkey, Google Forms et Typeform. Cependant, il n'est pas déconseillé de se renseigner sur les autres plateformes disponibles en fonction de ses besoins et de ses ressources. Voici une liste non-exhaustive: LimeSurvey, Zoho Survey, Qualaroo, Formstack, Wufoo, Checkbox Survey, SmartSurvey, QuickTap-Survey, SoGoSurvey, Snap Surveys, AskNicely, Opinio, Alchemer, Cognito Forms, Feedbackify.

7.3.1.1 Qualtrics (<https://www.qualtrics.com/>)

Cette plateforme est une des plus reconnues et utilisées à l'international, tant dans le milieu académique que dans le secteur privé. En plus d'offrir des outils de collecte de données et de sondages, Qualtrics est utilisé dans le marketing et dans la gestion de l'expérience client. Il est donc pertinent de se familiariser avec cet outil, car il offre des compétences pratiques pour la recherche, mais également pour obtenir des opportunités de carrière. Qualtrics offre plusieurs services pratiques pour la collecte de données, avec des options flexibles pour la programmation et l'administration des

7.3 Plateformes de sondages et collecte de données

sondages. Par exemple, Qualtrics s'adapte à différents formats en fonction de l'appareil du répondant (Evans & Mathur, 2018).

7.3.1.2 REDCap (<https://www.project-redcap.org/>)

Research Electronic Data Capture (REDCap) permet de construire et de gérer des sondages ainsi que des bases de données. Pour accéder aux services de cette application, il est nécessaire d'être un partenaire du REDCap Consortium ou membre d'une organisation qui en fait partie. Seules les organisations à but non lucratif peuvent adhérer au Consortium. Les données et les sondages qui y sont produits peuvent être partagés et utilisés par différents chercheurs issus de diverses institutions. L'exportation vers différents types de fichiers (Excel, PDF, SPSS, SAS, Stata, R) est possible. Ce qui distingue REDCap des autres applications est sa compatibilité avec les dossiers médicaux, sa sécurité pour les données sensibles, ainsi que son approche académique à la collecte de données par sondage.

7.3.1.3 SurveyMonkey (<https://www.surveymonkey.com/>)

SurveyMonkey se distingue des autres applications en permettant de construire et gérer des sondages/formulaires à l'aide d'une interface conviviale sans toutefois perdre de ses fonctionnalités. En plus d'avoir recours aux nouvelles technologies de l'I.A. pour aider à construire des sondages adaptés à vos besoins, cette application propose plusieurs centaines de modèles personnalisables élaborés par des experts dans le domaine. SurveyMonkey permet également l'analyse des données et la création de rapports directement sur l'application, en plus de permettre l'exportation vers d'autres types de programmes. Les forfaits varient en gamme de tarifs, allant du gratuit avec des fonctionnalités restreintes, jusqu'aux options payantes destinées aux particuliers et aux entreprises.

7 Les outils de collecte de données

7.3.1.4 Google Forms (<https://docs.google.com/>)

Cette application se distingue par sa simplicité et son accessibilité, en grande partie grâce à l'omniprésence de google tant dans le monde académique que dans la vie courante. Google Forms est inclus dans le forfait de base du Google Workspace, ce qui le rend largement compatible avec les autres applications de Google, en plus d'être disponible gratuitement. Bien que ses fonctionnalités soient moins avancées que celles de ses compétiteurs, Google Forms peut convenir pour des sondages plus simples et rapides grâce à son interface conviviale, à sa fonction d'analyse de données directement sur la plateforme, ainsi qu'à ses modèles préfabriqués.

7.3.1.5 TypeForm (<https://www.typeform.com/>)

Si votre objectif est de produire des formulaires avec une esthétique attrayante, moderne et interactive, TypeForm est la plateforme idéale. Elle permet de se concentrer sur l'expérience de l'utilisateur et de l'impliquer dans le sondage grâce à son aspect visuel. Cette plateforme dispose d'une option gratuite, ainsi que plusieurs forfaits payants. Typeform est également compatible avec plusieurs applications de gestion du flux de travail (Zapier, Google Sheets, Slack, etc).

7.3.2 Les limites des sondages en ligne

Néanmoins, les sondages en ligne comportent des défis, notamment en ce qui concerne l'échantillonnage, les taux de réponse et les caractéristiques des non-répondants. Il est également nécessaire de se méfier des enjeux éthiques et de confidentialité (Nayak & K. A., 2019). Comme la généralisation est essentielle pour conférer une valeur scientifique à ses résultats de

7.3 Plateformes de sondages et collecte de données

recherche, les sondages en ligne ont leurs limites. En effet, il est crucial de connaître la population cible pour effectuer des inférences valides, et l'échantillonnage doit reposer sur des caractéristiques précises. Même si des informations démographiques peuvent être collectées et des quotas utilisés, il n'est toutefois pas réellement possible de confirmer les informations sur le répondant (Andrade, 2020). Les sondages traditionnels où l'on retrouve un contact direct sont plus susceptibles de permettre de brosser un portrait plus complet du répondant (Evans & Mathur, 2018). Les répondants avec des biais peuvent également plus facilement répondre aux sondages en ligne et limiter la généralisation (Andrade, 2020). Les sondages en ligne sont également souvent perçus comme des pourriels, ont généralement de faibles taux de réponse, sont impersonnels et peuvent avoir des instructions peu claires. Ils ont également leurs lots d'enjeux de confidentialité (Evans & Mathur, 2018).

Conseils méthodologiques à la réalisation d'un sondage numérique
(Evans & Mathur, 2018)

L'article de Evans et Mathur (2018) est une revue de littérature observant l'évolution des sondages numériques depuis la parution de leur dernier article sur le sujet en 2005. À travers cet article, les auteurs offrent des conseils méthodologiques en fonction de leur analyse de contenu de la littérature scientifique. Les conseils d'Evans et Mathur (2018) sont résumés ci-dessous. Afin d'obtenir plus de détails, n'hésitez pas à vous référer directement à cet article. De plus, bien qu'il s'agisse d'un article crédible et largement documenté, il est toujours pertinent de consulter des sources spécifiques à vos besoins.

- 1.Définir le but du sondage avant la méthodologie. Lorsque possible, inclure des hypothèses testables et des méthodes basées sur des fondations théoriques.
- 2.Choisir le type de sondage.
- 3.Décider des méthodes d'échantillonnage, des quotas et des échéances.
- 4.Déterminer le responsable de la construction du sondage.

7 Les outils de collecte de données

- 5.Soyez transparent en divulguant le but du sondage, la façon dont les données seront utilisées ainsi que l'auteur du sondage.
- 6.Les questions et les catégories de réponses doivent être élaborées de manière objective et dans une perspective de convivialité.
- 7.Les sondages doivent être assez légers pour favoriser un taux de réponse positif, mais assez complet pour avoir l'information nécessaire.
- 8.Ils doivent également être attrayant afin de favoriser leur complétion par le répondant.
- 9.S'assurer de l'anonymat du répondant.
- 10.Il faut régulièrement procéder à des tests afin de corriger les faiblesses du questionnaire.
- 11.Déterminer qui administre le sondage, qui collecte l'information, et qui analyse les données.
- 12.Établir un échéancier pour les différentes étapes de l'étude.
- 13.Suite à la collecte de données, entreposer les données brutes dans un fichier électronique.
- 14.Utiliser les méthodes appropriées (qualitatif ou quantitatif), et analyser les données selon les buts de l'étude.
- 15.Dans le cas d'une recherche académique, il est important d'avoir une section dédiée aux limites de l'étude.
- 16.Conserver l'anonymat des répondants lors de l'analyse et de la publication.
- 17.Agir sur les résultats. Rien ne sert de conduire un sondage qui ne contribue pas à la croissance du savoir ou n'apporte pas de changement stratégique ou organisationnel.
- 18.Toujours se plier à un code d'éthique rigide.

Il s'agit donc ici d'un court résumé des plateformes de sondages et de la collecte de données en ligne, tentant de couvrir l'essentiel de cet outil afin de vous aider lors de votre parcours académique, ou simplement comme aide-mémoire pour la réalisation d'un sondage. Les outils énumérés précédemment permettent une étude approfondie de phénomènes concernant les citoyens. Bien sûr, il n'est pas possible de couvrir l'entièreté de cet outil très complexe et ayant évolué dans le temps. Cette section ne

7.4 Factiva : outils de récolte de données médiatiques

sert donc que de point de départ si vous vous intéressez à l'élaboration d'un sondage numérique. Il vous est donc recommandé de vous renseigner davantage avec d'autres ressources afin de compléter ce qui est indiqué dans cet ouvrage.

7.4 Factiva : outils de récolte de données médiatiques

L'émergence de nouvelles technologies de même que la fragmentation médiatique, causée notamment par l'apparition de chaînes de nouvelles en continu, ébranlent considérablement les écosystèmes médiatiques occidentaux (Chadwick, 2017). Un récent courant de recherche se penche sur le rôle des médias relativement aux comportements des individus dans une perspective de fragmentation médiatique. Ces changements de dynamique médiatiques permettent aux individus de choisir leurs sources d'information. Cette fragmentation aurait conséquemment pour effet de contribuer à la formation de chambres d'écho. Ainsi, les études sur les effets des médias visent à comparer les agendas de différentes organisations médiatiques de même que de comprendre le cadrage de la nouvelle qu'ils offrent aux citoyens. Pour effectuer de telles études comparées, l'accès à des données médiatiques est essentiel. L'arrivée de données massives permet de nouvelles avenues de recherche pour les chercheurs.euses en sciences sociales en raison de l'importante quantité de données accessibles aux chercheurs.euses, ce qui permet une compréhension accrue des réalités médiatiques modernes.

L'outil Factiva offre un accès à l'ensemble des articles d'une panoplie de médias provenant d'une vaste sélection de pays. Le moteur de recherche est opéré par Dow Jones et offre également l'accès à des documents d'entreprises. En revanche, l'accès qu'il offre aux contenus médiatiques est particulièrement pertinent pour la communauté scientifique en communication et en sciences sociales. Il offre l'accès à plus de 15 000 sources médiatiques provenant de 120 pays. Il permet de télécharger une quantité illimitée de documents RTF, un format de fichier de texte, pouvant contenir jusqu'à 100

7 Les outils de collecte de données

articles chacun. En outre, ils peuvent être sélectionnés automatiquement en cochant le bouton proposant de sélectionner les 100 articles de la page de résultat. Chaque page de résultat contient 100 articles à la fois. Enfin, Factiva permet également de filtrer les doublons.

Additionnellement, cet outil permet également de lancer une requête de recherche par mots-clés et par date qui permet, par exemple, de récolter les articles médiatiques concernant un sujet précis dans une ligne de temps déterminée. De manière plus précise, Factiva permet de filtrer la recherche d'articles par source, par date, par auteur, par sociétés, par sujet, par secteur économique, par région et par langue. Disons qu'un.e chercheur.euse désire comparer la couverture médiatique d'une élection donnée. Il peut, par le biais de Factiva, sélectionner tous les articles contenant le mot « élection » dans une sélection de médias, et ce, durant la période de l'élection. Les mots clés sélectionnés peuvent être adaptés aux désirs de l'utilisateur.ice de manière à inclure des mots qui peuvent être mis ensemble ou à un maximum d'intervalle de mot. L'utilisation des signes « and » et « or », aussi connus sous le nom d'opérateurs booléens, permettent d'ajouter un mot dans la requête de recherche. En ajoutant near5, l'on peut spécifier qu'il doit y avoir un maximum de 5 mots entre les deux mots recherchés. L'on peut également mettre certains signes à la fin de mots, ce qui permet de préciser le champ de recherche. Par exemple, dans une étude récoltant des articles sur les immigrants, le mot immigrant pourrait être écrit de la manière suivante : immigra*. Ainsi, tous les mots débutant par ce suffixe seraient inclus de la recherche d'article, ce qui comprend donc : immigrant, immigration, immigrants, immigrante, etc. La Figure 1 est une capture d'écran de l'interface de recherche de Factiva. Ainsi, en ajoutant un opérateur booléen, l'on peut préciser un champ de recherche. L'utilisateur.ice pourrait, par exemple, rechercher des articles sur les immigrants syriens, et rajoutant les opérateurs “and” ou encore “or”, de même que le mot « syri* », l'étoile étant rajoutée pour inclure le plus de mots possible.

Ainsi, Factiva permet d'avoir accès facilement à des données utiles pour de l'analyse textuelle d'articles médiatiques. Comme les textes deviennent ac-

7.4 Factiva : outils de récolte de données médiatiques




Figure 7.1: image3_1

cessibles rapidement et simplement aux chercheurs.euses, cet outil optimise considérablement l'analyse de contenu par thèmes ou par ton.

Cependant, ce ne sont pas tous les médias qui sont accessibles sur Factiva. Dans l'optique ou un média recherché n'est pas trouvable sur Factiva, le logiciel Eureka représente une bonne alternative. Eureka se concentre principalement sur les médias francophones (autant au Québec qu'en Europe). La structure d'Eureka est similaire à celle de Factiva. En effet, Eureka permet de filtrer des articles médiatiques par requête de recherche adaptée à la source, la date ou encore l'auteur. Toutefois, les requêtes de recherche doivent être formulées d'une manière quelque peu différente. Elles doivent donc être adaptées au fonctionnement d'Eureka. Les articles doivent être sélectionnés à la main, et peuvent être téléchargés dans un document PDF pouvant contenir un maximum de 50 articles à la fois. La Figure 2 contient l'interface de recherche d'Eureka.

Il existe aussi une panoplie d'outils permettant un accès à des données médiatiques. Quoique Factiva soit intuitive et que de nombreuses universités possèdent des licences permettant d'exploiter la plateforme, plusieurs alternatives s'offrent à la communauté scientifique. NexisUni, qui comprend entre autres l'outil LexisNexis Academic particulièrement prisé par le champ

7 Les outils de collecte de données




Figure 7.2: image3_2

d'études de communication aux États-Unis, représente une excellente alternative. C'est également le cas de NewsBank qui permet lui aussi un accès à un vaste répertoire d'articles médiatiques. Les chercheurs.euses peuvent choisir la plateforme qui leur convient le mieux, en prenant en compte notamment l'accès qui peut leur être fourni par l'institution universitaire les employant.

En somme, la révolution numérique permet un accès sans précédent aux données médiatiques, ce qui permet des analyses approfondies du rôle des médias traditionnels dans une société démocratique.

7.5 Les extracteurs : avoir accès à des données massives via du code.

7.5 Les extracteurs : avoir accès à des données massives via du code.

Chacun des acteurs démocratiques énumérés précédemment peut également être étudié par le biais d'extracteurs qui offrent un accès à des données numériques massives. Les extracteurs de données numériques sont des infrastructures de code permettant d'extraire des données brutes d'une source définie. La section suivante explique comment les extracteurs peuvent être utiles dans un contexte de recherche en sciences sociales numériques.

Les données en lien avec les décideurs sont souvent accessibles sur des sites gouvernementaux. Toutefois, certaines identifications peuvent être nécessaires et l'accès peut être compliqué, particulièrement dans une perspective de données massives. C'est dans cette optique que les extracteurs de données numériques peuvent être utiles. Un code peut extraire de manière automatisée les débats des parlements, les communiqués de presse des gouvernants, les plateformes électorales des partis politiques, ce qui offre un accès inégalé aux chercheurs.euses aux données de décideurs. Dans une autre optique, des extracteurs peuvent également offrir l'accès aux données provenant de médias socionumériques comme Twitter (maintenant X) ou Facebook . Un extracteur peut, par exemple, être en mesure de répertorier l'ensemble des Tweets de journalistes, de politiciens ou encore de citoyens de manière automatisée, offrant un accès inégalé aux chercheurs.euses à des données massives exclusives. L'élaboration d'extracteurs est toutefois facilitée par l'existence d'API (Application programming interface) sur les plateformes exploitées. L'API d'un site ou d'une application permet à un tiers parti d'avoir accès à du code expliquant le fonctionnement de la plateforme étudiée, ce qui en facilite l'extraction de données. Par exemple, Twitter possédait avant les changements de directions récents un API qui facilitait l'élaboration d'un extracteur. En contrepartie, Facebook ne possède pas d'API, ce qui rend l'accès à ses données beaucoup plus complexe. Un extracteur peut également offrir l'accès à des données médiatiques, en

7 Les outils de collecte de données

codant un accès à des fils RSS ou encore aux HTML des médias extraits.

L’élaboration d’un extracteur est toutefois une tâche complexe qui requiert un certain nombre de connaissances en lien avec les langages de programmation. Les chapitres 4 et 5 du présent ouvrage offrent justement un survol du langage fonctionnel R, qui est utilisé par de nombreux développeurs lors de l’écriture d’extracteurs. R est également reconnu pour ces fonctionnalités statistiques qui sont, elles aussi, abordées ultérieurement dans ce livre.

7.6 Covidence : outil de récolte d’articles scientifiques

Comme mentionné précédemment, les outils numériques de données massives facilitent le travail des personnes chercheuses lors de la récolte de données dans le cadre d’analyses empiriques. Cependant, la révolution technologique offre également des outils pouvant être utiles lors d’autres étapes du cycle de la recherche. Il s’agit notamment du cas de la revue de littérature, alors que de nombreux outils offrent aux personnes chercheuses des ressources permettant d’élaborer un cadre théorique exhaustif par le biais de données massives sur la littérature scientifique. L’outil Covidence, géré par une compagnie sans but lucratif, en est un exemple particulièrement prisé du monde académique lors de l’entreprise de revues de littérature.

La plateforme en ligne Covidence est utilisée pour faciliter les revues systématiques de littérature. Cette dernière permet de réduire drastiquement le temps d’accomplissement du travail en plus de le rendre plus simple et plus intuitif. L’outil a été développé pour mieux gérer et organiser l’évaluation de quantité importante d’études scientifiques. L’exécution d’une revue de littérature sur Covidence se fait par le biais d’un double codage. C’est-à-dire que l’évaluation des études se fait manuellement par deux codeurs travaillant de manière autonome et qui mettront en commun leurs résultats à la fin de l’exercice. L’outil est reconnu pour ses trois étapes précises : « Title and abstract screening », « Full text review » et « Extraction ». Covidence permet d’importer des données massives

7.6 Covidence : outil de récolte d'articles scientifiques

provenant de base de données bibliographiques. En effet, l'outil lance des requêtes auprès de multiples bibliothèques, ce qui offre l'accès à des milliers d'études sur le champ étudié par les personnes chercheuses. Ces requêtes sont adaptées aux besoins spécifiques de la personne chercheuse voulant explorer en profondeur un domaine de la littérature scientifique.

La première étape, soit le « Title and abstract screening », consiste en la révision des titres et des résumés des articles récoltés. Pour rendre le travail davantage efficace, il est nécessaire d'inclure des critères précis pour analyser les titres et résumés d'articles. En se servant du jugement et des critères qui étaient recherchés, les individus doivent éliminer ou accepter selon la pertinence de l'article quant à la littérature étudiée. Cette partie est souvent longue, puisque la littérature existante est souvent massive. Il est donc important pour les personnes chercheuses de se rencontrer à maintes reprises pour discuter des conflits de jugement et pour trouver des compromis. En outre, cette étape, plutôt longue, s'avère très utile et motivante, puisqu'il est possible de développer un jugement critique davantage raffiné et de s'instruire dans une littérature continuellement plus précise.

Une fois avoir complété la revue des titres et des résumés, il faut entamer le « Full text review » qui, comme l'indique le nom, consiste à la révision complète des textes sélectionnés. Cette étape demande d'analyser chaque texte, puis de voter « oui », « non » ou « peut-être » quant à la conservation du texte dans la revue de littérature. Le vote permet donc soit d'exclure l'article, de le retenir ou de l'envoyer à la prochaine étape. D'un autre côté, les conflits rendent le travail beaucoup plus long, puisque les codeurs.euses ont un texte entier à argumenter. Ainsi, cette partie du travail, bien qu'elle comporte beaucoup moins de documents, est assez longue et exigeante.

La dernière étape, soit celle de l'extraction, consiste à recueillir toute donnée étant utile à l'étude de la littérature désignée. Cette étape est demandante, car les chercheur.euse.s doivent se conformer à une grille de codification prédéfinie. Le but est qu'un consensus entre les codeurs émerge

7 Les outils de collecte de données

de ce processus. L'extraction permet de faire ressortir les théories, les méthodologies et les conclusions présentent dans les études retenues.

Une fois les étapes de la revue systématique terminées, Covidence facilite l'exportation des résultats de l'extraction sous forme de tableaux, de graphiques et de rapports pour la métá-analyse ou pour la rédaction d'articles scientifiques. De nombreuses universités offrent un accès à Covidence par le biais de licences, et l'outil est particulièrement utile et bien construit. Toutefois, il existe d'autres alternatives à Covidence. Le choix de l'outil dépend des coûts de même que des besoins spécifiques des personnes chercheuses. Les plateformes DistillerSR, Archie et Rayyan sont notamment largement utilisées par les personnes chercheuses.

7.7 Conclusion et discussion:

Le précédent chapitre portait sur les différents outils de collecte de données massives mis à la disposition des chercheur.euse.s s'intéressant au champ des sciences sociales numériques. Les outils relevés se démarquent par leur capacité d'accorder l'accès à des données permettant d'étudier les trois principaux acteurs de la société démocratique, soit: les citoyens, les décideurs et les médias. Comme mentionné à plusieurs reprises lors du chapitre, le but de ce dernier n'est pas d'offrir une liste complète des outils disponibles. Toutefois, les outils énumérés ont été sélectionnés en raison de leur intuitivité, leur relative simplicité d'accès de même que leurs capacités techniques considérées par les auteurs comme étant particulièrement pertinentes dans une optique de recherche en sciences sociales numérique. Ainsi, ce chapitre démontre que la possibilité d'effectuer des recherches en sciences sociales numériques par le biais de données massives est plus que jamais accessible à la communauté scientifique, particulièrement en ce qui a trait à la collecte de données permettant de tels travaux. Une fois les données collectées, le travail d'analyse représente un défi technique supplémentaire se dressant devant les personnes chercheuses. Les chapitres suivants visent

7.7 Conclusion et discussion:

à familiariser les chercheurs.euses à des outils méthodologiques permettant l'analyse et la visualisation de données massives au sein des sciences sociales.

Bibliographie:

- Schroeder, R. (2014). Big data and the brave new world of social media research. *Big Data & Society*, 1(2), 2053951714563194.
- Chadwick, A. (2017). The hybrid media system: Politics and power. Oxford University Press.
- Connelly, R., Playford, C. J., Gayle, V., & Dibben, C. (2016). The role of administrative data in the big data revolution in social science research. *Social science research*, 59, 1-12.
- Manovich, L. (2011). Trending: The promises and the challenges of big social data. *Debates in the digital humanities*, 2(1), 460-475.
- Burrows, R., & Savage, M. (2014). After the crisis? Big Data and the methodological challenges of empirical sociology. *Big data & society*, 1(1), 2053951714540280.
- Kramer, A. D., Guillory, J. E., & Hancock, J. T. (2014). Experimental evidence of massive-scale emotional contagion through social networks. *Proceedings of the National academy of Sciences of the United States of America*, 111(24), 8788.
- Andrade, C. (2020). The Limitations of Online Surveys. Indian Journal of Psychological Medicine, 42(6), 575-576. <https://doi.org/10.1177/0253717620957496>
- Evans, J. R., & Mathur, A. (2018). The value of online surveys: A look back and a look ahead. *Internet Research*, 28(4), 854-887. <https://doi.org/10.1108/IntR-03-2018-0089>
- Nayak, M., & K A, N. (2019). Strengths and Weakness of Online Surveys. 24, 31-38. <https://doi.org/10.9790/0837-2405053138>

8 Une image vaut mille mots

Camille Tremblay-Antoine¹ Nadjim Fréchet²

8.1 Introduction

Une fois les données collectées, nettoyées, traitées et analysées, une partie centrale du travail d'un scientifique de données est de faire parler les résultats de ses tests empiriques. Il s'agit alors de trouver la meilleure manière de rendre l'information digeste pour les experts et initiés de votre discipline académique ou pour le grand public. La visualisation graphique des données est donc centrale afin de vulgariser les résultats d'une recherche empirique.

L'objectif de ce chapitre est d'apprendre aux codeurs débutants les rudiments de la visualisation graphique en R. Ce chapitre présentera plus particulièrement les packages R *ggplot2* et *dplyr* eux-mêmes téléchargeable à partir du package *tidyverse*. Si *dplyr* permet de préparer les données avant leur visualisation, *ggplot2* est un package dédié à la production de graphiques. Ce chapitre présente sa grammaire avec une série d'exemples (Wickham 2009; Wickham, Çetinkaya-Rundel, and Grolemund 2023).

Ce chapitre est plus technique que théorique et permet aux codeurs débutants d'en apprendre davantage sur la manière de construire des graphiques en R avec des données concrètes. La question centrale qui devrait vous

¹Université Laval

²Université de Montréal

8 Une image vaut mille mots

guider lorsque vous créez des visualisations est la suivante: **Comment optimiser l'intelligibilité des données?** L'objectif d'un graphique n'est pas seulement d'illustrer les données. Un bon graphique devrait permettre de vulgariser une information ou de mettre en saillance un aspect particulier des données. L'objectif communicationnel devrait toujours être gardé en tête. Les graphiques en exemple dans ce chapitre sont construits avec les données de l'Étude Électorale Canadienne de 2019 qui sont facilement téléchargeables sur leur site³.

La première section de ce chapitre expose les options et packages également disponibles pour la construction de graphiques en R. La deuxième section de ce chapitre compare les avantages et inconvénients de l'utilisation de *ggplot2* par rapport aux autres packages de visualisation de données qui auront été présentés. La troisième section de ce chapitre montre des exemples de graphiques construits avec la grammaire de *ggplot2* en utilisant les données de l'Étude électorale canadienne de 2019. Les codes employés pour produire les graphiques en exemple sont disponibles dans l'annexe de ce livre. Ces codes reproductibles permettront aux codeurs débutants d'adapter ces derniers pour leurs propres projets.

8.2 Réflexion théorique

8.2.1 Les options disponibles

De nombreux *packages* ont été développés dans le langage R dans le but de visualiser des données graphiquement, il devient donc facile de s'y perdre. Heureusement, les options qui s'offrent à nous se précisent lorsque l'on s'intéresse à ce qui est le plus utilisé dans la communauté des codeurs de ce langage de programmation. Les *packages* les plus utilisés représentent des outils qui ont été substantiellement validés et améliorés par leurs développeurs, mais aussi par une importante communauté de codeurs en

³<http://www.ces-eec.ca/>

8.2 Réflexion théorique

ligne et de chercheurs universitaires. Trois de ces options sont présentées dans ce chapitre: les graphiques du *Base R*, le *package Lattice* et le *package ggplot2*. Les avantages et inconvénients respectifs de ces trois approches pour la création de graphiques sont explicités dans les sections suivantes.

8.2.1.1 Avantages et inconvénients de Base R

Le *Base R* est le langage de base de R et il permet de faire de nombreuses manipulations statistiques sans avoir à installer de *packages* au préalable. Le *Base R* permet notamment de produire des graphiques rapidement. Cela peut être utile pour visualiser la distribution d'une variable ou pour regarder la relation entre deux d'entre elles, par exemple. Pour produire un graphique avec le langage de base R, il suffit de faire appel à la fonction *plot()*. Avec la fonction *plot()*, le codeur peut visualiser la distribution d'une variable seule en spécifiant l'axe des *x* dans cette dernière. Le codeur peut également visualiser la relation entre deux variables en spécifiant à l'intérieur de la fonction celles qui composeront les axes des *x* et des *y* du graphique. Les fonctions *barplot()*, *hist()* ou *boxplot()* disponibles dans le *Base R* permettent de spécifier le style de graphique souhaité, qu'on veuille représenter nos données sous forme de diagramme à barre, d'histogramme ou de diagramme en boîtes (Kabacoff 2022, 119–32).

```
# Exemple de graphique avec la fonction barplot() du BaseR

barplot(y,names.arg=x,
        main="Figure 1 - Proportion (%) de répondants par province\n",
        col = "blue",
        sub="\nSource: Étude Électorale Canadienne de 2019
```

Alors qu'un peu tout peut être fait avec le *Base R*, ce langage demeure élémentaire; il est difficile d'innover dans la visualisation ou même de produire des graphiques plus sophistiqués. Le *Base R* peut sembler plus simple pour l'exploration de données ou pour produire des graphiques de

8 Une image vaut mille mots

base rapidement, mais ce langage devient rapidement complexe lorsqu'on cherche à améliorer l'esthétique de son graphique ou à visualiser des relations entre plusieurs variables, ce que *lattice* et *ggplot2* permettent plus facilement(Wickham 2009, 3–4).

8.2.1.2 Avantages et inconvénients de *lattice*

Développé par Deepayan Sarkar, *lattice* cherche à faciliter la visualisation de graphique en facettes. Plus précisément, ce *package* vise à améliorer les graphiques du *Base R* en fournissant de meilleures options de graphisme par défaut pour visualiser des relations multivariées. Ce *package* est donc intéressant pour les chercheurs et les codeurs voulant présenter graphiquement la relation entre plus de deux variables (Kabacoff 2022, 373–77; Sarkar 2008, 2023). Pour produire un graphique de base avec *Lattice*, le *package* *lattice* doit préalablement être installé dans la bibliothèque de *packages* du codeur et chargé dans sa session au début de son code (voir annexe). Par la suite, le codeur doit spécifier le type de graphique souhaité avec la fonction appropriée⁴. Une fois la fonction choisie, il doit spécifier par une formule les variables x et y ainsi que la troisième variable à contrôler et à visualiser en facettes (*graph_type(formula / variable en facettes, data=)*).

Si la Figure 1 produite à partir du *Base R* nous permet de visualiser le pourcentage de répondants par province dans l'Étude Électorale Canadienne de 2019, le *package* *lattice* nous permet de visualiser facilement ce même pourcentage de répondants en tenant compte du positionnement idéologique des Canadiens par province sur l'échelle gauche-droite, comme l'illustre la Figure 2 (0 étant la gauche et 10 la droite).

```
# Exemple de graphique avec la fonction histogram() du package lattice
```

⁴Plusieurs options disponibles comme des histogrammes avec la fonction *histogram()* ou des graphiques de densité avec la fonction *densityplot()*.

8.2 Réflexion théorique

```
histogram(~gaucheDroite | province, data = GraphiqueLattice, breaks = seq(0, 10,
  by = 1),
  main = "Figure 2 - Distribution des Canadiens\n par province sur l'échelle gauche-droite",
  xlab = "\nIdéologie gauche-droite",
  ylab = "Pourcentage (%)\\n",
  col = "blue",
  sub="\nSource: Étude Électorale Canadienne de 2019
```

Cependant, le *package lattice* a pour désavantage d'avoir un modèle formel (une grammaire de graphique) moins compréhensible et intuitif que celui de *ggplot2* lorsque vient le temps d'améliorer l'esthétisme des graphiques. De plus, sa plus faible popularité fait en sorte que ce *package* demeure moins développé par la communauté de codeurs de R que ne l'est *ggplot2*. Nous examinons plus en détail la grammaire de graphique de ce dernier *package* ainsi que ses avantages et inconvénients dans la prochaine section (Kabacoff 2022, 373–77 et 390; Wickham 2009, 6).

8.2.1.3 Avantages et inconvénients de ggplot2

Développé principalement par Hadley Wickham, *ggplot2* est un *package R* faisant partie de la collection de *packages* de *tidyverse*. Ainsi, *Ggplot2* peut être utilisé avec les autres *packages* centraux de *tidyverse* ce qui limite de potentiels conflits entre les fonctions de *packages* qui puissent être incompatibles avec *ggplot2*. Par exemple, le *package dplyr* de *tidyverse* est très utile pour analyser, organiser et préparer vos données à visualiser avec *ggplot2* (Wickham et al. 2019; Wickham, Çetinkaya-Rundel, and Grolemund 2023, 30).

Le principal avantage de *ggplot2* reste sa grammaire qui permet à l'utilisateur de rendre ses graphiques beaucoup plus visuellement attrayants en facilitant la personnalisation esthétique. Ceci permet de pousser l'esthétisme de vos graphiques à un très haut niveau par rapport aux autres *packages* de visualisation graphique disponibles en R. Les

8 Une image vaut mille mots

graphiques *ggplot2* se construisent couche par couche, soit par l'ajout des différents éléments du graphique au fur et à mesure dans le code du graphique à construire.

La première couche des graphiques *ggplot* est généralement celle des données et des variables à visualiser. Elle contient plusieurs éléments fondamentaux qui sont essentiels à chaque graphique. Le premier élément est la spécification de l'utilisation du package *ggplot2* qui se fait simplement en appelant la fonction *ggplot2()*. Dans cette fonction, il faut ensuite mentionner quelle est la base de données (*data=*) ainsi que la fonction qui sera utilisée pour positionner les données (*aes()*). Le positionnement le plus courant est de positionner des données *x* par rapport à des données *y*, ce qui se fait de la sorte: *aes(x=, y=)*.

La deuxième couche des graphiques *ggplot2* est celle du *geom*, qui spécifie le type de graphique souhaité. Les types de graphiques les plus couramment utilisés avec *ggplot2* sont les nuages de points (*geom_point()*), les diagrammes de lignes de tendances ou de séries chronologiques (*geom_line()*), les courbes de densité (*geom_density()*) ainsi que les graphiques à bandes (*geom_bar()*). Mais les possibilités sont infinies (ou presque!) avec ggplot2 et bien plus de types de graphiques existent.

Les autres couches des graphiques *ggplot2* dépendent souvent du codeur et des étapes de construction de son graphique⁵ (Wickham 2009, 77 et 89-93). Le reste de ce chapitre présente la grammaire de *ggplot2* avec un exemple de construction de graphique à bande présenté couche par couche.

⁵Les étapes (couches) d'un graphique *ggplot2* ne sont pas nécessairement dans le même ordre d'un graphique à un autre.

8.3 Réflexion méthodologique

8.3.1 Comment utiliser ggplot2

```
# Première couche de l'exemple de graphique  
# ggplot2 (base de données, variables et geom)  
  
ggplot(data=GraphiqueExemple, aes(x=province, y=prop)) +  
  geom_bar(stat="identity")
```

Tel que mentionné dans le dernier paragraphe, la première étape est de spécifier la base de données et les variables qu'on souhaite visualiser. Vous vous souviendrez qu'au début de la section, nous avons mentionné la collection *tidyverse*, et plus spécifiquement le package *dplyr* qui y est compris. Ce dernier a été utilisé pour nettoyer/calculer la proportion de répondants par province au préalable, ce qui nous permet de positionner directement la variable *prop* dans l'axe y.

8.3.2 Exemples et fonctionnalités

8.4 Trucs et astuces

8.5 Pour aller plus loin

8.6 Références

9 Baliser les sciences sociales : langages et pratiques

Lorsque vous lisez un article scientifique, une page Web ou un curriculum vitæ professionnel, vous vous doutez peut-être que le texte n'est pas toujours produit à l'aide d'un logiciel de traitement de texte comme Microsoft Word, Apple Pages ou LibreOffice Writer. La mise en page complexe réglée au millimètre près, la qualité des figures et des tableaux, l'utilisation de gabarits professionnels, le style des références ou encore la présence d'éléments interactifs sont difficiles et parfois impossibles à reproduire à l'aide d'un logiciel de traitement de texte régulier. L'ajout d'extraits de code, de tableaux de régression ou encore de figures de haute qualité graphique, ainsi que leur personnalisation, nécessitent une interface particulière.

Pour ces raisons et plusieurs autres, les chercheurs en sciences sociales font souvent appel aux langages de balisage, ou *markup languages*. Ceux-ci permettent de produire des documents et pages Web sans les limitations des logiciels de traitement de texte. Le présent livre, par exemple, est écrit à l'aide du langage de balisage Markdown avec l'aide du système de publication Quarto. D'entrée de jeu, vous vous demandez peut-être quelle est l'utilité d'apprendre ces langages alors que les logiciels de traitement de texte sont nombreux, simples d'approche et en amélioration constante. Ce chapitre n'a pas pour objectif de décourager l'utilisation de ces logiciels, qui sont utiles et même souvent essentiels pour la production rapide de documents ainsi que pour des tâches de suivi des modifications et de travail avec des équipes multidisciplinaires. Le chapitre tentera plutôt de

montrer que de savoir utiliser les langages de balisage est un atout pour les équipes de recherche qui souhaitent élaborer des documents complexes et professionnels. Il s'agira de répondre, tour à tour, aux trois grandes questions suivantes : *Qu'est-ce qu'un langage de balisage?* *Quand et pourquoi utiliser un langage de balisage?* *Comment utiliser un langage de balisage?* L'accent sera mis sur Quarto ainsi que sur les langages Markdown et L^AT_EX, bien que d'autres langages soient aussi abordés.

9.1 Qu'est-ce qu'un langage de balisage?

Un langage de balisage constitue un ensemble de commandes qui peuvent être entremêlées à du texte afin de produire une action informatique. Chaque langage contient son propre ensemble de commandes cohérentes et complémentaires. De manière plus formelle, ces commandes sont nommées *balises* (*tags* en anglais) et inscrites par le chercheur ou la chercheuse au travers du texte. Les balises constituent une manière de communiquer avec le logiciel utilisé dans un langage qu'il peut comprendre. Par exemple, une balise permet d'indiquer au logiciel que vous désirez qu'une section du texte soit écrite en caractères gras, en italique, à double interligne ou encore que vous souhaitez positionner une image d'une certaine manière au travers du texte. Cette interaction est rendue possible par la standardisation des langages de balisage : chaque balise correspond à une action précise, peu importe le logiciel utilisé, la langue dans laquelle le texte est rédigé, le type d'ordinateur utilisé, etc. Dans votre document source, les balises sont entremêlées au contenu de votre document. Au moment de compiler ce dernier, les balises produisent les actions informatisées qu'elles commandent et laissent comme document final le contenu mis en page tel que vous l'avez défini via les balises utilisées. La compilation est le processus par lequel un document écrit en langage de balisage est transformé en fichier textuel, en format PDF dans le cas de L^AT_EX par exemple. La Figure ?? montre un exemple d'utilisation du langage de balisage Markdown dans un fichier Quarto sur la plateforme Visual Studio Code. L'écran à droite de l'image

9.1 Qu'est-ce qu'un langage de balisage?

montre le fichier PDF résultant du formatage réalisé dans la partie centrale de l'écran. Les balises utilisées sont décrites plus tard dans ce chapitre.




Figure 9.1: Exemple d'utilisation du langage de balisage Markdown dans un fichier Quarto sur la plateforme VS Code
Source : Auteurs du présent chapitre.

Le premier langage de balisage, le Generalized Markup Language (GML), a été inventé en 1969 par les chercheurs Charles F. Goldfarb, Ed Mosher et Ray Lorie pour la compagnie IBM. Goldfarb et ses collègues devaient intégrer trois applications créées avec des langages différents et avec une logique différente pour les besoins d'un bureau de droit. Même après avoir créé un programme qui permettait aux trois applications d'interagir, ces langages demeuraient différents et avaient chacun leur propre fonctionnement. Le développement de GML a permis de résoudre ce problème en standardisant et en structurant le langage : les mêmes commandes étaient utilisées pour accomplir les mêmes tâches dans chaque programme (Goldfarb 1996). GML

9 Baliser les sciences sociales : langages et pratiques

a été amélioré durant les décennies suivantes et a été suivi par d'autres langages de balisage, dont L^AT_EX (1985), BIBT_EX (1988), HTML (1993), XML (1998), Markdown (2004) et R Markdown (2012) (Encyclopaedia Britannica 2023; Hameed 2023; Markdown Guide 2023; World Wide Web Consortium (W3C) 1998; Xie 2023).

Les langages de balisage permettent d'effectuer différentes tâches. HTML, qui est sans doute le plus connu des langages de balisage, permet de formater des sites Web. XML, quant à lui, permet de structurer de larges volumes de données. L^AT_EX permet pour sa part de formater du texte et de créer des documents en format PDF. Markdown permet également de créer des documents en format PDF, mais aussi en format HTML ou DOCX — format utilisé pour les documents Word —, contrairement à L^AT_EX. R Markdown permet d'ajouter des extraits de code R à un fichier en langage Markdown. Enfin, depuis 2022, le système de publication scientifique et technique multilingue Quarto permet de créer des documents qui intègrent des extraits de code R, L^AT_EX, Python, Julia ou JavaScript, créés dans différents types d'environnements, à un fichier en langage Markdown (Allaire 2022). L^AT_EX, Markdown, R Markdown et Quarto permettent aussi d'intégrer les références bibliographiques du système de traitement de références BIBT_EX. Les langages de balisage communiquent ainsi souvent les uns avec les autres au sein d'un même fichier. Le chapitre 6 explique la manière de citer les références en langage BIBT_EX par le biais de Zotero et de Better BIBT_EX.

Les balises constituent une manière de donner manuellement des commandes au logiciel que vous utilisez. Si vous utilisez Microsoft Word, vous avez accès à une panoplie de boutons qui vous permettent de formater votre texte. Les balises exercent les mêmes fonctions de formatage pour les fichiers produits en L^AT_EX ou en Markdown, mais doivent être ajoutées à l'écrit par l'utilisateur. Lorsque vous appuyez sur un bouton ou utilisez une commande comme Ctrl-G ou Cmd-I dans Word, en réalité, cette commande ajoute des balises au travers de votre texte, mais rend celles-ci invisibles dans l'interface que vous utilisez. Cela permet d'avoir un texte élégant et facile à lire, mais comporte aussi plusieurs inconvénients. Le principal inconvénient est de limiter le pouvoir que vous avez sur le formatage de votre

9.1 Qu'est-ce qu'un langage de balisage?

texte. En effet, si les boutons à votre disposition ne vous permettent pas de réaliser une opération, celle-ci sera éternellement impossible à réaliser pour vous. A contrario, les langages de balisage permettent un contrôle presque infini sur les opérations que vous souhaitez réaliser. Incidemment, dans la mesure où vous utilisez le langage approprié pour la tâche que vous souhaitez accomplir, vous devriez être capable de donner exactement la commande nécessaire à votre logiciel. Les langages de balisage, bien qu'ils aient un coût d'apprentissage qui peut s'avérer important et que l'interface de travail soit moins intuitive qu'un document Word, vous offrent une plus grande flexibilité.

Afin d'utiliser un langage de balisage, il est impératif que le logiciel que vous utilisez puisse prendre en compte ce langage. Un logiciel permet rarement d'utiliser n'importe quel langage. Par exemple, le logiciel TEXShop permet seulement d'utiliser le langage LATEX. Il est aussi impératif de bien utiliser le langage de balisage. En effet, comme pour les langages de programmation, les langages de balisage ne peuvent pas déduire ce que vous souhaitez leur faire comprendre. Si vous souhaitez mettre du texte en gras, vous devez utiliser les bonnes balises. La moindre erreur peut être coûteuse, puisqu'une erreur dans la balise que vous utilisez risque de produire une commande incompréhensible et un message d'erreur, le logiciel ne réussissant pas à associer votre balise mal inscrite à une action informatisée. Conséquemment, il est impératif de bien vérifier les balises utilisées afin d'éviter toute erreur qui empêcherait votre document d'être compilé, c'est-à-dire d'être traduit dans son format final¹. Chaque caractère dans une balise est important et il y a rarement plus d'une seule manière de commander une action. Par exemple, en LATEX, il n'y a qu'une seule manière de mettre du texte en gras. Il faut précisément utiliser cette commande: `\textbf{}`. Le positionnement des balises est lui aussi critique : il délimite la portion de texte à laquelle doit être appliquée l'action commandée par la balise.

¹Les logiciels permettent plus ou moins efficacement d'identifier les balises problématiques. Certains ne produisent qu'un message d'erreur sans donner d'indication sur la source du problème, alors que d'autres ciblent très spécifiquement la ligne de syntaxe où se situe la balise problématique.

9 Baliser les sciences sociales : langages et pratiques

Il est important de distinguer les langages de balisage des langages de programmation, qui sont abordés plus en détail dans le chapitre 4. En effet, ceux-ci sont similaires à certains égards, mais ont des vocations différentes. Les deux s'appuient sur un langage informatisé, mais les langages et leurs objectifs diffèrent. Un langage de programmation définit des processus informatisés alors qu'un langage de balisage permet d'encoder du contenu de manière à ce que celui-ci soit lisible tant pour l'humain que pour son ordinateur.

Dans le contexte de la recherche en sciences sociales, la programmation est généralement utilisée afin de récolter, d'analyser et de présenter visuellement des données. Une fois cartes, tableaux et graphiques produits, ceux-ci peuvent être enregistrés — par exemple en format PDF ou PNG — et inclus au sein d'un document qui sera formaté en utilisant un langage de balisage. En R Markdown et en Quarto, des extraits de langage de programmation peuvent être inclus dans des sections bien délimitées de documents écrits en langage de balisage. Plus généralement, le langage de programmation contribue à l'analyse alors que le langage de balisage est essentiellement utile afin de présenter les travaux de recherche, que ce soit dans un document écrit ou sur un site Web. C'est principalement de cette manière que sont utilisés les langages de programmation et de balisage dans le cadre de la recherche en sciences sociales.

9.2 Comment utiliser un langage de balisage?

En pratique, comment utilise-t-on Markdown, L^AT_EX et BIBT_EX? D'emblée, L^AT_EX a une syntaxe particulière qui demande un certain temps d'adaptation. Pour écrire une phrase simple comme celle-ci, la phrase peut être écrite telle quelle. Par contre, pour mettre un **mot** en caractères gras, il faut utiliser la balise suivante: `\textbf{mot}`. Pour mettre le **mot** en rouge, la balise est `\textcolor{red}{mot}`. Pour le mettre en italique et

9.2 Comment utiliser un langage de balisage?

en note de bas de page², les balises `\footnote{\emph{mot}}` peuvent être utilisées. Ainsi, des balises peuvent contenir d'autres balises. En langage LATEX, une balise commence toujours par une barre oblique inversée. Par la suite, le nom de la fonction — *emph*, *textbf*, *textcolor*, etc. — est appelé. Enfin, généralement, le mot à formater est placé entre accolades `({})`.

Chaque document LATEX commence par un préambule. Celui-ci présente des informations telles que la taille des caractères, le type de document, le format de mise en page, la police de caractères, l'utilisation d'en-têtes et de pieds de page, ainsi que l'utilisation de *packages* LATEX permettant différentes fonctionnalités de personnalisation du document. Il n'est pas nécessaire ni souhaitable d'apprendre l'ensemble des fonctions et des *packages* LATEX qui existent. Au contraire, il est souvent mieux de commencer par un gabarit de document qui convient au type de document que vous voulez créer et ensuite de rechercher en anglais sur Stack Overflow la manière d'ajouter des éléments de formatage que vous ne connaissez pas, par exemple en recherchant `highlight latex text`.

Markdown fonctionne de manière similaire à LATEX, mais se démarque par sa plus grande flexibilité et sa syntaxe beaucoup plus légère. Par contre, il nécessite parfois l'utilisation de balises LATEX afin de réaliser certaines tâches, comme changer la couleur du texte. Tout document Markdown débute avec un court bloc de syntaxe YAML (acronyme de *Yet Another Markup Language*) qui définit les paramètres généraux du document. Voici un bloc YAML typique pour un document Quarto :

```
---
```

```
title: "Baliser les sciences sociales"
subtitle: "Langages et pratiques"
date: today
author:
  - Alexandre Fortier-Chouinard^ [University of Toronto]
  - Maxime Blanchard^ [McGill University]
```

²*mot*

9 Baliser les sciences sociales : langages et pratiques

```
- Étienne Proulx^ [McGill University]
format: pdf
toc: true
date-format: "MMM D, YYYY"
bibliography: references.bib
---
```

Outre le titre, le sous-titre et le nom des auteurs, on trouve aussi dans l'en-tête YAML la présence d'une table des matières (`toc`), la date et son format, le format du document compilé — dans ce cas-ci, PDF — ainsi que le chemin d'arborescence afin d'accéder au document `BIBTEX` où sont enregistrées les références utilisées. Il est aussi possible d'y définir la taille de la police de caractères ou encore le gabarit Word servant à définir le format d'un document `DOCX` à produire. De manière particulièrement importante, c'est l'endroit où sont chargés les *packages* `LATEX` qui seront utilisés. En effet, la majorité des *packages* et fonctions `LATEX` sont utilisables dans Markdown, alors que l'inverse n'est pas vrai. Il est donc possible de personnaliser un document Markdown en utilisant des *packages* ayant été créés pour `LATEX`.

La syntaxe à utiliser au travers du texte est somme toute plutôt simple. Pour mettre un ou plusieurs **mots en gras**, il suffit de les entourer de deux astérisques (****mots en gras****); pour les mettre *en italique*, il faut les encadrer d'une seule astérisque (***en italique***). Pour définir un titre de section ou de sous-section, il suffit de mettre des # devant le titre en question. Plus vous ajoutez de #, plus le titre sera petit et plus il sera considéré à un niveau hiérarchique inférieur dans la structure du texte. La syntaxe Markdown est donc plus légère que celle de `LATEX`, dans le but d'en rendre la lecture plus simple pour les utilisateurs et utilisatrices.

Bien que des gabarits Markdown soient disponibles, ceux-ci sont plus rares. Ils se trouvent pour la plupart sur GitHub et sont rendus disponibles par leur créateur. Cela étant dit, leur personnalisation peut s'avérer plutôt complexe. En somme, Markdown est particulièrement pratique pour les

9.2 Comment utiliser un langage de balisage?

documents ne nécessitant pas de respecter un gabarit précis et requérant simplement un document d'allure simple et professionnelle.

Pour sa part, BIBTEX a une syntaxe relativement simple. D'emblée, les références BIBTEX pour des articles et ouvrages scientifiques sont disponibles sur Google Scholar. Toutefois, pour citer des sites Web ou des articles de médias, la référence doit être écrite à la main selon un format précis. Une bibliographie sur BIBTEX peut ressembler à ceci :

```
@book{darwin03,
    address = {London},
    author = {Darwin, Charles},
    publisher = {John Murray},
    title = {{On the Origin of Species by Means of Natural Selection
or the Preservation of Favoured Races in the Struggle for Life}},
    year = {1859}
}

@article{goldfarb96,
    title={The Roots of SGML: A Personal Recollection},
    author={Goldfarb, Charles F},
    journal={Technical communication},
    volume={46},
    number={1},
    pages={75},
    year={1999},
    publisher={Society for Technical Communication}
}
```

Un fichier BIBTEX ne contient rien de plus qu'une série de publications commençant chacune par la balise @ suivie du type d'article — *article*, *book* pour un livre, *incollection* pour un chapitre de livre, *inproceedings* pour une présentation dans une conférence, *unpublished* pour un article non publié et *online* pour un site Web sont parmi les plus connus — et des informations

sur la publication mises entre accolades. La première information entre accolades est le code de la référence, par exemple `\cite{goldfarb96}`. Dans le fichier `LATEX`, l'auteur doit écrire `\cite{goldfarb96}` pour voir dans le document PDF compilé Goldfarb (1996); le lien est automatiquement cliquable et renvoie à la notice bibliographique correspondante. L'ordre des publications dans le document `BIBTEX` a peu d'importance, puisque `LATEX` réordonne par défaut la bibliographie en ordre alphabétique.

9.2.1 Environnements d'édition et de compilation

Contrairement à Microsoft Word et Apple Pages, il existe plusieurs options d'environnements d'édition et de compilation spécifiques à chaque langage. Ces environnements sont des plateformes et des logiciels conçus pour faciliter l'édition, la mise en forme et la compilation de documents dans des langages de balisage tels que `LATEX` et `Markdown`. Ils permettent également de rendre plus efficace et conviviale la production de documents tout en fournissant des fonctionnalités spécifiques aux besoins de chaque langage. Il existe une grande diversité d'environnements d'édition et de compilation, et le choix est libre pour la chercheuse ou le chercheur de trouver celui qui convient le mieux à ses besoins ou aux besoins de son groupe de recherche. Les trois options discutées ici sont parmi les plus utilisées par les chercheurs en sciences sociales et peuvent être regroupées en deux catégories : les logiciels de bureau et les éditeurs en ligne.

D'abord, il existe plusieurs logiciels de bureau qui offrent un environnement d'édition et/ou de compilation pour les langages de balisage. Ces logiciels fournissent les programmes principaux, les extensions essentielles et des outils complémentaires de compilation et de visualisation afin de permettre la production de documents écrits en langages de balisage. Le logiciel RStudio, également abordé dans le chapitre 4, permet de produire des documents avec différents langages de balisage et programmation, ainsi que de naviguer entre eux, à partir d'une même fenêtre. Il suffit d'installer certains *packages* contenant les fichiers nécessaires à l'utilisation

9.2 Comment utiliser un langage de balisage?

des langages de balisage. Par exemple, il est possible de produire des documents en L^AT_EX en utilisant le code suivant dans la console pour installer le *package* nécessaire à l'utilisation de la distribution L^AT_EX TinyT_EX : `install.packages("tinytex")`. Suivant le même principe, il est possible de produire des documents en R Markdown sur RStudio en installant le *package* suivant : `install.packages("rmarkdown")`. Pour Quarto, le téléchargement se fait en ligne, directement à partir du site Web de Quarto (2023).

Pour l'écriture en L^AT_EX, il est également nécessaire d'installer l'une des nombreuses distributions en ligne afin de pouvoir compiler ces documents dans un environnement local. Il existe des distributions telles que MacT_EX pour Mac, MikT_EX pour Windows et plusieurs autres (Just 2013). Ces distributions se distinguent par les différents *packages* avec lesquelles elles sont compatibles.

Un autre environnement régulièrement utilisé pour travailler en langage de balisage est le logiciel de bureau VS Code. VS Code prend en compte un plus grand nombre de langages de programmation et est utilisé par les programmeurs de tous domaines, tandis qu'RStudio est surtout utile pour les chercheurs en sciences sociales qui travaillent surtout en R.

Lorsque vient le temps de collaborer à plusieurs sur un document écrit en Markdown ou en L^AT_EX, les logiciels de bureau évoqués précédemment nécessitent l'utilisation de GitHub et de Git. L'utilisation de ces éditeurs peut présenter un défi supplémentaire pour les équipes de recherche non initiées. Il existe ainsi des éditeurs en ligne qui permettent de collaborer en temps réel sans passer par Git et GitHub, de manière similaire à Google Docs³. Le plus connu de ces logiciels est Overleaf, qui permet de produire des documents en langage L^AT_EX. Puisqu'Overleaf permet d'avoir accès à ses documents L^AT_EX à partir de n'importe quel navigateur, il n'y a pas de dépendance à un logiciel local sur un ordinateur, ce qui constitue un avantage important. La contrepartie de cet avantage est qu'en utilisant

³VS Code possède également une extension, Live Share, qui permet de travailler en temps réel sur un même document.

Overleaf, l'équipe de recherche est dépendante d'une connexion à Internet. En utilisant le package `LATEX rmarkdown`, Overleaf peut également inclure du code Markdown. Cependant, Overleaf ne permet pas de créer des documents en format DOCX ou HTML, ce qui constitue une limite de l'application. Overleaf comporte un compteur de mots intégré, ce qui n'est pas le cas des autres logiciels et environnements présentés plus haut.

9.3 Quand et pourquoi utiliser un langage de balisage?

La plupart des langages de balisage permettent de remplir l'une des deux fonctions suivantes, qui sont particulièrement importantes dans le contexte de la recherche en sciences sociales : produire des documents écrits et formater des pages Web. Dans les deux cas, ces actions peuvent être réalisées à partir de logiciels simples, mais ces logiciels ont des limites importantes auxquelles les langages de balisage apportent des solutions⁴.

Pour l'écriture de documents très simples comme une liste d'épicerie ou des notes rapides pendant une conférence, les logiciels de traitement de texte sont tout à fait convenables : ils sont simples et rapides à utiliser, un formatage professionnel du document n'est pas de mise. Utiliser un langage de balisage pour des tâches de base peut en effet rendre la tâche inutilement longue et complexe. Toutefois, plus la complexité d'un document augmente, plus il devient difficile d'obtenir un résultat satisfaisant en utilisant un logiciel de traitement de texte tel que Word, Pages ou Writer. A contrario, `LATEX` permet de produire des documents de tous les niveaux de complexité, tel que démontré sur la Figure ???. Quant à Markdown, sa courbe d'apprentissage se situerait logiquement entre celles de `LATEX` et

⁴Les langages de balisage permettent également de créer des pages Web. Bien que les pages Web puissent être créées à partir de sites Web comme WordPress, le langage HTML permet de produire des résultats plus *personnalisables*, plus *automatisables* et avec une plus *grande qualité graphique*. Cette question n'est pas abordée en détail dans ce chapitre.

9.3 Quand et pourquoi utiliser un langage de balisage?

de Word, puisque ses balises sont simplifiées. Plus généralement, utiliser un langage de balisage comme L^AT_EX ou Markdown⁵ comporte plusieurs avantages par rapport aux logiciels de traitement de texte traditionnels. Ces avantages font tous appel à un mélange de quatre concepts principaux : automatisation, personnalisation, flexibilité et qualité graphique.




Figure 9.2: Utilité relative de Word et de L^AT_EX selon la complexité et la taille du document

⁵Les avantages et désavantages de Markdown cités dans cette section s'appliquent également à Quarto et à R Markdown, puisque ces derniers font appel au langage Markdown.
Source : Yannick Dufresne (2015).

9.3.1 Avantages

9.3.1.1 Référencement

Premièrement, L^AT_EX et Markdown permettent d'intégrer une bibliographie *automatique* et professionnelle en utilisant BIBT_EX. Cette bibliographie peut être adaptée très facilement en différents styles bibliographiques reconnus ou en un style bibliographique *personnalisé* à partir d'un des nombreux gabarits professionnels disponibles. Avec BIBT_EX, il n'y a pas à vérifier si le titre de l'article est toujours en italique, si le numéro de volume est toujours entre parenthèses ou si le nom de famille des deuxièmes auteurs est toujours avant ou après le prénom puisque toutes ces opérations sont effectuées de manière *automatique*. BIBT_EX comprend également les différences entre les types de sources — articles scientifiques, livres, sites Internet, etc. — et ajuste leur présentation en conséquence. De plus, si une des sources que vous citez n'est pas incluse dans la bibliographie, une erreur s'affiche, vous permettant d'identifier le problème plutôt que de vous retrouver avec une référence manquante. À l'inverse, si une source est retirée du texte, elle disparaît *automatiquement* de la bibliographie dans le document final mais demeure présente dans le fichier où se trouvent les références bibliographiques. Cela évite les aller-retour pour vérifier que chaque source de la bibliographie se trouve au moins une fois dans le texte et que chaque source dans le texte est citée en bibliographie. Grâce aux balises, en cliquant sur les références incluses dans le document, vous vous retrouverez immédiatement plus loin dans le document, à l'endroit où se trouve l'entrée bibliographique associée. Les références BIBT_EX pour articles scientifiques peuvent être copiées-collées à partir de Google Scholar. BIBT_EX rend donc extrêmement simple et efficace l'utilisation des références bibliographiques grâce à sa capacité à *personnaliser* et *automatiser* leur présentation⁶.

⁶L'utilisation d'un logiciel de traitement de texte, en particulier lorsque combiné avec une extension Zotero, peut également produire un résultat automatisé et personnalisé à un certain degré. Cependant, au moment où ce chapitre est écrit, le retrait d'une citation du texte principal en Word avec Zotero n'enlève pas immédiatement cette

9.3 Quand et pourquoi utiliser un langage de balisage?

9.3.1.2 Figures et tableaux

L'intégration de figures et de tableaux dans le texte est aussi rendue très simple et professionnelle grâce à L^AT_EX et à Markdown. La taille de la figure ou du tableau, son positionnement et son intégration par rapport au texte environnant peuvent être réglés avec précision. Cependant, l'ajout de texte avant ou après la figure ou le tableau ne produira pas des résultats inattendus tels qu'une demi-page vide avant un graphique ou un titre de tableau complètement en bas d'une page. En définissant des paramètres pour l'ensemble du texte, la chercheuse ou le chercheur peut *personnaliser* entièrement la présentation des figures et des tableaux. De plus, la *qualité des figures et des tableaux* ne diminue pas lors de leur intégration : les figures restent aussi belles qu'elles l'étaient originellement, ce qui n'est pas toujours le cas dans les logiciels de traitement de texte. Les figures et les tableaux sont aussi numérotés *automatiquement*, ce qui veut dire que vous n'aurez jamais à vous préoccuper de modifier les numéros si l'ordre des figures et tableaux est modifié dans le texte. Grâce aux balises, en cliquant sur le numéro associé à la figure ou au tableau dans le texte, le document se retrouve automatiquement à l'endroit où se trouve la figure ou le tableau. De plus, les figures peuvent être intégrées en format PDF, ce qui permet au lecteur de copier-coller ou de surligner de l'information se trouvant sur le graphique directement, incluant les titres des axes et les annotations.

Surtout, l'intégration de graphiques produits par R au texte en langage de balisage est simplifiée et *automatisée*. En effet, même lorsque les données ou le code pour produire un graphique changent, R resauvegarde le fichier dans le même chemin d'arborescence (*path*) particulier que vous avez indiqué, par exemple C:/Users/Jean/Dropbox/projet1/graphs/Figure1.pdf. Le langage de balisage peut ensuite indiquer le même chemin d'arborescence, de sorte qu'il n'est pas nécessaire de recopier-coller la figure à l'intérieur

citation de la bibliographie, et l'ajout de liens vers la bibliographie doit se faire source par source, ce qui prend un temps important et peut occasionner des erreurs humaines.

9 Baliser les sciences sociales : langages et pratiques

du document chaque fois que des changements y sont apportés; la figure est mise à jour *automatiquement*.

L'intégration de figures et de tableaux est particulièrement simple et *flexible* avec Quarto. Contrairement à L^AT_EX, qui nécessite la production de tableaux et de figures dans un document en langage de programmation (comme R), Quarto permet de créer une figure grâce à du code R *et* d'intégrer celle-ci au texte dans un même document. Cela se fait grâce à l'intégration de blocs de code R (*code chunks*) dans le document. Le code est produit dans le bloc de code et la figure ou le tableau qui en résulte apparaît à la fois dans le document Quarto, où des balises supplémentaires permettent d'adapter le formatage, et sur le document fini. Cependant, certains *packages* R permettent de créer des tableaux de régression de grande qualité en format L^AT_EX. Les tableaux de régression en format Markdown sont pour l'instant plus difficiles à produire au-delà d'un certain niveau de complexité, en raison des limitations du langage Markdown. Il demeure possible de produire des tableaux en langage L^AT_EX dans un fichier Markdown ou Quarto.

9.3.1.3 Équations

L^AT_EX permet également d'ajouter des équations mathématiques poussées. En effet, il existe des balises pour chaque symbole mathématique, et celles-ci peuvent être agencées de manière à former des équations cohérentes. Ces équations peuvent être intégrées au sein même d'une phrase ou être mises de l'avant dans un paragraphe à part centré.

9.3.1.4 Table des matières et mise en page

Markdown et L^AT_EX permettent aussi la gestion *automatisée* de la table des matières, et les références aux pages appropriées à partir de la table des matières se mettent à jour en continu. La table des matières prend en compte l'architecture du texte choisie manuellement par le chercheur, qui est définie par des balises définissant différents niveaux hiérarchiques

9.3 Quand et pourquoi utiliser un langage de balisage?

de sections, sous-sections ou chapitres. Des manières *automatiques* de référencer les figures et les tableaux dans des sections distinctes de la table des matières sont également offertes, encore une fois *personnalisables* au goût du chercheur.

Bien que la mise en page de documents produits via Markdown et L^AT_EX puisse être définie entièrement manuellement par les personnes plus expérimentées, les novices apprécieront les nombreux gabarits (*templates*) qui permettent de gérer *automatiquement* la mise en page clés en main. Les gabarits permettent de rendre l'apparence d'un document plus esthétique et uniforme et peuvent être utilisés tels quels ou servir de point de départ pour un chercheur ou une chercheuse souhaitant y apporter certaines modifications sans toutefois partir d'une feuille blanche. La majorité des personnes qui utilisent ces langages, même les plus expérimentées, utilisent ces gabarits comme base lorsqu'elles rédigent un document. Ceux-ci constituent une mine d'or puisqu'ils rendent accessible le code Markdown ou L^AT_EX ayant servi à la conception du gabarit, permettant à la chercheuse ou au chercheur de comprendre comment est obtenu le résultat que lui offre le gabarit. Incidemment, il est possible d'identifier les sections de code produisant certains éléments de mise en page — positionnement des numéros de page, positionnement du nom des auteurs en début de document, etc. — et les modifier ou s'en inspirer afin de modifier d'autres gabarits. L'utilisation de ces gabarits peut s'avérer complexe au départ, mais il s'agit d'une complexité qui s'avère ultimement extrêmement productive puisqu'elle vous permettra de devenir autonome et d'ajuster les gabarits à votre convenance afin de produire exactement le résultat désiré en termes de mise en page. En comparaison, les logiciels de traitement de texte rendent souvent très ardue la mise en page uniforme d'un document, puisque cet élément ne peut pas être *automatisé*. La liste des gabarits disponibles est extrêmement large, et ceux-ci ont une variété de fonctions. En effet, une variété de gabarits professionnels et de haute *qualité graphique* sont offerts gratuitement en ligne pour des articles, des livres, des rapports, des *curriculum vitæs* Figure ?? ou encore des feuilles de temps pour des contrats rémunérés Figure ??.

9 Baliser les sciences sociales : langages et pratiques



Figure 9.3: Exemple de gabarit L^AT_EX de curriculum vitae
@liantze23 : .

9.3 Quand et pourquoi utiliser un langage de balisage?



Figure 9.4: Exemple de gabarit L^AT_EX de feuille de temps
`@roux13` : .

Les Figure ?? et Figure ?? ne sont que quelques exemples des milliers de gabarits de documents L^AT_EX disponible en ligne. Plusieurs d'entre eux peuvent être téléchargés à partir du site Web d'([overleaf23?](#)). Vous pouvez y naviguer et voir quel gabarit convient le mieux à vos besoins. Certaines manières plutôt spécifiques de formater le texte sont présentement disponibles avec L^AT_EX ou Markdown bien que non disponibles en Word, ce qui constitue une autre preuve de leur grande *flexibilité* et capacité de *personnalisation*. Bien qu'il soit rare que nous ayons absolument besoin de personnaliser le texte ainsi, ces possibilités peuvent s'avérer utiles lorsque vous rédigez un texte qui doit se conformer en tout point à un gabarit spécifique. En effet, certaines revues scientifiques, maisons d'édition et universités, dans le cadre de la rédaction d'articles, de mémoires et de thèses par exemple, imposent ce type de gabarit inflexible et parfois plutôt capricieux.

9.3.1.5 Compatibilité entre types de documents

Un autre avantage non négligeable de Markdown — qui le distingue à cet égard de L^AT_EX — est la *flexibilité* des formats de documents qui peuvent être produits. En effet, Pandoc Markdown, une extension du langage Markdown de base, permet d'intégrer dans un seul document plusieurs langages de balisage différents tels que Markdown, L^AT_EX et HTML. Quarto utilise Pandoc Markdown et est également habilité à travailler avec des extraits de code R ou Python. Ceci permet donc à l'utilisateur ou à l'utilisatrice de bénéficier des fonctionnalités de différents langages dans un seul document, rendant ainsi possible une variété de *personnalisations* qui ne seraient pas possibles autrement. Qui plus est, puisque Markdown permet de créer des fichiers Word réguliers, PDF professionnels et HTML à partir d'un même document, vous pouvez choisir à votre convenance et à tout moment de quelle manière sera compilé le document rédigé. Cette possibilité de créer des documents Word est particulièrement pratique dans le cadre de collaboration avec des chercheuses et chercheurs n'utilisant pas les langages de balisage ainsi que lors de l'envoi de manuscrits à des revues scientifiques, puisque certaines d'entre elles exigent de recevoir ceux-ci sous forme de document Word.

9.3.1.6 Popularité

La popularité de certains langages de balisage dans le monde de la recherche confère un avantage considérable à celles et ceux qui savent les utiliser. La maîtrise de ces langages offre aux chercheurs et chercheuses une polyvalence lorsqu'ils doivent collaborer avec diverses équipes de recherche utilisant différentes méthodes de travail. Par exemple, depuis sa création L^AT_EX a été adopté largement par le milieu de la publication de travaux scientifiques (Gaudeul 2007). À titre indicatif, le logiciel Overleaf était utilisé en 2022 par 11 millions d'utilisateurs et utilisatrices dans 189 pays autour du globe. Plus de 2000 compagnies et 6800 universités utilisent Overleaf pour écrire en L^AT_EX (“Wow! Ten Million Users!” n.d.). La popularité des langages

9.3 Quand et pourquoi utiliser un langage de balisage?

de balisages en fait donc un outil difficile à contourner pour une personne qui voudrait poursuivre une carrière en recherche académique. L'avantage ci-bas sur la gestion des embûches illustre également comment la popularité permet une meilleure gestion de celles-ci.

9.3.1.7 Gestion des embûches

Bien que l'apprentissage de \LaTeX et de Markdown puisse être parsemé de nombreuses embûches, ces deux langages bénéficient d'une communauté d'utilisateurs et d'utilisatrices en ligne sur laquelle il est possible de s'appuyer afin de résoudre tout problème rencontré. Ces individus — particulièrement les plus expérimentés — sont nombreux à partager leur expérience à leurs collègues rencontrant des problèmes afin de contribuer à régler ceux-ci. Cette communauté est présente sur une multitude de sites Web, bien que le point de rencontre principal soit le forum Stack Overflow (2023), qui est également utilisé pour régler des problèmes de programmation et est abordé plus en détail dans le chapitre 4. Une simple recherche sur Google d'un problème rencontré avec \LaTeX ou Markdown vous offrira des liens vers des échanges pertinents ayant eu lieu sur Stack Overflow ou encore vers de la documentation technique. Vous pourrez donc filtrer les résultats et observer les nombreuses solutions envisageables à votre problème afin de définir laquelle est la plus appropriée dans votre situation. Il est important de noter, toutefois, que cette communauté est nettement plus développée pour les utilisateurs de \LaTeX que de Markdown, puisque ce dernier langage est moins répandu que le premier.

Également, avec l'émergence de l'intelligence artificielle (IA), de nombreux modèles d'IA génératifs commencent à émerger comme des ressources d'aides utiles pour les chercheuses et les chercheurs. Au moment de la rédaction du présent chapitre, le *chatbot ChatGPT*, développé par OpenAI et basé sur le grand modèle de langage (*large language model*, LLM) GPT-3.5, est une ressource d'aide en émergence en ce qui a trait aux langages de balisage. Le corpus de données sur lequel il a été formé inclut

9 Baliser les sciences sociales : langages et pratiques

une grande variété de langages et de styles d’écriture, incluant L^AT_EX et Markdown. Ainsi, il est possible de poser des questions en langage courant à ce *chatbot* lorsque des problèmes de balisage sont rencontrés. Celui-ci fournira en réponse le texte avec les balises adéquates pour régler le problème. Cela s’applique même pour des problèmes pour lesquels la réponse n’est pas directement indiquée sur Stack Overflow, lorsque la logique des langages est comprise par ces modèles basés sur l’IA. ChatGPT est toutefois plus outillé en L^AT_EX qu’en Markdown ou en Quarto en raison de la plus grande abondance de ressources en L^AT_EX disponibles en ligne, bien que ses capacités soient en constante amélioration. Il arrive cependant régulièrement que les réponses des modèles de langage comme ChatGPT soit erronées — tout comme certaines réponses sur Stack Overflow peuvent ne pas être adaptées à régler un problème similaire vécu sur un autre ordinateur, avec des paramètres différents. Il demeure donc important de vérifier les réponses des modèles basés sur l’IA afin de ne pas avoir de mauvaises surprises lors de la compilation du code. Ainsi, il est utile de s’appuyer autant sur la communauté d’utilisatrices et d’utilisateurs de langages de balisage qui échange des ressources en ligne que sur les modèles de langage basés sur l’IA.

9.3.2 Philosophie du code source ouvert et du logiciel libre

L’utilisation des langages de balisage s’inscrit bien dans la philosophie du logiciel libre. Le langage L^AT_EX est distribué sous la license *L^AT_EX project public license* (LPPL), alors que Quarto 1.4 est distribué sous la license du Massachusetts Institute of Technology (MIT). Moyennant le respect de leurs licenses respectives, ces licenses permettent ainsi aux utilisateurs de L^AT_EX et de Quarto d’utiliser ces langages comme ils le souhaitent, de redistribuer des copies, de modifier le fonctionnement de ces langages et d’en redistribuer des versions améliorées. Bien que L^AT_EX et Quarto ne soient pas des logiciels, leur license utilisation est cohérente avec la philosophie du logiciel libre et permet à ces langages d’être utilisés dans de nombreux logiciels.

9.3 Quand et pourquoi utiliser un langage de balisage?

D'autre part, L^AT_EX et Quarto sont deux langages à code source ouvert (*open source*). Ainsi, leur distribution est entièrement gratuite, il n'y a rien à payer. Leur code source est disponible et les changements à ce code doivent être indiqués. Les licences LPPL et MIT ne discriminent pas certains groupes ou personnes, et elles ne restreignent personne dans l'utilisation pour un domaine d'activité. Ces deux licences ne sont pas spécifiques pour un produit, ce qui signifie que ces deux langages peuvent être utilisés dans plusieurs logiciels et programmes. Elles sont également technologiquement neutres, rendant ainsi L^AT_EX et Quarto accessibles aux utilisateurs de tous les systèmes d'exploitation.

9.3.3 Inconvénients

Il existe toutefois des désavantages inhérents à l'utilisation des langages de balisage. L'un des principaux désavantages de Markdown et de L^AT_EX est le fait qu'ils ne comportent aucun système de suivi des modifications lors de travaux collaboratifs. Pour réviser un travail fait en langage de balisage, des commentaires peuvent être ajoutés sur le fichier sortant — nécessairement PDF pour un fichier sortant produit avec L^AT_EX. Des commentaires peuvent aussi être faits directement dans le document L^AT_EX ou Markdown, à l'aide de balises spécifiques. Ces commentaires n'apparaissent cependant pas dans le fichier sortant. Le suivi des modifications en L^AT_EX et Markdown nécessite donc souvent l'utilisation de Git et de GitHub, qui sont abordés plus en détail dans le chapitre 8. Même avec une plateforme de gestion des versions comme GitHub, les longs paragraphes ayant fait l'objet de plusieurs modifications peuvent être longs à comparer par rapport aux logiciels de traitement de texte, qui permettent de visualiser les propositions d'ajouts et de retraits de caractères de manière plus intuitive. Le suivi des modifications en logiciel de traitement de texte permet également de distinguer les auteurs de différents commentaires par leurs noms, alors que les ajouts et retraits itératifs en GitHub peuvent rendre difficile l'identification de l'auteur d'une modification. Pour ces raisons, et aussi pour faciliter la mise en page par les éditeurs, certaines revues scientifiques refusent les fichiers PDF et

9 Baliser les sciences sociales : langages et pratiques

demandent que les soumissions soient faites en format DOCX — ce qui pose problème pour les utilisateurs de L^AT_EX mais pas ceux de Markdown.

Les langages de balisage comportent également un autre désavantage important dans certains cas : l'absence d'un correcteur de fautes de français complet, en particulier pour corriger les fautes autres que celles d'orthographe en français. Parmi les principaux endroits permettant l'édition en langages de balisage, Visual Studio Code (VS Code) et Overleaf comprennent tous deux une extension LanguageTool, qui permet la révision orthographique et syntaxique dans plusieurs langues. VS Code possède également une extension Antidote pour les personnes qui paient déjà pour ce logiciel. D'autres extensions linguistiques existent également pour VS Code, de même que pour les logiciels de traitement de texte comme Word. Cependant, RStudio ne possède qu'un correcteur *orthographique* de base, disponible en plusieurs langues. Ce correcteur ne repère pas les erreurs de syntaxe, de grammaire ou de forme, entre autres. Ces éléments sont pourtant essentiels pour la rédaction de textes académiques⁷, d'autant plus que les utilisateurs de L^AT_EX ont tendance à faire davantage de fautes d'orthographe et de grammaire lors de la rédaction que les utilisateurs de Word (Knauff and Nejasmic 2014). Nous déconseillons ainsi l'utilisation de RStudio pour l'édition de fichiers L^AT_EX et Quarto, et nous encourageons fortement les utilisateurs d'Overleaf et de VS Code d'utiliser des extensions permettant la correction grammaticale telles que LanguageTool.

Enfin, les langages de balisage, contrairement aux logiciels de traitement de texte, nécessitent d'être compilés, ce qui implique que deux fichiers coexistent : le fichier où le langage de balisage est utilisé — format .tex pour L^AT_EX, .md pour Markdown ou encore .qmd pour Quarto — ainsi que

⁷Pour les utilisateurs de RStudio, il est souvent nécessaire de modifier le texte dans un logiciel de traitement de texte externe pour faire une révision linguistique complète, puis d'intégrer les corrections en collant le texte corrigé dans le document original en Markdown ou L^AT_EX. Une application de bureau Grammarly peut également être intégrée sur RStudio. Cette application repère les erreurs de syntaxe, mais ne corrige que l'anglais, et certains soucis de repérage des mots aux bons endroits dans le texte en rendent présentement l'utilisation difficile.

9.3 Quand et pourquoi utiliser un langage de balisage?

le fichier où le texte final balisé apparaît — généralement `.pdf`, `.docx` ou `.html`. La compilation peut prendre un temps variable selon la complexité du document, mais dure typiquement une quinzaine de secondes. Le fait de devoir travailler avec deux fichiers en parallèle et de ne pas voir immédiatement l'effet des balises sur le document final constitue ainsi un autre désavantage des langages de balisage.

`LATEX` comporte aussi quelques difficultés techniques particulières qui peuvent être réglées ou diminuées en travaillent en Markdown. Premièrement, `LATEX` est difficile à apprendre. Certaines tâches qui peuvent sembler simples comme l'ajout d'un tableau peuvent nécessiter de nombreuses lignes de code. De plus, à la moindre erreur de frappe dans l'utilisation d'une balise, le code risque de ne pas fonctionner et de ne pas produire le document PDF souhaité. C'est ce qu'on appelle une erreur de compilation. Markdown est un langage plus simple à apprendre, avec des balises plus courtes et intuitives. Il occasionne donc moins d'erreurs de compilation.

Deuxièmement, `LATEX` est peu compatible avec les logiciels de traitement de texte comme Word. Pour transférer un fichier créé à partir d'un logiciel de traitement de texte vers `LATEX`, les balises doivent être ajoutées manuellement une par une. À l'inverse, pour transférer un document `LATEX` vers un fichier de traitement de texte, le convertisseur Pandoc peut être utilisé, mais celui-ci ne repère pas toutes les balises et il est souvent nécessaire de faire des aller-retour entre le fichier `LATEX` original et le fichier converti en format DOCX pour s'assurer du succès de la conversion. Parfois, les balises doivent être retirées une par une et le formatage doit être refait en utilisant les boutons fournis sur le logiciel de traitement de texte. Il est aussi possible de copier le texte directement à partir du fichier PDF produit par `LATEX` vers un logiciel de traitement de texte, mais les fins de ligne sont interprétées par Word, Pages ou Writer comme des retours plutôt que des espaces, et les accents sont souvent mal copiés et doivent être réécrits manuellement. Encore une fois, Markdown évite ce problème en permettant d'écrire un fichier DOCX à partir du langage de balisage. Le formatage du fichier DOCX demeure un peu compliqué cependant et doit être fait à partir du modèle d'un autre document DOCX formaté tel que

9 Baliser les sciences sociales : langages et pratiques

souhaité. De plus, les fichiers DOCX ne peuvent pas être transformés en format Markdown. Quarto permet d'écrire un texte en format Markdown et de produire un fichier DOCX à partir d'un gabarit Word. De plus, pour les fichiers Word à transformer en format Markdown, les balises plus simples en Markdown qu'en L^AT_EX rendent la tâche plus simple.

Somme toute, Word n'est pas à antagoniser et demeure très utile pour des tâches simples. Cependant, dans le monde académique, la production de fichiers de qualité faisant appel à des graphiques, tableaux et blocs de code personnalisés de qualité et automatisés est simplifiée en utilisant des langages de balisage. Il n'est ainsi pas anodin que ces langages soient adoptés largement dans le monde académique. Pour ces raisons, il est avantageux pour une personne poursuivant une maîtrise en science sociale ou autre de passer outre la difficulté initiale d'apprentissage des langages de balisage. L'apprentissage de ces langages permettra de s'aligner sur les pratiques répandues dans le milieu académique et d'améliorer davantage la qualité de la production d'écrits scientifiques.

9.4 Conclusion

Tout compte fait, les langages de balisage permettent d'effectuer des tâches que vous ne pourriez pas normalement réaliser en utilisant un logiciel de traitement de texte classique. Ils facilitent la production de documents professionnels dans différents formats personnalisés, produits avec des processus automatisés, avec une grande qualité graphique. Les langages de balisage demandent un certain temps d'apprentissage, entre autres pour L^AT_EX, mais peuvent ensuite être utilisés dans différents environnements de travail en ligne comme hors ligne.

9.5 Références

10 Outils d'intelligence artificielle

Jozef Rivest, Laurence-Olivier Foisy, Hubert Cadieux

```
getwd()
```

```
[1] "/Users/jozefrivest/Documents/GitHub/livre-outils"
```

Ce chapitre vise à initier les lecteurs à ce qu'est l'intelligence artificielle (IA), aux enjeux qu'elle engendre ainsi qu'à son potentiel pour les sciences sociales. Nous souhaitons d'abord et avant tout mener les lecteurs vers la réflexion. Dans ces pages, il y a beaucoup plus de questions que de réponses. Cet état de fait reflète bien l'état de la connaissance que nous avons sur l'IA. Nous sommes aussi bien loin d'être des spécialistes en la matière. Malgré cela, nous pensons qu'initier la réflexion et la discussion s'impose. Se poser des questions et tenter de trouver des réponses ne peut que générer des bénéfices. Par conséquent, si ce chapitre aura permis d'éclairer certains enjeux, ou s'il stimulera davantage de questionnement, alors nous aurons réussi notre objectif.

Nous débutons par définir et expliquer ce qu'est l'intelligence artificielle. Bien que ça ne soit pas une tâche facile, nous souhaitons simplement donner une idée générale de ce qu'il s'agit. Ensuite, nous souhaitons mettre l'accent sur l'évolution constante de ce champ de recherche, ainsi que les défis que ça pose. La section suivante se penche sur certains enjeux éthiques lié à l'utilisation de l'IA, notamment en ce qui concerne le plagiat. Cela nous mène à se questionner sur la place du chercheur, aujourd'hui et dans le

futur, avec l'arrivée de ces nouvelles technologies. La dernière section se penchera sur la place de cette technologie en sciences sociales. Quel usage pourrait-on en faire, et surtout quels en sont les limites.

10.1 Définition et différents type d'IA

Qu'est-ce que l'intelligence artificielle (IA)? Est-ce quelque chose d'homogène, ou s'agit-il plutôt « des intelligences artificielles »? Dans un premier temps, il est important de préciser que l'intelligence artificielle est un champ d'études (Devedzic 2022). Par conséquent, il s'agit d'un ensemble d'objets, relativement vaste et en constante expansion, qui s'intéressent, à sa façon, à l'intelligence artificielle. Pour préciser ce propos, prenons l'exemple de la science politique. Malgré la formulation au singulier, la science politique est un grand ensemble de différents sous-champs d'études, qui ont chacun leur propre objet d'intérêt. La philosophie politique, les relations internationales, la politique comparée et l'étude de l'opinion publique, par exemple, sont tous des sous-champs qui s'intéressent, à leur façon, au phénomène politique. Dans le même sens, et compte tenu de cette pluralité de perspectives, il est important de noter qu'il n'y a pas de consensus dans la définition de l'IA (Wang 2019 ; König et al. 2022). De plus, la rapidité du développement de ce champ rend le traçage de frontières définitionnelles plutôt difficile : comment définir, d'une manière précise et consensuelle, quelque chose qui évolue constamment (Devedzic 2022 ; Bertolini 2020, 15)?

Deux définitions de l'IA peuvent tout de même être retenues. La première vient de John McCarthy (2007, 2) : « Il s'agit de la science et de l'ingénierie qui consistent à créer des machines intelligentes¹, en particulier des programmes informatiques intelligents. Elle est liée à la tâche similaire

¹Intelligence étant définie de la façon suivante : « L'intelligence est la partie informatique de la capacité à atteindre des objectifs dans le monde. On trouve différents types et degrés d'intelligence chez l'homme, chez de nombreux animaux et chez certaines machines. » (McCarthy 2007, 2)

10.1 Définition et différents type d'IA

consistant à utiliser des ordinateurs pour comprendre l'intelligence humaine, mais l'IA ne doit pas se limiter aux méthodes qui sont biologiquement observables. » [Traduction DeepL] La seconde définition provient de la compagnie IBM (2023a) : « Dans sa forme la plus simple, l'intelligence artificielle est un domaine qui combine l'informatique et des ensembles de données robustes pour permettre la résolution de problèmes. Elle englobe également les sous-domaines de l'apprentissage automatique et de l'apprentissage profond, qui sont souvent mentionnés en conjonction avec l'intelligence artificielle. Ces disciplines sont composées d'algorithmes d'IA qui cherchent à créer des systèmes experts qui font des prédictions ou des classifications basées sur des données d'entrée. » [Traduction DeepL] Ces extraits permettent de comprendre que l'IA consiste à reproduire artificiellement certaines capacités cognitives humaines, afin de rendre les machines « intelligentes » en leur donnant la capacité de résoudre des problèmes par elles-mêmes.

Ces définitions restent toutefois à préciser, notamment dans le champ d'application de l'IA : qu'en est-il concrètement ? Comment est-ce utilisé ? Comment ça fonctionne ? Si l'IA se distingue en plusieurs types, en faire la liste et identifier leurs différentes branches et applications possibles serait fastidieux et s'écarterait de l'objectif de ce chapitre introductif. Cependant, pour ceux désirant en savoir plus sur le sujet, les articles de McCarthy (2007) et de Hanchen et al. (2023), ainsi que le Cambridge Handbook of Artificial Intelligence (König et al. 2022) sont très riches et illustratifs sur ce qu'est l'IA ainsi que sur ses champs d'applications.

Avant toute chose, il est important de distinguer l'IA général (strong) du précis (narrow). Le premier, et le moins populaire en nombre de recherches et d'applications, cherche à développer une machine qui aurait les mêmes capacités cognitives que l'humain, non seulement en termes de résolution de problème, d'apprentissage et de planification, mais aussi qui serait dotée d'une conscience de soi (IBM 2023a ; König et al. 2022). Le deuxième est plus restrictif, se limitant à la réalisation d'un ou de plusieurs objectifs spécifiques. De ces deux visées, il y a trois principaux champs de recherche qui se penchent sur les méthodes de fonctionnement

10 Outils d'intelligence artificielle

de l'IA : l'apprentissage machine (machine learning), les réseaux neuronaux artificiel (artificial neural networks) ainsi que l'apprentissage profond (deep learning).

L'apprentissage machine : « [...] consiste à programmer des ordinateurs pour optimiser un critère de performance à l'aide de données d'exemple ou d'expériences passées. Nous avons un modèle défini jusqu'à certains paramètres, et l'apprentissage est l'exécution d'un programme informatique pour optimiser les paramètres du modèle à l'aide des données d'entraînement ou de l'expérience passée. » [Traduction DeepL] (Alpaydin et Bach 2014, 3). Le but est d'entraîner le modèle afin qu'il puisse reconnaître des tendances, et qu'il puisse décrire et/ou faire des prédictions à partir de ces tendances (Alpaydin and Bach 2014, 3). Il est le champ le plus populaire dans la recherche faite sur l'IA, notamment parce qu'il constitue une base importante pour les autres recherches dans le domaine (Devedzic 2022).

Ensuite, un sous-champ de l'apprentissage machine, l'apprentissage profond : « [...] fait référence à un réseau neuronal composé de plus de trois couches [...]. L'apprentissage en profondeur automatise une grande partie de l'extraction des caractéristiques, éliminant ainsi une partie de l'intervention humaine manuelle nécessaire et permettant l'utilisation d'ensembles de données plus importants. Il peut ingérer des données non structurées dans leur forme brute et déterminer automatiquement la hiérarchie des caractéristiques qui distinguent les différentes catégories de données les unes des autres, ne nécessitant pas d'intervention humaine. » [Traduction DeepL] (IBM 2023a). Ainsi, l'apprentissage profond permet une certaine forme d'automatisation des tâches demandées à l'IA, en lui fournissant les capacités nécessaires d'apprendre par lui-même pour corriger et améliorer son fonctionnement. Pour ce faire, on doit développer des structures neuronales artificielles, qui s'inspirent des neurones du cerveau humain.

C'est d'ailleurs la tâche de ceux qui s'intéressent aux réseaux neuronaux artificiels : « Les réseaux neuronaux artificiels (RNA) sont constitués d'une couche de nœuds, contenant une couche d'entrée, une ou plusieurs couches

10.2 L'évolution constante de l'IA

cachées et une couche de sortie. Chaque nœud, ou neurone artificiel, se connecte à un autre et possède un poids et un seuil associés. Si la sortie d'un nœud individuel est supérieure à la valeur seuil spécifiée, ce nœud est activé et envoie des données à la couche suivante du réseau. Dans le cas contraire, aucune donnée n'est transmise à la couche suivante du réseau. » [Traduction DeepL] (IBM 2023b). Ainsi, le but est de reproduire les structures cognitives humaines, afin de permettre à l'IA d'accomplir des tâches plus complexes. L'une des principales utilités de ce sous-champ est qu'il permet d'augmenter la rapidité du classement de données ; la reconnaissance vocale ou d'image, par exemple, ne prend que quelques minutes grâce à cela, contrairement à plusieurs heures lorsque fait par des humains (IBM 2023b).

10.2 L'évolution constante de l'IA

Plusieurs chercheurs, dont le professeur Yoshua Bengio de l'Université de Montréal, ont lancé plusieurs avertissements sur le développement de l'IA, notamment à cause de la rapidité de son évolution. Dans un article paru dans The Economist, M. Bengio (2023) nous dit qu'il prévoyait le développement d'une IA avec des capacités similaires à celles de l'humain d'ici quelques décennies, peut-être un siècle. Depuis l'arrivée de ChatGPT-4, celui-ci a revu sa prédiction pour la situer entre quelques années et quelques décennies (Bengio 2023). Dans les dix dernières années seulement, les systèmes de reconnaissance d'images et de langages en sont venus à dépasser les capacités humaines (Roser 2022). La figure 1 présente cette évolution.

10 Outils d'intelligence artificielle

Language and image recognition capabilities of AI systems have improved rapidly⁴




Figure 10.1: Évolution de l'IA depuis 1998

Comme on le remarque, cette évolution ne suit pas une trajectoire linéaire. Depuis 2015, la plupart de ces technologies ont évolué de manière quasi-exponentielle. Cette progression fulgurante nous permet de faire quelque constat pour appréhender l'évolution future. Ce qui est intéressant de la recherche dans ce domaine, c'est que le développement des capacités de l'IA permet, en retour, de la développer encore plus rapidement. L'IA peut rendre l'IA exponentiellement plus puissante (Harari 2023). Elle est capable de se faire évoluer à une vitesse plus grande, grâce à ses capacités de traitement de données et d'auto-améliorassions, que si elle était uniquement dépendante de l'humain.

En tant que chercheur en sciences sociales, pourquoi devrait-on être préoccupé par le développement de l'IA? Tout d'abord, il est intéressant de commencer à réfléchir ainsi qu'à analyser les différents impacts que l'IA a sur nos sociétés. Les avancés dans le domaine en plus de l'accessibilité à ces technologies, tel que Large Language Model (LLM), en font de nouveaux objets d'étude actuel, et surtout sans grandes réponses. Yuval Noah Harrari

10.3 Les différents outils de l'IA

(2023), historien et philosophe, explique dans un article que la capacité de l'IA à manipuler ainsi qu'à générer du langage en font des outils puissants qui ont le potentiel d'avoir de profond impact sur nos civilisations. Par conséquent, l'étude des effets de l'IA sur nos sociétés devient un nouveau sujet de recherche dont tous les champs des sciences sociales et sciences humaines ont intérêt à se pencher. Présentement, il est anticipé que cette technologie puisse être utilisée pour « générer et partager de fausses informations, érodant la confiance sociale et la démocratie; pour surveiller, manipuler et maîtriser les citoyens, nuisant aux libertés individuelles et collectives; ou pour créer de puissantes armes physiques ou digitales qui menaceraient la vie humaine. » [Traduction libre] (Bremmer and Suleyman 2023, 32). Compte tenu des conséquences potentielles que ces technologies peuvent avoir sur le monde social, tous les domaines scientifiques ont un fort incitatif à décloisonner leur savoir et leurs analyses, en plus de maximiser l'interdisciplinarité et la recherche collaborative. Une compréhension plus complète de ces changements ainsi qu'une communication de ce savoir ne pourra que générer des bénéfices pour le monde académique, social et politique.

10.3 Les différents outils de l'IA

Cette section vise à présenter différents outils de l'intelligence artificielle aux lecteurs. Ce qui est important de comprendre ici, et pour faire suite à la section précédente, c'est que les outils présenté ici risque d'avoir changé entre le moment d'écrire ce chapitre et le moment où les lecteurs liront le chapitre. Certaines fonctionnalités pourraient toujours être les mêmes, certaines pourraient avoir été améliorées et d'autres pourraient être complètement nouvelles. Par conséquent, l'objectif ici est de présenter certaines utilités et fonctionnalités de l'IA, et surtout d'inciter les lectuers à développer leurs propres capacités réflexives quant à leur utilisation de l'IA. Cette technologie offre de nouvelles opportunités, mais elle apportera aussi son lot d'enjeux et de questions dont il vaut mieux s'y intéresser afin

10 Outils d'intelligence artificielle

de développer une utilisation saine et intégrée de ces outils.

Trois catégories d'outils seront présentées: les « *Large Language Models* » (LLM), les assistants de traduction ainsi que les assistants de revue de littérature.

10.3.1 1. Les LLMs

10.3.2 2. Les Assistants de Traduction

10.3.3 3. Les Assistants de Revue de littérature

Dans cette section, deux principaux outils seront présentés: *research rabbit* et *ellicit*. Il s'agit de deux ressources gratuites en ligne qui facilite le début d'une revue des écrits, notamment lorsque l'on ne connaît pas beaucoup la littérature sur un sujet et/ou sur un champs d'étude. Ces deux outils sont d'ailleurs compatibles avec *Zotero*, qui fut présenté au chapitre 4 de ce livre.

Débutons avec *Ellicit*. Avec l'intelligence artificielle, cet outils suggère des articles et des livres scientifiques à partir d'une question de recherche préliminaire, ou à partir de concepts. L'application offre une version gratuite, mais qui est toutefois limité dans le nombre de crédits disponibles mensuellement afin de faire des recherches. Par conséquent, il faut l'utiliser avec parcimonie. Afin de démontrer l'utilité de ce logiciel, utilision un exemple concret.

Par exemple, disons que je m'intéresse à la question suivante: Qu'est-ce que la démocratie? Cependant, je ne sais par où commencé pour me faire une tête sur le sujet. *Ellicit* offre une solution à ce problème. La Figure ?? correspond au menu d'accueil du site web. Une fois là, je n'aurais qu'à écrire ma question dans la case « *Ask a research question* ». Les résultats générés sont représentés dans la Figure ?? et Figure ??

10.3 Les différents outils de l'IA




Figure 10.2: Menu d'accueil d'Ellicit

This screenshot shows a research summary page. At the top, it asks 'Qu'est-ce que la démocratie?'. Below this, there are four paper summaries:

- La démocratie contre elle-même**: Summary, Main finding, Methodology, Intervention, Outcome measured, Limitations.
- Principes du gouvernement représentatif**: Summary, Main finding, Methodology, Intervention, Outcome measured, Limitations.
- La démonisation des intellectuels : Qu'est-ce qu'il faut dénoncer?**: Summary, Main finding, Methodology, Intervention, Outcome measured, Limitations.
- La démocratie participative, ses conditions et malheur tout**: Summary, Main finding, Methodology, Intervention, Outcome measured, Limitations.

On the left, there are sections for 'Papers' (with a count of 4) and 'Abstract summary'. On the right, there is a sidebar with 'e.g. summary, counter arguments' and a 'See more' link.

Figure 10.3: Court résumé du sujet

Figure 10.4: Suggestions de lectures

10 Outils d'intelligence artificielle

Le logiciel offre donc un moyen intéressant afin de faire un premier « filtrage » de la littérature sur un sujet, tout en fournissant un résumé des sources suggérées à partir desquelles nous pouvons juger de sa pertinence en fonction de nos besoins.

Cependant, il est fortement recommandé d'utiliser le résumé produit par le logiciel, dans la Figure ??, et ceux de chaque suggestion, dans la Figure ??, à titre indicatif et uniquement pour notre propre réflexion. En d'autres termes, **ne jamais faire un copier-coller de ces résumés afin de les inclures dans notre travail de recherche**. Ce logiciel doit impérativement être accompagné d'une utilisation intègre de la littérature. Une bonne utilisation de ce logiciel devrait se limiter à trouver des articles et/ou des livres scientifiques selon nos besoins, que nous consulterons par la suite pour rédiger notre revue des écrits et trouver des références supplémentaires.

Un autre outils soffre à nous afin de trouver des références supplémentaires: *Research Rabbit*. Ce logiciel est gratuit, mais demande de se créer un compte afin de pouvoir utiliser ses services. Une fois que j'ai lu plusieurs articles et/ou chapitres de livre, et que j'ai incorporé les documents dans Zotero, je peux importer mon fichier contenant mes références dans *Research Rabbit*. Reprenons notre exemple de la démocratie de tout à l'heure.

Mettre les exemples dans Research Rabbit et montrer les différentes fonctionnalités, notamment le mapping

10.4 Quelle est la place du chercheur maintenant?

Avec l'avènement de l'IA, il est tout à fait raisonnable de se demander quelle est la place du chercheur aujourd'hui. L'avenir du chercheur est-il en danger? Pourrait-on assister au développement des sciences sociales sans chercheur humain derrière? Si tel est le cas, est-ce que ça ne constituerait pas un paradoxe important? Est-ce que la machine est mieux placée pour comprendre la réalité du monde sociale, ainsi que ses mécanismes, que l'humain? D'une part, certains pensent que l'IA risque de générer

10.4 Quelle est la place du chercheur maintenant?

des « laboratoires autonomes » (Hanchen Wang, Tianfan Fu, Yuanqi Du, Wenhao Gao, Kexin Huang, et al. 2023, 55). Il n'est pas difficile d'imaginer un monde où tout le processus scientifique, de la conception jusqu'à la communication, serait fait par l'IA. Le chercheur perdrait ainsi sa profession, et se limiterait à n'être qu'une partie de l'auditoire vers qui les résultats sont présentés.

Bien que nous n'en sommes pas encore là, il est important de réfléchir aux différents enjeux qui se poseraient dans une telle situation. Par exemple, étant donné que l'IA est, pour l'instant, très opaque dans tout le processus qui le mène de l'intrant vers le résultat, comment pourrait-on s'assurer que la machine a pris toutes les précautions nécessaires pour respecter les différents enjeux éthiques? A-t-elle eu le consentement libre et éclairé de tous les participants? De plus, quel est le niveau de confiance que nous pouvons avoir envers des résultats dont on ne connaît pas le processus qui y a mené? Sur cette dernière question, l'une des caractéristiques fondamentales de la science est la reproductibilité des protocoles scientifiques (King, Keohane, and Verba 2021; Bourgeois 2021). Toutes les recherches doivent présenter, d'une manière très précise, comment les données ont choisi, comment elles ont été collectées et comment elles ont été analysées. Le terme transparence est très important, et résume l'esprit de toute communication scientifique. Or, c'est une limite importante de l'IA en ce moment: nous n'avons pas accès aux processus qui mènent de l'intrant à l'extrant (Hanchen Wang, Tianfan Fu, Yuanqi Du, Wenhao Gao, Kexin Huang, et al. 2023, 56). Cette opacité nous empêche d'évaluer correctement la validité d'un protocole scientifique qui serait réalisée par l'IA. La conséquence logique de cette situation est de toujours rester vigilant et de questionner constamment les informations fournies par le robot conversationnel. L'utilisation exclusive de tel logiciel, sans se référer à des sources scientifiques qui ont été publiées par des revues scientifiques ou des éditeurs scientifiques, ne devrait jamais être une option. Il n'est pas seulement question d'intégrité et d'éthique, mais de toute la conception de ce que constitue un savoir scientifique. L'utilisation de ChatGPT, par exemple, pour produire un savoir quelconque met au défi nos conceptions épistémologiques. Générer des textes entiers

avec l'aide de l'IA ne devrait donc pas être considéré.

Comme nous le voyons, l'avènement de l'IA en recherche amène des questions et des réflexions épistémologiques² et méthodologiques³ importantes. Ces questions sont cruciales et doivent être abordées le plus rapidement possible. En tant que chercheur, nous devons nous questionner par rapport à l'utilisation de ces nouvelles technologies. Il faut être proactif et initier les réflexions sur la place du chercheur maintenant.

En ce sens, il faut élargir notre perspective et dépasser la question quant à savoir si la profession de chercheur va disparaître ou non. En fait, il faut se questionner par rapport au rôle du chercheur. Qu'est-ce qu'il devient à l'ère de l'intelligence artificielle? Comment se transforme-t-il? Pour l'instant, il est encore difficile de répondre et d'anticiper efficacement ce qui arrivera. Il n'en reste pas moins pour autant qu'initier la réflexion est nécessaire. Encore une fois, les universités sont des lieux privilégiés pour avoir ce genre de réflexion, tant venant des étudiants que des enseignants.

10.5 L'IA en sciences sociales

Malgré que l'utilisation de l'IA en sciences sociales soit relativement récente, il y a déjà quelques recherches qui se sont penchées sur son utilisation dans un contexte scientifique. Tout d'abord, la recherche de Peterson et al. (2021), qui s'intéresse à comprendre comment les individus prennent des décisions, utilise l'IA afin de traiter une importante quantité de donnée rapidement. Leur base de données est environ trente fois plus importante que celles des études précédentes. De plus, ils ont programmé

²L'épistémologie est l'une des branches de la philosophie des sciences qui s'intéresse au savoir et à la connaissance. De manière générale, et très simplifié, l'une des questions fondamentales de l'épistémologie et de se questionner quant à savoir ce qu'est un savoir qui serait scientifique.

³La méthodologie fait référence à la branche de la philosophie des sciences qui s'intéresse aux outils de collecte et d'analyse de données.

10.5 L'IA en sciences sociales

différentes théories afin de vérifier laquelle correspondait le mieux aux patterns présents dans les données. L'utilisation de l'IA dans cette recherche est très intéressante puisqu'elle permet de tester des théories existantes sur un vaste ensemble de données, qui auraient pris beaucoup plus de temps si cela avait été réalisé « manuellement ».

Ensuite, la recherche de Park et al. (2023) utilise l'IA pour créer des “generative agents” qui interagissent entre eux reproduisant des comportements individuels et collectifs humains. Leur objectif et d'en faire des proxys¹ pour étudier le comportement humain. Leur modèle prend la forme d'une simulation interactive, similaire au jeu vidéo Sims. Bien que ce ne soit pas encore au point, cette application de l'IA permettrait de tester des prototypes de systèmes sociaux ainsi que des théories (Park et al. 2023).

Similairement, la recherche de Argyle et al. (2023) utilise ChatGPT comme proxy pour étudier l'opinion publique certains sous-groupes sociaux. Leur objectif est de démontrer que ChatGPT peut être utilisé, avec un bon niveau de confiance, pour explorer et tester des hypothèses qui seraient coûteuses si c'était fait avec des sujets humains. En effet, le déploiement d'un sondage est toujours une sorte pari; ils sont en général relativement coûteux, et il est difficile de prévoir si les résultats obtenus seront significatifs. ChatGPT permettrait donc de faire un prétest afin d'améliorer et de corriger un questionnaire avant de le déployer sur des sujets humains.

Malgré ces avantages, il est important de souligner quelques limites quant à l'utilisation de l'IA en sciences sociales. La limite la plus importante est que l'IA ne remplace en aucun cas un être humain. Étant des chercheurs en sciences sociales et sciences humaines, nous dénaturerions nos disciplines si l'on se limitait à l'IA pour répondre à nos questions. Par conséquent, un test réalisé avec l'IA ne pourra jamais avoir le même niveau de confiance qu'une recherche réalisée avec des humains. Il est donc important de limiter l'utilisation de l'IA à des fins exploratoires. Une autre limite importante, mentionnée par Park et al. (2023) dans leur recherche, est que l'IA peut être sujette à des hallucinations. En d'autres termes, l'IA peut fabriquer des informations de toute pièce (Weise and Metz 2023). Cela pose un sérieux

problème quant à la fiabilité des informations générées par l'IA. C'est pour cette raison, notamment, que nous devons toujours rester vigilants. Les conséquences d'attribuer une valeur scientifique à des informations qui seraient fausses seraient graves. La science ne vise pas à construire une compréhension fictive de la réalité. Une fausse compréhension des interactions et des dynamiques sociales pourrait avoir des conséquences vraiment importantes sur le bien-être de nos sociétés. Restons vigilants.

10.6 Conclusion

En guise de conclusion, nous souhaitons lancer une dernière réflexion un peu plus philosophique, mais tout aussi importante: le transhumanisme, « [...] un mouvement international, culturel et intellectuel, prônant l'usage des sciences et des techniques dans le but d'améliorer la condition humaine, notamment par l'augmentation des capacités physiques et mentales des êtres humains » (Forestier and Ansermet 2021). La question principale qui se pose est: est-ce vraiment raisonnable d'augmenter les capacités humaines au-delà de leur limite biologique? Surtout, que deviendront les sciences sociales et humaines si le principal sujet d'étude, soit l'humain, n'est plus tout à fait lui-même? Peut-on faire des sciences sociales sur des sujets qui sont que partiellement humain? Ce qui rend les sciences sociales aussi intéressantes et pertinentes c'est peut-être, justement, parce que l'humain n'a pas d'essence. Pour reprendre les mots de Sartre (1996, 26), « l'existence précède l'essence ». En d'autres termes, et comme Sartre l'explique, l'humain n'existe pas pour remplir une fonction pré-déterminée, contrairement à un crayon qui a été conçu pour remplir la tâche spécifique d'écrire. C'est dans cette liberté, et c'est par l'expérience, que l'humain se construit et se définit. Notre existence en tant que scientifique du monde social et humain est possible que grâce à cette condition fondamentale : l'absence d'une essence qui précède l'existence. Sinon, à quoi bon étudier le monde social s'il a une fonction pré-déterminée et fixe, dans lequel les humains n'auraient aucune agentivité?

10.6 Conclusion

Cependant, avec l'arrivée de l'IA et ce désir de constamment repousser les limites humaines, ne sommes-nous pas en train de prouver à Sartre qu'il a tort? En fait, l'humain se serait imposé une essence, soit celle d'être une pièce indispensable pour faire fonctionner les rouages du système capitaliste. Face à la conception de la « croissance infinie » qui est entretenue par ce système, l'être humain a besoin de quelque chose pour « briser » ses capacités qui elles sont limitées : « [...] un remodelage technoscientifique et biomédical des corps et des vies, dans leur matérialité biologique même, afin d'adapter les individus au régime capitaliste globalisé de l'accélération. » (Dévédec 2021, 100). L'IA sera-t-elle une pièce de plus vers la réalisation de cet idéal transhumaniste?

Le propos ici n'est pas d'encourager les lecteurs à ne pas utiliser l'IA. En fait, nous souhaitons tout simplement appeler à une certaine prudence. Le risque que cette technologie nous pose est d'en devenir dépendant, voir trop (Park et al. 2023). Bien qu'elle offre de nombreux avantages, elle a aussi le piège d'offrir beaucoup de raccourcis et de nuire à plusieurs de nos capacités intellectuelles et physiques. Il faut donc développer un jugement critique dans notre utilisation de l'IA. Se poser des questions sur notre utilisation personnelle de ces outils constitue, dès aujourd'hui, le fondement des chercheurs en sciences sociales numériques.

Toutefois, à moins que la recherche porte directement sur ChatGPT, nous déconseillons fortement d'utiliser uniquement ce que le robot conversationnel fournit comme réponse. Reprenons l'exemple du totalitarisme. Dans ce cas, bien que la définition fournie soit relativement adéquate, nous recommandons d'aller consulter des sources académiques afin de trianguler la définition générée, d'une part, et surtout de présenter une définition qui est reconnue par les pairs scientifiques. Pour ce faire, il est possible d'utiliser ChatGPT. Nous pouvons lui demander de nous fournir 5 livres qui portent sur le sujet. À partir de ces recommandations, nous pouvons nous référer directement à ces ouvrages et débuter notre revue des écrits. Surtout, à moins que ce ne soit que pour vous faire une idée du contenu, n'utilisez pas ChatGPT pour résumer un livre et utiliser le résumé pour votre travail ! Cette pratique constitue une forme de plagiat. Aller consulter les ouvrages

10 Outils d'intelligence artificielle

directement plutôt que d'utiliser les définitions fournies par ChatGPT fait partie des bonnes pratiques. Développer un esprit de synthèse est fondamental pour chaque étudiant.e universitaire, ainsi que pour les futurs chercheur.euse.s. Commencez dès maintenant à développer ces capacités plutôt que de demander à ChatGPT de le faire à votre place.

10.7 Utilisation du package OpenAI

10.7.1 Installation et chargement du package

```
install.packages("openai") ## au besoin  
library(openai)
```

10.8 Configuration de l'API

Procurez vous une clé API sur le site d'OpenAI. Soyez conscient que vous aurez besoin d'une carte de crédit pour vous inscrire et que l'utilisation de l'API est payante. Renseignez-vous sur les modèles disponibles et leurs frais d'utilisation. En date de la publication du livre, le modèle de tarification d'OpenAi est de charger un prix spécifique par 1000 tokens. Le prix des Tokens en entrée est moins élevé que celui des tokens en sortie.

Lorsque vous aurez votre clé API, utilisez le package usethis pour la configurer dans votre environnement R.

```
install.packages("usethis") ## au besoin  
usethis::edit_r_environ()
```

Ajoutez la ligne suivante à votre fichier `.Renvironment`.

```
OPENAI_API_KEY=inserez-votre-cle-api-ici-sans-guillemets
```

10.9 Utilisation de l'API

La fonction principale du package openai est `create_chat_completion()`. Elle prend en entrée le modèle que vous souhaitez utiliser ainsi que le message que vous souhaitez envoyer au modèle en format list. Voici un modèle d'utilisation de la fonction:

```
chat_prompt <- create_chat_completion(
  model = "gpt-3.5-turbo",
  messages = list(
    list(
      "role" = "system",
      "content" = "You are a helpful assistant."
    ),
    list(
      "role" = "user",
      "content" = "Please do the following:")
  )
)
```

Le résultat de votre requête sera contenu dans l'objet `chat_prompt` formatté en JSON. Vous pouvez accéder aux variables de la même façon qu'un dataframe normal. Le contenu de la réponse sera dans `chat_prompt$choices$content`.

Utiliser `chatgpt` de cette façon ouvre plein de possibilités. Appliquer des instructions sur un ensemble d'observations à l'aide de boucles, utiliser des fonctions pour générer des messages et les appliquer à travers d'autres API, analyser des sites webs en temps réel en scraping avec des paquets tels

10 Outils d'intelligence artificielle

rvest, etc. Ce sera à vous de réfléchir aux possibilités que vous souhaitez explorer.

10.10 Notes

- Il est possible d'accéder aux statistiques d'utilisation de token dans `chat_prompt$usage$prompt_tokens` et `chat_prompt$usage$completion_tokens`. Vous pouvez donc calculer le coût de votre requête en fonction du modèle que vous utilisez.
- Ne pas oublier d'inclure `.Renvironment` dans votre gitignore pour ne pas vous faire voler votre clé API.
- Il est possible de créer des images avec la fonction `create_image`("Inserez votre texte ici")
- Il est possible d'effectuer du speech-to-text avec la fonction `create_transcription()` et `create_translation()`
- Plus de documentation est disponible au <https://irudnyts.github.io/openai/>
- Plus de fonctionnalités sont disponibles en python mais le package R est suffisant pour la plupart des utilisations.

10.11 Annexe 1

Bonnes pratiques d'utilisation Harvard. 2023. « Guidelines for using ChatGPT and other Generative AI tools at Harvard ». <https://provost.harvard.edu/guidelines-using-chatgpt-and-other-generative-ai-tools-harvard>

MIT. 2023. « Advice and responses from faculty on ChatGTP and A.I.-assisted writing ». <https://cmsw.mit.edu/advice-and-responses-from-faculty-on-chatgpt-and-a-i-assisted-writing/>

10.12 Annexe 2

Q : Qu'est-ce que le totalitarisme? R : Le totalitarisme est un système politique et idéologique caractérisé par un contrôle absolu et centralisé du gouvernement sur tous les aspects de la vie publique et privée d'une société. Dans un régime totalitaire, le gouvernement exerce un pouvoir autoritaire et oppressif, limitant sévèrement les libertés individuelles, supprimant les droits de l'homme, et éliminant ou réprimant toute opposition ou critique.

Bonnes pratiques d'utilisation Harvard. 2023. « Guidelines for using ChatGPT and other Generative AI tools at Harvard ». <https://provost.harvard.edu/guidelines-using-chatgpt-and-other-generative-ai-tools-harvard>

MIT. 2023. « Advice and responses from faculty on ChatGTP and A.I.-assisted writing ». <https://cmsw.mit.edu/advice-and-responses-from-faculty-on-chatgpt-and-a-i-assisted-writing/>

10.13 Annexe 2

Q : Qu'est-ce que le totalitarisme? R : Le totalitarisme est un système politique et idéologique caractérisé par un contrôle absolu et centralisé du gouvernement sur tous les aspects de la vie publique et privée d'une société. Dans un régime totalitaire, le gouvernement exerce un pouvoir autoritaire et oppressif, limitant sévèrement les libertés individuelles, supprimant les droits de l'homme, et éliminant ou réprimant toute opposition ou critique.

Les caractéristiques clés du totalitarisme comprennent :

1. **Contrôle gouvernemental absolu** : Le gouvernement exerce un contrôle total sur tous les aspects de la vie, y compris l'économie, la culture, l'éducation, les médias, la religion et les activités sociales.

2. **Idéologie dominante** : Le régime totalitaire est basé sur une idéologie spécifique qui est imposée à la population. Cette idéologie est souvent promue comme la seule vérité et toute forme de pensée dissidente est sévèrement réprimée.
3. **Culte de la personnalité** : Les dirigeants du régime totalitaire sont souvent présentés comme des figures quasi-divines ou héroïques, et un culte de la personnalité est créé autour d'eux pour renforcer leur autorité.
4. **Répression politique** : Toute forme d'opposition politique est réprimée de manière brutale. Les opposants sont souvent emprisonnés, torturés, voire exécutés. La surveillance et la dénonciation sont courantes pour empêcher toute critique du régime.
5. **Propagande intensive** : Le gouvernement contrôle les médias et utilise la propagande pour manipuler l'opinion publique, répandre sa vision du monde et justifier ses actions.
6. **Absence de droits individuels** : Les droits individuels tels que la liberté d'expression, la liberté de la presse, le droit de réunion et d'association sont souvent supprimés au profit de la suprématie de l'État.
7. **Contrôle de l'éducation** : L'éducation est utilisée pour propager l'idéologie du régime et façonner la mentalité des citoyens conformément à ses objectifs.
8. **Utilisation de la terreur** : La terreur et l'intimidation sont utilisées pour maintenir le contrôle sur la population. Les purges et les arrestations arbitraires sont fréquentes pour maintenir un climat de peur.

Des exemples historiques de régimes totalitaires incluent l'Allemagne nazie sous Adolf Hitler, l'Union soviétique sous Joseph Staline, et la Chine sous Mao Zedong. Le totalitarisme est généralement considéré comme une forme extrême et oppressive de gouvernement, en contraste avec les

10.13 Annexe 2

systèmes démocratiques qui mettent l'accent sur les libertés individuelles, la séparation des pouvoirs et la participation citoyenne.

{« pagebreak »}

11 À voir

11.1 Défis et enjeux éthiques de l'IA, focus sur ChatGPT

En tant qu'étudiant, professeur, professionnel ou chercheur, il faut se questionner par rapport à notre propre utilisation des différents outils de l'IA. Tout d'abord, il est important de comprendre qu'il y a plus de questions que de réponses pour l'instant. Face à ce constat, nous n'avons pas la prétention d'être en mesure de cibler toutes les questions qui émergent actuellement, et encore moins d'avoir les réponses. Cependant, cela ne justifie pas pour autant d'être passif. Nous devons essayer d'être réflexifs et critiques dans la limite de nos capacités et de nos connaissances. En ce sens, les étudiants et les enseignants doivent aussi être proactifs en entreprenant les démarches nécessaires ainsi qu'en s'engageant dans la réflexion.

Dans un premier temps, un bon usage de ces outils débute avec une bonne réflexion quant à leur utilisation. Par conséquent, les universités constituent des endroits privilégiés pour favoriser les discussions et les réflexions quant à l'utilisation de ces technologies. D'ailleurs, certaines universités se sont déjà dotées de lignes directrices quant à l'utilisation de robots conversationnels et de l'IA générative¹. Nous sommes d'avis que chaque université aurait intérêt à se doter de tel document, afin de fournir les ressources nécessaires aux étudiants ainsi qu'aux membres du corps professoral dans leur utilisation de ces outils. L'accompagnement

¹Sur ce sujet, nous recommandons de consulter les ressources dans la section Bonnes pratiques d'utilisation de l'IA dans l'Annexe 1 du chapitre.

11 À voir

et l'encadrement dans l'exploration et l'utilisation de l'IA nous paraissent être une bonne stratégie à adopter afin de permettre le développement de bonnes pratiques.

Actuellement, un enjeu majeur, surtout avec les robots conversationnels, est le plagiat. Notre but ici est de présenter les différentes ressources qui s'offrent aux lecteurs pour qu'ils puissent développer les bonnes pratiques d'utilisation de ces outils tout en restant intègres. Pour ce faire, nous présenterons dans les paragraphes suivants les bonnes pratiques de citation selon l'American Psychological Association et The Chicago Manual of Style. Avant cela, il est important de spécifier que notre point de vue, et les propos tenus dans ce livre, ne remplace en aucun cas les règlements disciplinaires et/ou codes de conduite établis par une institution académique quelconque. Par conséquent, nous invitons fortement les lecteurs à consulter les sites web de ces associations, à se référer aux personnels appropriés pour toutes questions relatives à l'utilisation de texte généré par l'IA ainsi qu'à tout document relatif au plagiat produit par l'institution académique fréquentée. Passons maintenant à la présentation de ces manuels de style.

L'American Psychological Association (APA) encourage les utilisateurs à être transparents quant à leur utilisation de logiciels tel que ChatGPT. Lorsqu'utilisés, les chercheurs devraient spécifier clairement qu'ils ont utilisé le logiciel, en plus de décrire comment ils ont utilisé le logiciel, quel prompt ont-ils utilisé et quel a été le résultat en plus de fournir des extraits textuels (McAdoo 2023). Il est recommandé de documenter chaque utilisation. Se créer un document qui inclue la date d'utilisation, la question demandée ainsi que la réponse obtenue doit faire partie des bonnes pratiques de chacun. Ces éléments peuvent être ajoutés en annexe au besoin (McAdoo 2023). Sans grande surprise, il est impératif de citer l'auteur lorsqu'on utilise des idées qui ne sont pas les nôtres. Dans le cas de robots conversationnels, nous devons citer le développeur (McAdoo 2023). Par exemple, pour une citation de ChatGPT, il faudra référer à OpenAI, soit le développeur du logiciel.

Utilisons un exemple concret afin d'illustrer le tout. Supposons que je

11.1 Défis et enjeux éthiques de l'IA, focus sur ChatGPT

m'intéresse au concept du totalitarisme, mais que je n'ai pas une compréhension claire de ce que ça signifie. Je pourrais utiliser ChatGPT pour me fournir une définition du concept. Si je souhaite l'inclure dans mon travail, je procèderais de la façon suivante : nous avons utilisé ChatGPT afin de nous donner une définition du totalitarisme. Pour ce faire, nous lui avons posé la question suivante : « Qu'est-ce que le totalitarisme? ». Le logiciel nous a fourni la définition suivante : « Le totalitarisme est un système politique et idéologique caractérisé par un contrôle absolu et centralisé du gouvernement sur tous les aspects de la vie publique et privée d'une société. Dans un régime totalitaire, le gouvernement exerce un pouvoir autoritaire et oppressif, limitant sévèrement les libertés individuelles, supprimant les droits de l'homme, et éliminant ou réprimant toute opposition ou critique. » (OpenAI 2023)

En bibliographie, la référence serait insérée comme suit, et ensuite j'irai insérer la question et la réponse complète en annexe².

OpenAI. (2023). ChatGPT (Version du 3 août 2023) [Large Language Model]. <https://chat.openai.com/auth/login> (exemple tiré de McAdoo 2023)

Quant au manuel de style Chicago, il est recommandé de mentionner et d'expliquer que nous avons utilisé ChatGPT pour accomplir une certaine tâche dans notre texte. Toutefois, comme le lien généré lors de l'utilisation individuelle de ChatGPT n'est pas public et ne peut pas être consulté par les autres, il n'est pas recommandé d'insérer la référence en bibliographie.

Toutefois, à moins que la recherche porte directement sur ChatGPT, nous déconseillons fortement d'utiliser uniquement ce que le robot conversationnel fournit comme réponse. Reprenons l'exemple du totalitarisme. Dans ce cas, bien que la définition fournit soit relativement bonne, nous recommandons d'aller consulter des sources académiques afin de trianguler la définition qui a été générée, d'une part, et surtout de présenter une définition qui est reconnue par les pairs scientifiques. Toutefois, pour ce faire,

²Référez-vous à l'Annexe 2 pour un exemple.

11 À voir

il est possible d'utiliser ChatGPT. Nous pouvons lui demander de nous fournir 5 livres qui portent sur le sujet. À partir de ces recommandations, nous pouvons nous référer directement à ces ouvrages et débuter notre revue des écrits. Surtout, à moins que ce ne soit que pour vous faire une idée du contenu, n'utilisez pas ChatGPT pour résumer un livre et utiliser le résumé pour votre travail! Cette pratique constitue une forme de plagiat. Aller consulter les ouvrages directement plutôt que d'utiliser les définitions fournies par ChatGPT fait partie des bonnes pratiques. De plus, développer un esprit de synthèse est fondamental pour chaque étudiant universitaire, ainsi que pour les futurs chercheurs. Commencez dès maintenant à vous pratiquer pour développer ces capacités. Ne demandez pas à ChatGPT de le faire à votre place.

12 Kit de démarrage pour les sciences sociales numériques

Marc-Antoine Rancourt, Flavie Lachance, Justine Béchard, William Poirier

12.1 Introduction

Alors que les chapitres précédents se sont consacrés à la présentation théorique et pratique des sciences sociales numériques, le présent chapitre s'efforcera à aider le lecteur à faire sens de la grande quantité d'information que contient l'ouvrage et à commencer sa propre démarche d'apprentissage numérique. À ce propos, le titre n'est pas anodin. Il est possible de voir ce chapitre comme l'endroit où débuter son apprentissage des nouveaux outils numériques présentés dans cet ouvrage.

En plus d'aider de lecteur à installer et à utiliser plusieurs des outils présentés précédemment, ce chapitre offre également des conseils afin d'éviter de communs pièges lors de l'apprentissage de nouveaux outils. Le corps du texte du présent chapitre est divisé en trois parties en lien avec le niveau de difficulté associés à l'apprentissage des différents outils numériques: débutant, intermédiaire et avancé. De plus, chaque partie termine par une liste de pièges à éviter et qui est associé au niveau d'apprentissage qui lui est propre.

12.2 Débutant

Cette section peut s'adresser à tous les lecteurs, mais elle vise particulièrement ceux et celles qui débutent leurs parcours dans le monde numérique. Elle se divisera en deux sous-sections portant chacune sur un type d'outils nécessaires à la pratique des sciences sociales numériques. La première partie couvre le langage de programmation R et l'environnement de programmation qui lui est associé, RStudio. Elle commence par présenter au lecteur comment télécharger R et RStudio correctement. Ensuite, elle offre différentes ressources afin de pouvoir apprendre à utiliser R et naviguer RStudio adéquatement. La seconde section guide le lecteur dans l'installation de L^AT_EX, puis présente des ressources utiles à son utilisation.

12.2.1 R et RStudio

Le chapitre 4 du présent livre introduit le langage de programmation R, ses avantages, ses inconvénients et son utilité. Cette partie du livre se veut un complément à ce chapitre visant à aider le lecteur à se familiariser avec le langage R. La première étape pour mener à bien cette tâche est de le télécharger. R fonctionne sur une grande quantité de plateformes, notamment sur les différentes distributions de Windows, de macOS et de Linux. Pour le télécharger, il faut commencer par se rendre sur le *Comprehensive R Archive Network*. Il est fortement conseillé d'utiliser ce site puisqu'il est l'endroit principal où se trouve la plupart des choses liées à R. Il est aussi facile d'utilisation, très bien documenté et régulièrement mis à jour. Il est possible d'accéder le site à partir de l'adresse suivante : <https://cran.r-project.org/>. Dans le haut de la page, un lien pour chacun des trois systèmes d'exploitation principaux – Windows, macOS et Linux – redirige vers la page appropriée. Il suffit de cliquer sur la distribution présente sur l'ordinateur et l'installer.

12.2 Débutant

Il existe plusieurs ressources qu'un nouvel utilisateur de R peut consulter afin de se familiariser avec le langage de programmation. Comme pour de nombreuses autres choses, il est possible d'apprendre en faisant des exercices en ligne et en suivant des tutoriels. Les tutoriels sont une manière tout autant enrichissante que divertissante pour se familiariser avec certains outils du monde numérique, notamment le langage R. DataCamp est un des sites les plus populaires, mais aussi les plus complets et accessibles, à cette fin. Datacamp est une plateforme d'apprentissage en ligne proposant des exercices interactifs en ligne, axé principalement sur l'analyse et les données. La plateforme est facile à utiliser et contient une grande quantité de module sur les différents aspects du langage R. En date de 2023, selon le site de l'entreprise, DataCamp contient plus de 140 cours interactifs portant sur le langage R, en plus de contenir plus de 100 tutoriels variés. La plateforme a également un forum où il est possible d'interagir avec les autres utilisateurs et poser des questions. Un autre avantage de Datacamp est son accessibilité. En plus des cours accessibles gratuitement, Datacamp offre des réductions sur les abonnements pour les étudiants et les enseignants. Il est également possible pour les enseignants d'obtenir gratuitement un compte Datacamp Entreprise à des fins d'utilisation éducative. D'autres plateformes dans le même genre que DataCamp existent. Les alternatives les plus populaires sont CodeAcademy et Coursera. Bien qu'il n'y ait rien de mal à proprement parler à utiliser ces alternatives, nous conseillons DataCamp car cette plateforme apparaît être la meilleure pour l'apprentissage de nouveaux outils numériques destinés à la science des données en sciences sociales.

En plus de ces différentes ressources en ligne, plusieurs excellent ouvrages d'introduction au langage de programmation R sont disponibles. Les auteurs du présent ouvrage proposent trois ouvrages aux nouveaux utilisateurs. Le livre *R For Data Science* d'Hadley Wickham et de Garret Grolemund est un classique en la matière et est un excellent guide sur les différents éléments à apprendre pour bien maîtriser le langage de programmation R ainsi que son utilité en sciences sociales computationnelles. Publié pour la première fois en 2017, il a été réédité une seconde fois en 2023 et est disponible gratuitement en ligne à l'adresse suivante: <https://r4ds.hadley.nz/>. Un

12 Kit de démarrage pour les sciences sociales numériques

second ouvrage qui peut être utile est *The Book of R: A First Course in Programming and Statistics* de Tilman Davies. Le *Book of R*, comme certains l'appelle, est un guide complet et convivial pour les débutants en R. Contrairement à d'autres ressources du même genre, il ne demande aucune expérience en programmation et à peine quelques connaissances de base en mathématiques afin de commencer à apprendre à utiliser R efficacement pour l'analyse statistique. Finalement, le troisième ouvrage, *Beyond Spreadsheets with R: A beginner's guide to R and RStudio* de Jonathan Carroll, montre comment prendre des données brutes et les transformer pour les utiliser dans des calculs, des tableaux, des graphiques, etc. Le livre a pour but d'aider le lecteur à bâtir des bases solides afin de lui permettre d'analyser et visualiser des données de toutes sortes à l'aide de R. Un avantage qu'a cet ouvrage sur les autres est qu'il est également un guide d'apprentissage pour RStudio. Ce livre, ainsi que celui de Tilman Davies, sont disponibles sur Amazon et autres plateformes de vente de livres.

En ce qui a trait à RStudio, outre que le livre de Tilman Davies susmentionné, il existe plusieurs ressources en ligne pouvant aider les utilisateurs débutants. DataCamp a un long tutoriel dédié à apprendre à utiliser l'environnement de programmation RStudio. Le site web de RStudio a également une section sur les bases de l'environnement de programmation. Plusieurs institutions offrent également de courts tutoriels par le biais de pages webs ou de vidéos accessibles sur des plateformes telles que Youtube. Autant pour R que pour RStudio, une grande quantité de ressources d'aide sont disponibles en ligne. Des forums tels que Stack Overflow et la section discussion de GitHub peuvent être très utiles pour avoir une réponse rapide à une question technique.

12.2.2 Les alternatives à Word : les langages de balisage

Le chapitre 5 du présent ouvrage introduit les langages de balisage L^AT_EXet Markdown, leurs historiques ainsi que leurs avantages et inconvénients. Cette partie du livre se veut un complément au chapitre 5 visant à aider le

12.2 Débutant

lecteur à se familiariser avec les principaux langages de balisage utilisés en sciences sociales numériques. La première étape pour afin d'utiliser les langages de balisage L^AT_EXet Markdown est de les télécharger. Bien que LaTeX peuvent être téléchargé à différents endroits, celui qui est généralement considéré comme étant officiel est le *Comprehensive TEX Archive Network* (CTAN). Le CTAN est disponible à l'adresse suivante : <https://www.ctan.org/>. Le CTAN est le lieu central pour tout ce qui touche L^AT_EX. CTAN compte actuellement 6483 packages, auxquels ont contribués 2946 usagers. La plupart des packages sont gratuits et peuvent être téléchargés et utilisés immédiatement. Les deux distributions TeX les plus couramment utilisées sont TEX Live et MiKTeX. Bien que leurs avantages aient été relativement différents dans le passé, en 2023, un nouvel usager ne verrait probablement pas la différence. Les deux distributions peuvent être téléchargées à partir du site Web du CTAN et utilisées rapidement. Elles sont supportés sur tous les versions principales de Linux, MacOS et Windows.

Plusieurs ressources pour L^AT_EXpeuvent se trouver en ligne. *The LaTeX Project* est une excellente source d'information sur le langage de balisage LaTeX. Cette ressource est disponible à l'adresse suivante : <https://www.latex-project.org/>. Elle contient une grande quantité de documentation à l'usage de nouveaux usagers, des nouvelles sur les mises à jours L^AT_EXainsi qu'une liste de publications portant sur L^AT_EXet son utilisation. Le site Web contient également plusieurs liens utiles vers GitHub ainsi que des informations pertinentes sur l'historique du langage. D'autres ressources sous formes de livres et d'articles existent et peuvent être très utiles aux nouveaux usagers de L^AT_EX. Le livre *Learning LATEX* par David Griffiths et collègues, publié en 1997, tient encore la route aujourd'hui. On peut y apprendre les bases du langages L^AT_EXqui n'ont pas changé depuis des décennies. En 2017, un autre livre important pour les nouveaux usagers est paru. *LaTeX in 24 Hours: A Practical Guide for Scientific Writing*, écrit par Dilip Datta, offre un aperçu de LaTeX aux académiques peu d'expérience technique préalable. Le livre présente aux lecteurs des exercices et des exemples simples et compréhensibles pour se familiariser rapidement avec le langage.

12 Kit de démarrage pour les sciences sociales numériques

Une grande quantité d'autres ressources sont disponibles sur le Web.

Comme noté au chapitre 5, Markdown est un langage de balisage servant à ajouter des éléments de formatage à des documents en texte brut. Il n'a pas à être téléchargé, il est natif à la plupart des systèmes d'opérations régulièrement utilisés. Afin de commencer à l'utiliser, il suffit d'ajouter des éléments de formatage Markdown à un fichier texte brut à l'aide d'un éditeur de texte. Il est également possible d'utiliser l'une des nombreuses applications Markdown pour les systèmes d'exploitation macOS, Windows, Linux, iOS et Android. Il existe également plusieurs applications Web spécialement conçues pour écrire en Markdown. L'environnement de programmation RStudio, susmentionné ainsi que présenté au chapitre 4, est un excellent endroit pour écrire en Markdown. RStudio permet également à l'utilisateur d'écrire en RMarkdown ainsi qu'en Quarto.

Comme L^AT_EX, Markdown est un langage de balisage qui existe depuis longtemps et dont les bases n'ont pas particulièrement changées dans les dernières décennies. Ainsi, il existe une panoplie de ressources en ligne aidant les nouveaux usagers à se familiariser avec le langage. Le créateur de Markdown, John Gruber, a un site Web contenant les bases du langage Markdown. Ce dernier peut être trouvé à l'adresse suivante : <https://daringfireball.net/projects/markdown/>. Le site Web *Markdown Tutorial*, comme son nom l'indique, est un site Web open source qui permet d'essayer Markdown dans le navigateur Web. Il est disponible à l'adresse suivante : <https://www.markdowntutorial.com/>. En format livre, le livre *The Markdown Guide* par Matt Cone est une courte mais complète introduction aux bases de Markdown. De la mise en forme à la publication, ce livre contient une grande quantité d'information et de ressources qui peuvent être même utiles aux usagers avancés. Comme pour L^AT_EX, une grande quantité d'autres ressources sont facilement accessibles sur le Web.

12.2.3 Pièges pour usagers débutants

Beaucoup de nouvelles informations ont été présentées jusqu'à présent dans ce livre. Il est normal de se sentir dépassé et de ne pas tout comprendre. En fait, il aurait été surprenant qu'un lecteur qui débute l'aventure numérique ait tout compris. L'important est de garder une attitude propice à l'apprentissage et se rappeler que rien de ceci n'est inatteignable. C'est au tout début du parcours que se trouve le premier des pièges pour débutants : **croire qu'il sera trop difficile d'apprendre, que c'est un objectif impossible à atteindre**. Même les auteurs de ce livre ont, un jour, commencés par faire *Hello World!* dans la console de RStudio. Le premier piège est souvent lié à un autre piège qui frappe les codeurs débutants : **la peur de demander de l'aide**. Il faut garder à l'esprit qu'une grande quantité des utilisateurs des outils présentés dans le présent livre sont passés par l'incertitude du début et la crainte du jugement des autres. N'ayez pas peur de poser vos questions, c'est comme cela qu'on apprend.

Une autre catégorie de pièges pour débutants pour les débutants concerne la pratique des connaissances nouvellement acquises. Les pièges pour débutants de cette catégorie sont au nombre de trois. Tout d'abord, on retrouve **la croyance qu'il est possible d'apprendre sans pratiquer**. Bien que cela puisse être possible pour quelques personnes ayant une mémoire phénoménale, la réalité est qu'il sera difficile pour le lecteur moyen de retenir l'information contenue dans ce livre et dans les exercices sans pratiquer les nouvelles notions. Le second piège de cette catégorie est lié à ce dernier point : DataCamp – où il y a des indices et du code déjà écrit – ne forme pas à lui seul des codeurs. Il faut faire attention à **ne pas rester pris dans une boucle infinie de tutoriels**. Faire des tests avec des projets personnels aide à assimiler les nouvelles connaissances en plus d'être plus intéressant. Le troisième pièges pour débutants de cette catégorie est de **ne pas être constant dans ses apprentissages**. Avec les exercices comme Datacamp, il est facile d'apprendre très rapidement. Toutefois, les apprentissages peuvent se perdre aussi rapidement qu'ils ont

12 Kit de démarrage pour les sciences sociales numériques

été acquis. Il est donc important de suivre une certaine continuité et même parfois de refaire certains exercices afin de se rafraîchir la mémoire pour s'assurer de bien comprendre les connaissances de base.

Le dernier pièges pour débutants est le suivant : **ne pas construire des bases solides avant d'aller plus loin.** Plusieurs nouveaux codeurs, excités par les nouveaux outils qu'ils apprennent, oublient qu'il est primordial de bien comprendre les éléments de base de la programmation et de la gestion de données avant de se lancer dans des projets plus complexes. Bien qu'il ne soit pas requis de connaître la mécanique pour conduire une automobile, il est tout de même parfois utile – voir nécessaire – de comprendre comment entretenir celle-ci.

12.3 Intermédiaire

Tout comme la section précédente, cette section peut tout à fait être utile à tous les lecteurs. Cependant, elle vise particulièrement ceux et celles qui ont commencé leurs parcours dans le monde numérique, mais qui cherchent à compléter leur parcours d'outils qui leur facilitera la vie. Cette section se divise en deux sous-sections portant chacune sur un type d'outils nécessaires à la pratique des sciences sociales numériques. La première partie couvre des ressources de gestion bibliographique. Elle commence par présenter au lecteur comment télécharger correctement les différents outils. Ensuite, elle offre différentes ressources afin de pouvoir apprendre les utiliser adéquatement. La seconde section guide le lecteur l'apprentissage de la visualisation graphique en R, puis présente des ressources utiles à sa pratique.

12.3.1 La gestion des références

Le chapitre 6 du présent livre porte sur la gestion des références. Il présente deux ressources de gestion bibliographique largement utilisés :

12.3 Intermédiaire

Zotero et BibLaTex. Cette partie du livre se veut un complément au chapitre 6. La première étape pour afin d'utiliser deux outils de gestion des références susmentionnés est de les télécharger. En ce que concerne Zotero, celui-ci peut être téléchargé à partir du site Web officiel de l'outil à l'adresse suivante : <https://www.zotero.org/download/>. Le site Web de Zotero contient une grande quantité de documentation pouvant aidant les différents niveaux d'utilisateurs. Ladite documentation aide notamment à apprendre à créer des bibliographies, comment travailler en collaboration et les différents *plug-ins* et *add-ons* qui peuvent être utilisés. Parmi ceux-ci, on retrouve notamment *Better BibTex* – présenté au chapitre 6 – qui aide grandement la gestion de données bibliographiques pour ceux utilisant Zotero et un langage de balisage tel que L^AT_EX ou Markdown. *Better BibTex* peut être téléchargé à l'adresse suivante : <https://retorque.re/zotero-better-bibtex/installation/>. Le site Web de *Better BibTex* contient également une foule de documentation aisant l'utilisation de l'outil.

La littérature académique sur les différents outils aidant à la gestion des données bibliographiques indiquent que beaucoup des professionnels de différents milieux utilisent Zotero. Il est aussi possible de constater que plusieurs préfèrent Zotero à d'autres options connues telles que EndNotes, RefWorks et Mendeley. Behera et Meher (2022) notent 13 avantages de Zotero sur sa compétition. Parmi ceux-ci, on retrouve notamment la capacité de Zotero à supporter une grande quantité de formats d'écriture, son caractère *open source* et gratuit, son développement constant par de nombreux chercheurs assurant sa qualité, en plus de son utilité pour le travail collaboratif. Ivey et Crum (2018) comparent les quatre options les plus populaires pour la gestion des données bibliographiques : Zotero, EndNotes, RefWorks et Mendeley. Ils notent pour leur part que Zotero était l'outil le plus précis pour la capture et la transformation de données Web en notices bibliographiques. Selon eux, Zotero créerait les notices bibliographiques les plus exactes. Parmi les options populaires gratuites Zotero et Mendeley, Gilmour et CobusKuo (2011) concluent que Zotero est la meilleure. Les auteurs notent notamment la précision des bibliographiques extractées et le peu d'erreurs produites par l'outil. Winslow et al. (2016) montrent, pour

12 Kit de démarrage pour les sciences sociales numériques

leur part, que Zotero peut aussi être utilisé à des fins pédagogiques. L'outil peut aider les chercheurs avec la littérature sur un sujet en plus d'avoir un impact concret sur les pratiques scientifiques.

Pour sa part, BibLaTeX n'a pas besoin d'être téléchargé puisque c'est un package qui vient avec essentiellement toutes les principales distributions TeX. Il ne suffit que d'utiliser la commande `\usepackage{biblatex}` pour y avoir accès. C'est une des trois alternatives populaires afin de citer avec LaTeX, les autres étant *natbib* et *bibtex*. Biblatex est généralement considéré comme étant l'option LaTeXmoderne pour traiter les données bibliographiques. Plusieurs apprécient grandement son interface simple et flexible. BibLaTeX supporte aussi mieux des langages autres que l'anglais en comparaison avec les deux autres options.

Le susmentionné CTAN contient une grande quantité de documentation portant sur BibLaTeX à l'adresse suivante : <https://www.ctan.org/pkg/biblatex>. De plus, Philip Kime, Moritz Wemheuer et Philipp Lehman ont mis en ligne un excellent guide intitulé « The biblatex Package » portant sur le package. Les auteurs ont compilé en 357 pages toutes les possibilités du package avec des exemples précis. Le document contient un guide pour les usagers de plus de 100 pages, en plus d'un historique des versions du package depuis 2012. Le document est à jour pour l'année 2023, et il est constamment mis à jour par les auteurs.

12.3.2 Visualisation graphique en R

Le chapitre 7 du présent ouvrage porte sur la visualisation graphique en R, les différentes options pour visualiser des données et une discussion concrète de la manière de faire avec *base R*, *lattice* et *ggplot2*. Pour plusieurs raisons présentées aux chapitre 7, *ggplot2* est présentement considéré comme étant la meilleure alternative de visualisation graphique avec R en sciences sociales numériques. Comme BibLaTeX, *ggplot2* n'a pas besoin d'être directement téléchargé à partir du Web. Il peut être téléchargé seul avec la fonction R *install.packages* ou avec le super-package *tidyverse*. Il ne suffit

12.3 Intermédiaire

que le l'appeler avec la fonction *library* pour y avoir accès une fois que cela est fait.

Outre le contenu du chapitre 7, une grande quantité de ressources est disponible en ligne afin de guider les utilisateurs de R dans leurs démarches de visualisation graphique. Youtube, StackOverflow et les autres sites Webs contenant des tutoriels ou de l'aide à la programmation sont remplis de guides pouvant être utiles. Toutefois, nous considérons que certaines ressources sont plus utiles que d'autres afin de bien comprendre les bases de *ggplot2*. Le susmentionné livre *R For Data Science* d'Hadley Wickham et de Garret Grolemund contient une importante section sur la création de graphiques avec *ggplot2* en R. Cette section du livre contient également des exercices pour le lecteur. Hadley Wickham a beaucoup travaillé sur ce sujet. Il a écrit plusieurs livres et articles sur le langage de programmation R et la visualisation graphique. Parmi lesdits écrits, l'article de Wickham (2010) est une ressource édifiante pour le compréhension de la *grammar of graphics*, à la base du projet *ggplot*. Wickham et collègues ont également écrit *ggplot2: Elegant Graphics for Data Analysis (3e)* qui porte également sur la philosophie derrière la création et l'utilisation de *ggplot2*. D'autres ouvrages, plus pratiques, ont été publié sur la visualisation graphique en R avec *ggplot2*. C'est notamment le cas du livre de Robert Kabacoff sur l'apprentissage de la visualisation graphique avec *ggplot2* « Modern Data Visualization with R ». Il est disponible en ligne à l'adresse suivante : <https://rkabacoff.github.io/datavis/>. Il couvre une grande quantité d'analyses statistiques possibles à faire en R et les meilleures manières de les présenter visuellement. Chaque type de graphique est accompagné de plusieurs exemples et d'une base de données. Finalement, DataCamp, la plateforme d'apprentissage mentionnée précédemment dans le présent chapitre, contient plusieurs tutoriels permettant à de nouveaux utilisateurs de se pratiquer avec *ggplot2*. DataCamp contient trois cours complets, pour 12 heures de tutoriels, sur la visualisation en R avec *ggplot2*, allant du niveau de débutant jusqu'au niveau avancé.

12.3.3 Pièges pour usagers intermédiaires :

À la suite des différents exercices et lectures complétés dans le cadre de cette familiarisation aux sciences sociales numériques, le lecteur doit s'assurer d'éviter certains pièges qui se dressent sur le chemin des chercheurs de niveau intermédiaire. Le premier d'entre eux est **vouloir apprendre plusieurs langages et n'en maîtriser aucun**. Plusieurs chercheurs, lorsqu'ils commencent à maîtriser de nouveaux outils, s'emballent et souhaitent en apprendre davantage. C'est une bonne chose, mais il faut faire attention à ne pas apprendre que quelques éléments de plusieurs langages de programmation, et plutôt en maîtriser un. Comme le dit un dicton populaire, « qui trop embrasse mal étreint ».

Un second pièges pour usagers intermédiaires auquel de jeunes chercheurs sont la proie est **coder en n'utilisant pas un style et une planification cohérente et constante**. En n'adoptant pas un style standard – ou en n'utilisant pas le plus souvent le même style – il peut devenir difficile pour les autres et pour soi-même de se retrouver dans le code. Cela peut causer d'importants problèmes de compréhension ou des problèmes techniques. Il est rare qu'un même code ne serve qu'une seule fois. Il est donc de viser à ce que le code qu'on produit soit compréhensible, transférable et – idéalement – optimisé. Un autre pièges pour usagers intermédiaires s'inscrivant dans la lignée du précédent est **écrire du code mais ne pas le commenter**. Commenter son code contribue grandement à la transférabilité et la pérennité de son travail. Bien que la fonction d'une section de code peut sembler évidente pour son créateur le jour où elle est produite, elle ne le sera pas nécessairement pour d'autres ou pour lui-même dans le futur.

Le troisième pièges pour usagers intermédiaires concerne l'utilisation des packages R. De nombreux packages r sont disponibles sur Internet. Dans certaines situations, l'utilisation de ceux-ci peut représenter un gain de temps et résoudre certains problèmes spécifiques. Toutefois, pour des tâches relativement simples, utiliser un package r risque d'ajouter une complexité

12.4 Avancé

inutile. En effet, comprendre un package R et l'adapter en fonction de son projet peut être long et laborieux. Il est donc souvent beaucoup plus efficace d'écrire son propre code plutôt que d'utiliser un package R.

Le dernier piège se dressant sur le chemin d'un chercheur de niveau intermédiaire est de **croire qu'il a suffisamment de connaissances et ne pas sortir de sa zone de confort**. L'apprentissage de techniques plus complexes demande de sortir de sa zone de confort et de se confronter à l'inconnu. Cela demande également d'accepter qu'on ne connaît pas tout et qu'il y aura des échecs et des frustrations. C'est ainsi qu'un chercheur intermédiaire peut dépasser ses limites et devenir un chercheur de niveau avancé.

12.4 Avancé

12.4.1 Le travail collaboratif

Le chapitre 8 du présent ouvrage présente principalement trois types d'outils complémentaires pour le travail collaboratif : les outils de communications, les outils de gestion de versions et les outils d'entreposage de données. Cette section est complémentaire au chapitre 8 qui présente les différents outils et leurs plusieurs avantages et inconvénients. Elle vous présentera des façons d'en apprendre plus sur ces trois types d'outils et de commencer à les utiliser.

L'outil de communication priorisé par les auteurs du chapitre 8 est Slack, une plateforme de communication utilisée dans le monde professionnel et académique où se trouvent différents salons de conversations et qui possède une tonne de fonctionnalités telles que les appels de groupes et le partage de documents. Gofine et Clark (2017) notent que Slack est un outil spécialement utile pour la communication, la planification et le partage de document en milieu académique. En ce qui concerne la documentation existente, le site Web de Slack contient plusieurs pages

12 Kit de démarrage pour les sciences sociales numériques

portant sur les différentes options de l'application ainsi que des liens vers des vidéos réalisées par leur équipe afin d'aider les utilisateurs à utiliser l'outil de manière efficace. La chaîne Youtube de la compagnie contient plusieurs vidéos aidant les nouveaux usagers à naviguer l'application. Du côté livre, le court ouvrage de Jonathan Miller *Getting Started with Slack: A Quick Start Guide for Everyone*, disponible sur le Web en format Kindle, est une bonne introduction à l'utilisation de Slack. L'auteur présente différentes techniques afin d'optimiser les communications d'équipe et les bonnes pratiques en terme d'utilisation de l'outil.

En ce qui a trait aux outils de gestion de versions, Git est le logiciel priorisé. Git est souvent utilisé à partir de GitHub, la plateforme Web principale pour l'outil. Le chapitre 8 présente Git et GitHub ensemble puisqu'ils sont utilisés de manière complémentaire par de nombreux usagers. Pour beaucoup d'utilisateurs, Git est la façon dont ils intéragissent avec le site Web GitHub, où se trouve leur données, à partir de la ligne de commande de leur ordinateur. D'autres téléchargent directement leurs fichiers à partir du Web et utilisent Git à partir de l'interface GitHub. Bien que certains utilisent Git mais pas GitHub, nous pensons que pour commencer, il est souhaiter d'utiliser les deux outils ensemble. Outre le contenu du chapitre 8, afin de commencer à utiliser Git et GitHub, il est possible de consulter le site Web de GitHub, qui contient beaucoup de documentation, et sur lequel il faut d'ailleurs se créer un compte. Plus d'une dizaine de livres sur Git et GitHub sont accessibles sur le Web. Après les avoir consulté, aucun d'entre eux ne semblent particulièrement pertinent à recommander ici. Rien ne semble battre l'abondance de ressources disponible sur le site de GitHub. Il contient même plusieurs dizaines de tutoriels afin d'en apprendre davantage sur les différentes commandes Git et les façons d'utiliser GitHub. Il est possible de trouver cela à l'adresse suivante : <https://skills.github.com/>. Consulter les différentes pages de documentation sur GitHub et commencer à utiliser l'outil semble être la meilleure manière d'apprendre.

Finalement, pour ce qui concerne les outils d'entreposage de données, les options proposées au chapitre 8 sont les plateformes Dropbox et Amazon Web Services (AWS). Commencer à utiliser Dropbox est assez intuitif.

12.4 Avancé

C'est similaire à l'arborescence de fichier d'un ordinateur commun, mais en ligne. Et puisque Dropbox peut être téléchargé et installé comme d'autres applications sur les différentes versions de Windows, de MacOS et de Linux, il est possible de synchroniser un dossier Dropbox en local avec son Dropbox en ligne. La seule chose qu'il faut pour utiliser Dropbox, c'est de se créer un compte. Il existe des forfaits payants pour avoir accès à plus d'espace de stockage, mais à la base, c'est gratuit. L'application peut être téléchargé sur le site Web de Dropbox. En ce qui concerne AWS, il existe plusieurs solutions et autant de forfaits qui y sont associés. Le site de AWS a énormément de documentation sur les différents services offerts et les fonctionnalités de l'outil. Ils ont leur guide d'apprentissage et plus de 100 tutoriels. Leur documentation est très complète et il y a peu de raisons de recommander un des quelques livres en ligne qui existent et qui sont essentiellement des copiés-collés de leur site Web. AWS a aussi un chatbot qui peut répondre à vos question en temps réel et il apparaît assez efficace.

12.4.2 Outils d'intelligence artificielle

Le chapitre 9 porte sur les différents outils liés à l'utilisation de l'intelligence artificielle. Plus spécifiquement, il présente le site d'OpenAI, qui contient notamment le fameux ChatGPT. Une grande quantité de publications, autant académiques que non académiques, sont parues dans les dernières années sur les différentes facettes de l'intelligence artificielle. La présente section fait état de quelques ressources utiles choisies pour leur pertinence et leur utilité dans l'apprentissage des outils d'intelligence artificielle d'OpenAI.

Le site Web de la compagnie OpenAI contient une grande quantité d'information sur l'utilisation de leurs différents outils. Leur site Web contient notamment un index des différents articles portant sur leurs produits. Il est possible de consulter ledit index à l'adresse suivante : <https://openai.com/research>. Tous les ouvrages disponibles ne sont pas

12 Kit de démarrage pour les sciences sociales numériques

nécessairement publiés dans des journaux revues par les pairs. Il faut faire attention avec les sources qu'on utilise qui sont disponibles gratuitement en ligne et dont les auteurs n'ont potentiellement pas eu à rendre de compte à des pairs avant leur publication.

L'ouvrage *ChatGPT for Higher Education and Professional Development: A Guide to Conversational AI* de Stephen Atlas est intéressant puisqu'il discute des différents mythes entourant ChatGPT avant de se lancer dans comment l'utiliser à différentes fins. Il offre une vision édifiante de son utilisation dans le monde universitaire et répond à de nombreuses questions fréquemment posées. Le livre de Sinan Ozdemir intitulé *Quick Start Guide to Large Language Models: Strategies and Best Practices for Using ChatGPT and Other LLMs* est aussi considéré comme un bon outil pour apprendre comment fonctionne ChatGPT. Il offre aux lecteurs une grande quantité d'information utiles et touche également notamment aux meilleures pratiques à utiliser lors de l'utilisation d'outils tels que ChatGPT. Il présente également ce qui se trouve derrière de tels outils et comment en tirer le plus possible. Enfin, plusieurs publications récentes traitent de trucs et astuces afin de bien commencer à utiliser. C'est notamment le cas de Lubiana et al. (2023) qui présente 10 choses à considérer lors de l'utilisation des récentes versions de ChatGPT, et de Patton et al. (2023) qui écrivent sur les opportunités et les défis de ChatGPT en sciences sociales numériques.

12.4.3 Pièges pour usagers avancés

L'un des pièges importants à éviter lorsque le chercheur se retrouve à un niveau avancé est la peur de partager son code. Ceci est spécialement vrai pour ceux pour qui l'apprentissage c'est fait en silo. Estimant leur code comme étant une propriété intellectuelle, plusieurs chercheurs développent cette réticence et refusent de partager le fruit de leur labeur. Toutefois, partager son code comporte de nombreux avantages, non seulement pour les autres membres de la communauté, mais également pour le chercheur lui-même. D'un côté, cela permet de recevoir des rétroactions de la part

12.5 Conclusion

d’autres chercheurs et développeurs. Cette collaboration peut donc grandement contribuer à l’amélioration de son code. De plus, partager son code représente une opportunité d’apprentissage pour les autres membres de la communauté qui peuvent s’en inspirer pour développer leurs compétences ou même le réutiliser dans leur propre projet. Cette transparence et cette collaboration sont donc avantageuses pour tous les partis.

Le deuxième piège pour usagers avancés duquel le chercheur avancé doit se méfier est de laisser le parfait devenir l’ennemi du bien. Certains chercheurs ont parfois tendance à être perfectionnistes et à perdre du temps et de l’énergie sur des détails mineurs qui n’ont, en fin de compte, aucune retombée majeure sur la qualité globale du projet, comme chercher à optimiser son code de manière excessive. Se soucier de la qualité de son travail est essentiel, mais le chercheur avancé doit également apprendre à savoir quand s’arrêter.

Après avoir consacré de nombreuses heures et travaillé d’arrache-pied pour acquérir des connaissances avancées en codage, le chercheur a de quoi être fière. Toutefois, il doit se méfier de l’ultime pièges pour usagers avancés : manquer d’empathie et de compréhension envers les nouveaux utilisateurs. Certains chercheurs de niveau avancé peuvent oublier qu’ils ont déjà été, eux aussi, des débutants. Il faut éviter de prendre pour acquis certaines connaissances de base qui peuvent sembler très simple pour un chercheur avancé, mais très complexe pour un débutant. Soutenir les nouveaux utilisateurs dans leur apprentissage avec patients et empathie permet une meilleure transmission des connaissances.

12.5 Conclusion

Le but du présent chapitre était d’offrir des informations additionnelles aux chapitres précédents dans le but de faciliter l’apprentissage des différents outils de travail en sciences sociales numériques présentés. Nous avons ici mis l’accent sur deux choses afin d’aider le lecteur. Premièrement, nous

12 Kit de démarrage pour les sciences sociales numériques

avons offert plusieurs ressources à consulter afin d'accéder et d'apprendre à utiliser les outils mis de l'avant. Les différents outils ont été classé selon la difficulté perçue et relative de leur apprentissage. Nous avons classé les outils ainsi puisque c'est généralement l'ordre dans laquelle les praticiens des sciences sociales numériques les apprennent. Afin de faciliter l'expérience d'apprentissage des lecteurs, nous avons pré-sélectionné certaines lectures considérées pertinentes dans le but d'éviter aux lecteurs une surcharge d'information. Nous avons choisi des ressources qui sont facilement accessibles en ligne et qui sont gratuites pour la plupart.

Ensuite, à la fin de chaque section, nous avons présenté les différents pièges associés aux divers niveaux d'apprentissage. Notre expérience indique que plusieurs comportements et attitudes sont liés à certains stades d'apprentissage. Évidemment, certains peuvent survenir plus tôt ou tard que d'autres. L'important est d'être au courant des mauvais plis qu'il est possible d'adopter et de les adresser en amont. Plusieurs des pièges susmentionnés suivent de nombreux professionnels pendant longtemps et compliquent leur travail individuel et collaboratif. Un praticien des sciences sociales numériques avertit en vaut deux.

References

- Adcock, Robert, and David Collier. 2001. "Measurement Validity: A Shared Standard for Qualitative and Quantitative Research." *American Political Science Review* 95 (3): 529–46. <https://doi.org/10.1017/S0003055401003100>.
- Allaire, JJ. 2022. *Announcing Quarto, a New Scientific and Technical Publishing System*. <https://posit.co/blog/announcing-quarto-a-new-scientific-and-technical-publishing-system/>.
- Alpaydin, Ethem, and Francis Bach. 2014. *Introduction to Machine Learning*. 3e ed. Massachusetts: MIT Press. <https://ebookcentral.proquest.com/lib/umontreal-ebooks/detail.action?docID=3339851>.
- Argyle, Lisa P., Ethan C. Busby, Nancy Fulda, Joshua R. Gubler, Christopher Rytting, and David Wingate. 2023. "Out of One, Many: Using Language Models To Simulate Human Samples." *Political Analysis* 31 (3): 337–51. <https://doi.org/10.1017/pan.2023.2>.
- Ballhausen, Miriam. 2019. "Free and Open Source Software Licenses Explained." *Computer* 52 (6): 82–86. <https://doi.org/10.1109/MC.2019.2907766>.
- Bengio, Yoshua. 2023. "One of the "Godfathers of AI" Airs His Concerns." *The Economist*, July 21, 2023. <https://www.economist.com/by-invitation/2023/07/21/one-of-the-godfathers-of-ai-air-concerns>.
- Béraud, Cyrille. 2007. "Le Logiciel Libre, Une Cause Nationale, Une Opportunité Pour Le Québec." FACIL. https://facil.qc.ca/files/2008-11-06_Assnat_0.pdf.
- Bertolini, Andrea. 2020. "Artificial Intelligence and Civil Liability." Policy Department for Citizen's Rights and Constitutional Affairs. Brussel: European Union. <https://www.europarl.europa.eu/RegData/etudes/>

References

- STUD/2020/621926/IPOL_STU(2020)621926_EN.pdf.
- Bessen, James. 2002. “What Good Is Free Software?” In *Government Policy Toward Open Source Software*, edited by Robert W. Hahn, 12–33. Brookings Institution Press. <https://www.jstor.org/stable/10.7864/j.cttvbd8kmv.5>.
- Bourgeois, Isabelle. 2021. “Qu'est-Ce Que La Recherche Sociale?” In *Recherche Sociale. De La Problématique à La Collecte Des Données*, 7e ed., 1–14. Boisbriand: Presses de l'Université du Québec.
- Bremmer, Ian, and Mustafa Suleyman. 2023. “The AI Power Paradox.” *Foreign Affairs*, 2023.
- Broca, Sébastien. 2013. *Utopie Du Locial Libre. Du Bricolage Informatique à La Réinvention Sociale*. Lyon: Le passage clandestin.
- Couture, Stéphane. 2014. “Les logiciels libres, un an plus tard.” Institut de recherche et d'informations socioéconomiques. 2014. <https://iris-recherche.qc.ca/blogue/secteur-public-et-communautaire/les-logiciels-libres-un-an-plus-tard/>.
- . 2020. “Free and Open Source Software.” In *The Handbook of Peer Production*, 153–68. John Wiley & Sons, Ltd. <https://doi.org/10.1002/9781119537151.ch12>.
- Dévédec, Nicolas Le. 2021. “"Sans Limites": Une Critique Politique Et Écologique Du Transhumanisme Et de Son Monde.” *Cahiers Société* 3: 99–122. <https://doi.org/10.7202/1090180ar>.
- Devedzic, Vladan. 2022. “Identity of AI.” *Discover Artificial Intelligence* 2 (23). <https://doi.org/10.1007/s44163-022-00038-0>.
- Encyclopaedia Britannica. 2023. *LaTeX*. <https://www.britannica.com/technology/LaTeX-computer-programming-language>.
- Forestier, François, and François Ansermet. 2021. “Le Transhumanisme.” In *La Dévoration Numérique*, 19–54. Paris: Odile Jacob. <https://www.cairn.info/la-devoration-numerique--9782415000240-page-19.htm>.
- Fortunato, Laura, and Mark Galassi. 2021. “The Case for Free and Open Source Software in Research and Scholarship.” *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* 379 (2197): 20200079. <https://doi.org/10.1098/rsta.2020.0079>.

References

- Gaudeul, Alex. 2007. “Do Open Source Developers Respond to Competition? The LATEX Case Study.” *Review of Network Economics* 6 (2). <https://doi.org/10.2202/1446-9022.1119>.
- Goldfarb, Charles F. 1996. *The Roots of SGML – A Personal Recollection*. <http://www.sgmlsource.com/history/roots.htm>.
- Hameed, Sharqa. 2023. *HTML History / Explained*. <https://linuxhint.com/html-history/>.
- Hanchen Wang, Tianfan Fu, Yuanqi Du, Wenhao Gao, Kexin Huang, Ziming Liu, Payal Chandak, Shengchao Liu, Peter Van Katwyk, Andreea Deac, Anima Anandkumar, Karianne Bergen, Carla P. Gomes, Shirley Ho, Pushmeet Kohli, Joan Lasenby, Jure Leskovec, Tie-Yan Liu, Arjun Manrai, Debora Marks, Bharath Ramsundar, Le Song, Jimeng Sun, Jian Tang, Petar Veličković, Max Welling, Linfeng Zhang, Connor W. Coley, and Yoshua Bengio, & Marinka Zitnik. 2023. “Scientific Discovery in the Age of Artificial Intelligence.” *Nature* 620: 47–60. <https://www.nature.com/articles/s41586-023-06221-2>.
- Harari, Yuval Noah. 2023. “Yuval Noah Harari Argues That AI Has Hacked the Operating System of Human Civilisation.” *The Economist*, April 28, 2023. <https://www.economist.com/by-invitation/2023/04/28/yuval-noah-harari-argues-that-ai-has-hacked-the-operating-system-of-human-civilisation>.
- Hughes, Jonathan. 2013. “Cameos, Supporting Roles and Stars: Citation and Reflection in the Context of Initial Teacher Education.” *Educational Research* 55 (1): 16–30. <https://doi.org/10.1080/00131881.2013.767023>.
- IBM. 2023a. “What Are Neural Networks? | IBM.” 2023. <https://www.ibm.com/topics/neural-networks>.
- . 2023b. “What Is Artificial Intelligence (AI) ? | IBM.” IBM. 2023. <https://www.ibm.com/topics/artificial-intelligence>.
- Janssen, Marco A. 2017. “The Practice of Archiving Model Code of Agent-Based Models.” *Journal of Artificial Societies and Social Simulation* 20 (1): 2.
- Janssen, Marco A., Calvin Pritchard, and Allen Lee. 2020. “On Code Sharing and Model Documentation of Published Individual and Agent-

References

- Based Models.” *Environmental Modelling & Software* 134 (December): 104873. <https://doi.org/10.1016/j.envsoft.2020.104873>.
- Just, Jérémie. 2013. “Les Distributions - Groupe Francophone Des Utilisateurs de TeX, LaTeX Et Logiciels Compagnons.” March 25, 2013. <https://www.gutenberg-asso.fr/Les-distributions>.
- Kabacoff, Robert. 2022. *R in Action: Data Analysis and Graphics with R and Tidyverse*. Third edition. Shelter Island, NY: Manning Publications.
- Karjalainen, Martti. 2010. “Large-Scale Migration to an Open Source Office Suite: An Innovation Adoption Study in Finland.” University of Tampere. <https://trepo.tuni.fi/bitstream/handle/10024/66646/978-951-44-8216-8.pdf?sequence=1>.
- Kibbee, Matthew. 2023. “A Guide to Evidence Synthesis:” Cornell University Library Evidence Synthesis Service. 2023. <https://guides.library.cornell.edu/evidence-synthesis/service>.
- King, Gary, Robert O. Keohane, and Sidney Verba. 2021. *Designing Social Inquiry. Scientific Inference in Qualitative Research*. Nouvelle édition. Princeton: Princeton University Press.
- Knauff, Markus, and Jelica Nejasmic. 2014. “An Efficiency Comparison of Document Preparation Systems Used in Academic Research and Development.” Edited by Cynthia Gibas. *PLoS ONE* 9 (12): e115069. <https://doi.org/10.1371/journal.pone.0115069>.
- König, Pascal D., Tobias D. Krafft, Wolfgang Schulz, and Katharina A. Zweig. 2022. “Essence of AI. What Is AI?” In *The Cambridge Handbook of Artificial Intelligence*, edited by and Michel Cannarsa Cristina Poncibò, 18–34. Cambrigde: Cambridge University Press. <https://doi.org/10.1017/9781009072168.005>.
- Kostoff, Ronald N., and Russell M. Cummings. 2013. “Highly Cited Literature of High-Speed Compressible Flow Research.” *Aerospace Science and Technology* 26 (1): 216–34. <https://doi.org/10.1016/j.ast.2012.04.006>.
- Krähmer, Daniel, Laura Schächtele, and Andreas Schneck. 2023. “Care to Share? Experimental Evidence on Code Sharing Behavior in the Social Sciences.” *PLOS ONE* 18 (8): e0289380. <https://doi.org/10.1371/jour>

References

- nal.pone.0289380.
- Markdown Guide. 2023. *Getting Started*. <https://www.markdownguide.org/getting-started/>.
- Marres, Noortje. 2017. *Digital Sociology. The Reinvention of Social Research*. Cambridge: Polity.
- McAdoo, Timothy. 2023. “How to Cite ChatGPT.” <https://apastyle.apa.org/blog/how-to-cite-chatgpt>. April 7, 2023. <https://apastyle.apa.org/blog/how-to-cite-chatgpt>.
- McCarthy, John. 2007. “WHAT IS ARTIFICIAL INTELLIGENCE?”
- Morandat, Floréal, Brandon Hill, Leo Osvald, and Jan Vitek. 2012. “Evaluating the Design of the R Language.” In *ECOOP 2012 – Object-Oriented Programming: 26th European Conference, Beijing, China, June 11-16, 2012. Proceedings*, edited by James Noble, 7313:104–31. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-642-31057-7>.
- Muenchen, Robert A. 2011. *R for SAS and SPSS Users*. 2nd ed. Statistics and Computing. New York: Springer.
- Open Source Initiative. 2006. “The Open Source Definition.” Open Source Initiative. July 7, 2006. <https://opensource.org/osd/>.
- Park, Joon Sung, Joseph C. O’Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. 2023. “Generative Agents: Interactive Simulacra of Human Behavior.” *arXiv*. <https://doi.org/10.48550/arXiv.2304.03442>.
- Paura, Liga, and Irina Arhipova. 2012. “Advantages and Disadvantages of Professional and Free Software for Teaching Statistics.” *Information Technology and Management Science* 15 (1). <https://doi.org/10.2478/v10313-012-0001-z>.
- Peterson, Joshua C., David D. Bourgin, Mayank Agrawal, Daniel Reichman, and Thomas L. Griffiths. 2021. “Using Large-Scale Experiments and Machine Learning to Discover Theories of Human Decision-Making.” *Science* 372 (6547): 1209–14. <https://doi.org/10.1126/science.abe2629>.
- Quarto. 2023. *Get Started*. <https://quarto.org/docs/get-started/>.
- Racz, Aleksandar, and Suzana Marković. 2018. “‘Worth(less) Papers’ – Are Journal Impact Factor and Number of Citations Suitable Indicators

References

- to Evaluate Quality of Scientists?” *Nova Prisutnost* XVI (2): 369–88. <https://doi.org/10.31192/np.16.2.10>.
- Roser, Max. 2022. “The Brief History of Artificial Intelligence: The World Has Changed Fast – What Might Be Next?” Our World in Data. December 6, 2022. <https://ourworldindata.org/brief-history-of-ai>.
- Santillán-Anguiano, Ernesto Israel, and Emilia Cristina González-Machado. 2023. “Advantages of a Free Software Culture for Qualitative Researchers in the Social Sciences.” *International Journal of Qualitative Research* 3 (1): 97–103. <https://www.ojs.literacyinstitute.org/index.php/ijqr/article/view/841>.
- Sarkar, Deepayan. 2008. *Lattice: Multivariate Data Visualization with R*. New York, NY: Springer New York. <https://doi.org/10.1007/978-0-387-75969-2>.
- . 2023. “Trellis Graphics for R.” <https://cran.r-project.org/web/packages/lattice/lattice.pdf>.
- Sartre, Jean-Paul. 1996. *L'existentialisme Est Un Humanisme*. Paris: Gallimard.
- Smith, Bradford L. 2002. “The Future of Software: Enabling the Marketplace to Decide.” In *Government Policy Toward Open Source Software*, edited by Robert W. Hahn, 69–86. Brookings Institution Press. <https://www.jstor.org/stable/10.7864/j.ctvbd8kmv.8>.
- Stack Overflow. 2023. *Stack Overflow*. <https://stackoverflow.com/>.
- Stallman, Richard. 1986. “GNU’s Bulletin.” 1986. <https://www.gnu.org/bulletins/bull1.txt>.
- . 2022. “En Quoi l’open Source Perd de Vue l’éthique Du Logiciel Libre - Projet GNU - Free Software Foundation.” Système d’exploitation GNU. 2022. <https://www.gnu.org/philosophy/open-source-misses-the-point.html>.
- Système d’exploitation GNU. 2023. “Catégories de Logiciels Libres Et Non Libres - Projet GNU - Free Software Foundation.” Système d’exploitation GNU. 2023. <https://www.gnu.org/philosophy/categories.html#>.
- Tippmann, Sylvia. 2015. “Programming Tools: Adventures with R.” *Nature* 517 (7532): 109–10. <https://doi.org/10.1038/517109a>.

References

- Wang, Pei. 2019. “On Defining Artificial Intelligence.” *Journal of Artificial General Intelligence* 10 (2): 1–37. <https://doi.org/10.2478/jagi-2019-0002>.
- Weise, Karen, and Cade Metz. 2023. “When A.I. Chatbots Hallucinate.” *The New York Times*, May 9, 2023. <https://www.nytimes.com/2023/05/01/business/ai-chatbots-hallucination.html>.
- Wickham, Hadley. 2009. *Ggplot2: Elegant Graphics for Data Analysis*. New York, NY: Springer New York. <https://doi.org/10.1007/978-0-387-98141-3>.
- Wickham, Hadley, Mara Averick, Jennifer Bryan, Winston Chang, Lucy McGowan, Romain François, Garrett Grolemund, et al. 2019. “Welcome to the Tidyverse.” *Journal of Open Source Software* 4 (43): 1686. <https://doi.org/10.21105/joss.01686>.
- Wickham, Hadley, Mine Çetinkaya-Rundel, and Garrett Grolemund. 2023. *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. Second edition. Beijing: O'Reilly.
- Williams, Sam, Richard M Stallman, and Christophe Masutti. 2010. *Richard Stallman et la révolution du logiciel libre - Une biographie autorisée*. s.l.: Eyrolles. https://iso.framadvd.org/standard/content2011/ubuntu/Data/Documents/pdf/framabooks/framabook6_stallman_v1_gnu-fdl.pdf.
- World Wide Web Consortium (W3C). 1998. *Extensible Markup Language (XML) 1.0*. <https://www.w3.org/TR/1998/REC-xml-19980210.html>.
- “Wow! Ten Million Users!” n.d. Accessed March 9, 2024. <https://www.owrleaf.com/blog-wow-ten-million-users>.
- Xie, Yihui. 2023. *Markdown*. <https://github.com/rstudio/markdown>.
- Yu, Jingyuan, and Juan Muñoz-Justicia. 2022. “Free and Low-Cost Twitter Research Software Tools for Social Science.” *Social Science Computer Review* 40 (1): 124–49. <https://doi.org/10.1177/0894439320904318>.
- Zaid, Yasmin Hanafi, Sarimah Shamsudin, and Hadina Habil. 2017. “Exploring Citations in Chemical Engineering Literature Review.” *LSP International Journal* 4 (1, 1). <https://doi.org/10.11113/lspi.v4n1.46>.

